


ฤดูใบไม้ผลิแห่งโลกโอเพนซอร์ส: การปฏิวัติสถาปัตยกรรม LLM

เจาะลึก 11 สถาปัตยกรรมเปลี่ยนโลกจากมกราคม-กุมภาพันธ์ 2026




>_

[SYSTEM] INIT_ANALYSIS...
[DATASET] 11_MODELS_Q1_2026
[FOCUS] ARCHITECTURAL_EVOLUTION

11 โมเดล 1 ล้านล้านพารามิเตอร์ และการเปลี่ยนผ่านครั้งใหญ่


การต่อสู้ในโลก Open-Weight ต้นปี 2026 ไม่ได้วัดกันที่ปริมาณข้อมูลเพียงอย่างเดียว แต่คือการแข่งขันเพื่อเอาชนะขีดจำกัดทางสถาปัตยกรรม (Architectural Bottlenecks) โดยเฉพาะการจัดการหน่วยความจำสำหรับ Long Context

TOTAL MODELS:	11
MAX SCALE:	1 Trillion Parameters (Kimi K2.5, Ling 2.5)
NEW PARADIGMS:	Hybrid Attention, MTP, Parallel Blocks



จุดจบของ Standard Attention และทางรอดของ Long Context


The Problem



ปัญหา: กลไก Attention แบบดั้งเดิม
มีต้นทุนการคำนวณระดับ $O(n^2)$
ทำให้การประมวลผล Context ยาวๆ
ใช้หน่วยความจำมหาศาล


The Solutions

Tech Tree




Sliding Window / GQA
(Classic Efficiency)

ลดการใช้ทรัพยากรด้วยการโฟกัสเฉพาะ Token
ใกล้เคียง (SWA) หรือแชร์ Key/Value (GQA)



Multi-Head Latent Attention - MLA
(DeepSeek Style)

บีบอัด KV Cache ลงใน Latent Space เพื่อ
ลดแบนด์วิดท์หน่วยความจำ



Hybrid / Linear Attention
(The Frontier)


แทนที่ Attention ด้วย Fast-weight
memory หรือกลไกแบบ Linear สำหรับ
Context ลึกแสน

สถาปัตยกรรม Hybrid Attention: ทะลวงขีดจำกัด 262k ทอเคน

โมเดลอย่าง Qwen3-Coder-Next (80B) เอาชนะ DeepSeek V3.2
ในด้านการเขียนโค้ดได้ด้วยการเปลี่ยนโครงสร้าง Attention ใหม่ทั้งหมด

Native 262k context
length memory efficiency

Qwen3-Coder-Next Attention Block




GQA แบบดั้งเดิมที่เสริมด้วย
Output Gate เพื่อรักษาความแม่น
ยำในการค้นหาข้อมูลเชิงลึก

แทนที่ Attention ปกติด้วย Fast-weight
memory อัปเดตข้อมูลด้วยกฎ Delta Rule
ใช้หน่วยความจำคงที่ ไม่ขยายตามความยาว

Multi-Token Prediction (MTP): ทวีคูณความเร็วทั้ง Training และ Inference

การคาดการณ์เพียง 1 token อาจไม่ทันใจ Step 3.5 Flash (196B) นำเทคนิค MTP-3 มาใช้เพื่อเร่งความเร็วทะลุขีดจำกัด


Standard Next-Token



The Mechanism

แทนที่จะเดาแค่คำถัดไป โมเดลมี Heads พิเศษสำหรับเดาคำที่ $t+1$, $t+2$ และ $t+3$ พร้อมกัน

MTP-3



Performance


ความเร็วสูงกว่า DeepSeek V3.2 ถึง 3 เท่า ด้วยขนาดพารามิเตอร์ที่เล็กกว่า

Step 3.5 Flash Throughput:
100 tokens/sec @ 128k context
(Hopper GPU)

The Titans: สงครามระดับ 1 ล้านล้านพารามิเตอร์

Kimi K2.5


Superpower: Early Fusion
Multimodality สโตร์ DeepSeek



การป้อนข้อมูลภาพและข้อความพร้อมกันตั้งแต่ช่วงแรกของ Pre-training ให้ผลลัพธ์ดีกว่าการนำภาพมาต่อเติมในภายหลัง

Ling 2.5 (Ant Group)

Superpower: Lightning
Attention + MLA



แลกเปลี่ยนประสิทธิภาพเชิงสัมบูรณ์กับความเร็วที่เหนือกว่า Kimi K2 ถึง 3.5 เท่าในบริบท 32k


Flagship Heavyweights: หักต่อหัดระดับเวิลด์คลาส

GLM-5 (z.AI) - 744B

- **Key Shift:** รับเอาเทคนิค **DeepSeek Sparse Attention** และ **MLA** เข้ามาใช้เต็มรูปแบบ
- **Design Choice:** **Reduced Transformer Layers** (92 -> 78) but **Increased Experts** (160 -> 256) เพื่อลด Inference Cost แบบขนาน

เทียบชั้น **GPT-5.2** และ **Claude 4.6 Opus**

Architectural Comparison



Qwen3.5 - 397B


- **Key Shift:** ขยายสเกลและนำ **Gated DeltaNet (Hybrid Attention)** เข้าสู่สายพานการผลิตหลัก (Mainline)
- **Design Choice:** โฟกัสความสามารถแบบ **Agentic Terminal Coding** อย่างเต็มรูปแบบ

The Speed & Coding Specialists: ประสิทธิภาพคุ้มค่าการคำนวณ

SWE-Bench

MiniMax M2.5 (230B)

Concept: ความเรียบง่ายที่ทรงพลัง
(The Power of Simplicity)




Architecture: สอนกระแสโลก! ไม่ใช่ Hybrid หรือ MTP
ใช้เพียง Plain Grouped Query Attention (GQA) แบบ
คลาสสิก แต่รีดประสิทธิภาพการเขียนโค้ดได้ล้ำหน้า GLM-5

SWE-Bench

Step 3.5 Flash (196B)


Concept: ราชแห่ง Throughput (Throughput King)



Architecture: มีพารามิเตอร์ที่แอดทิฟเพียง 11B (เทียบกับ
DeepSeek V3.2 ที่ 37B) ผสานการทำงานร่วมกับ MTP-3
เพื่อให้ได้ 100 tokens/sec อย่างเสถียร


The Architectural Wildcard: นวัตกรรมโครงสร้างจาก Arcee Trinity

Model: Arcee Trinity Large (400B MoE / 13B Active)




The Small Giants (Edge): ขุมพลังระดับ Local

Sequential Block (Classic)



Parallel Transformer Block (Tiny Aya)



Tiny Aya (3.35B) - Cohere

Innovation: สถาปัตยกรรม Parallel Transformer Block
คำนวณ Attention และ MLP ไปพร้อมกันจาก Input เดียวกัน
เพื่อลดคอขวด (Serial dependencies) และเพิ่ม Throughput


Engineering Note: ถอด QK-Norm ออกทั้งหมด เพราะพบว่าไป
ขัดขวางประสิทธิภาพในบริบท Long Context

Nanbeige 4.1 (3B)

Context: โครงสร้างคล้าย Llama 3 แต่ปลดล็อก
Input/Output Embeddings ออกจากกัน (Untied weights)
แลกจำนวนพารามิเตอร์ที่เพิ่มขึ้นกับ Loss ที่ลดลง

The Regional Masters: สเกลที่เปลี่ยนไป สถาปัตยกรรมที่เปลี่ยนตาม


30B



GQA



MLA



105B


Sarvam 30B vs 105B (India)

- The Scale Divide: โมเดล 30B เลือกใช้ความเรียบง่ายของ GQA (Classic) ในขณะที่โมเดล 105B จำเป็นเปลี่ยนไปใช้โครงสร้าง MLA ขั้นสูงสไตล์ DeepSeek เพื่อจัดการหน่วยความจำ

- Tokenization Efficiency: การสร้าง Tokenizer ใหม่จากศูนย์ ทำให้ประมวลผลภาษาท้องถิ่นอินเดีย ได้มีประสิทธิภาพสูงกว่าโมเดลทั่วไปถึง 4 เท่า

- Performance: ทรงพลังระดับโลก ในงาน Agentic Reasoning (Tau2) ชนะ DeepSeek R1 0528 ในบางดัชนี


แผนภูมิจำแนกวิวัฒนาการของ Attention (Spring 2026)



The Spring 2026 Open-Weight Master Roster

Model	Total Params	Active Params	Attention Type	MTP Usage
Kimi K2.5	1T	~32B	MLA + Vision	No
Ling 2.5	1T	-	Lightning Hybrid + MLA	No
GLM-5	744B	40B	Sparse + MLA	No
Arcee Trinity	400B	13B	3:1 SWA + Gated	No
Qwen 3.5	397B	17B	Gated DeltaNet	No
MiniMax M2.5	230B	-	GQA	No
Step 3.5 Flash	196B	11B	Gated GQA	Yes (MTP-3)
Sarvam 105B	105B	-	MLA	No
Qwen3-Coder	80B	3B	Gated DeltaNet	No
Tiny Aya	3.35B	3.35B	Parallel Block (No QK)	No

สถาปัตยกรรมเปิดประตู แต่ ข้อมูล คือผู้ชนะที่แท้จริง



แม้ว่าเราจะเห็นความหลากหลายของโครงสร้าง (ตั้งแต่ GQA เรียบง่ายไปจนถึง Linear Hybrid สุดซับซ้อน) แต่โครงสร้างพื้นฐานเหล่านี้ล้วนมีรากฐานมาจาก GPT ดั้งเดิม สิ่งที่สร้างความแตกต่างอย่างแท้จริงใน Modeling Performance กลับไม่ใช่แค่โครงสร้าง แต่คือคุณภาพของ Dataset ขั้นตอนการทำ Supervised Fine-Tuning และ Reinforcement Learning

นวัตกรรมทางโครงสร้างมีไว้เพื่อปลดล็อก ‘ความประหยัด (Efficiency)’ แต่สูตรการเทรนคือตัวกำหนด ‘ความฉลาด (Capability)’

จับตามองขอบฟ้าต่อไป (What's Next?)

สถาปัตยกรรมโอเพนซอร์สในไตรมาสแรกของปี 2026 แสดงให้เห็นถึงการหลุดพ้นจากข้อจำกัดเดิมๆ การผสานรวม (Convergence) ของเทคนิคต่างๆ กำลังปูทางไปสู่ก้าวถัดไป

