


การคิดโดยไร้ภาษา: การให้เหตุผลแฝงที่มีประสิทธิภาพด้วย Abstract-CoT


Thinking Without Words: Efficient Latent Reasoning with Abstract Chain-of-Thought



ลดการใช้โทเคนในการประมวลผลสูงสุด 11.6 เท่า ผ่านการเรียนรู้ "ภาษาการให้เหตุผล" แบบเฉพาะตัว
Reduces token consumption by up to 11.6x through learning a unique 'Reasoning Language'

อ้างอิงงานวิจัยโดย Keshav Ramji, Tahira Naseem, และ Ramón Fernandez Astudillo (IBM Research AI)
Based on research by Keshav Ramji, Tahira Naseem, and Ramón Fernandez Astudillo (IBM Research AI)

คอขวดของ Chain-of-Thought: ต้นทุนที่ซ่อนอยู่ของการให้เหตุผลด้วยภาษา



Abstract-CoT: การแทนที่ภาษาด้วย "โทเคนนามธรรม"

เปลี่ยนจากการให้เหตุผลด้วยภาษารธรรมชาติ (Natural Language) เป็นการใช้ลำดับโทเคนแบบไม่ต่อเนื่อง (Discrete Tokens) ที่สงวนไว้เฉพาะ ซึ่งสั้นกว่าและมีขอบเขตจำกัด

Verbalized Chain-of-Thought

Q: A car travels A→B at 60 km/h, rests 30 min at B, then returns at 80 km/h. The total trip takes 4 h. Find the distance from A to B.

<think>

Step 1: Let d be the A→B distance (km).

Step 2: $d/60 + 0.5 + d/80 = 4$.

...

...

Step 8: ...

Step 8: $7d/240 = 7/2 \Rightarrow d = 120$ km.

</think>

Answer: $d = 120$ km

Abstract Chain-of-Thought

Q: A car travels A→B at 60 km/h, rests 30 min at B, then returns at 80 km/h. The total trip takes 4 h. Find the distance from A to B.

<beginabstract>

[E] [C] [AE] [F] [A] [BB] [D]

[G] [BA] [H] [AC] [B] [AD] [F]

<endabstract>

Answer: $d = 120$ km

ภูมิทัศน์ของการให้เหตุผลใน LLM (The Reasoning Landscape)

	Verbal CoT	Continuous Latent (e.g., Coconut)	Pause Tokens	Abstract-CoT (Our Method)
ความเร็วในการ Inference (Speed)	ช้ามาก (Slow)	เร็ว (Fast)	เร็ว (Fast)	เร็วมาก (Very Fast)
ความสามารถในการตีความ (Interpretability)	สูง (High)	ต่ำ (Low)	ต่ำ (Low)	โครงสร้างวิเคราะห์ได้ (Structured/Bounded)
โครงสร้างพื้นที่ (Discrete vs. Continuous)	Discrete	Continuous (ทำให้ควบคุมยาก)	Discrete	Discrete (เสถียร)
ความซับซ้อนในการเทรน (Training Complexity)	ปานกลาง (Medium)	สูงมาก (Very High)	ต่ำ (แต่มักไม่ได้ผลลัพธ์ที่ดี)	โพสต์เทรนนิ่งเท่านั้น (Post-training only)


ปัญหา "Cold Start": เมื่อโทเคนใหม่ไม่มีความหมาย




โทเคนนามธรรม (<TOKEN_A>, <TOKEN_B>) ถูกเพิ่มเข้ามาใหม่
Embedding ของมันเริ่มต้นจากการสุ่ม (Random Initialization)
ทำให้ตอนแรกมัน**ไม่มีความหมาย**หรือนำหนักทางอรรถศาสตร์ใดๆ
โมเดลต้อง ***เรียนรู้*** ที่จะใช้กล่องเปล่าเหล่านี้เป็นเส้นทางในการคิด

ขั้นตอนที่ 1: การสร้างความหมายด้วย Policy Iteration Warm-Up

วงจร 2 ขั้นตอนเพื่อสอนให้โทเคนว่างเปล่าทำหน้าที่เป็นตัวกลางในการคิด




กลไก "คอขวดของข้อมูล" (The Information Bottleneck)



การบังคับให้โมเดลบีบอัดข้อมูล
โดยการปิดกั้นไม่ให้คำตอบสุดท้าย
(Final Answer) มองเห็นกระบวนการ
การคิดแบบภาษา (Verbal CoT)


ขั้นตอนที่ 2: การปรับปรุงด้วย Warm-Started RL และ GRPO

ใช้ Reinforcement Learning โดยบังคับให้ถอดรหัส (Constrained Decoding) เฉพาะคำศัพท์ที่เป็นโทเคนนามธรรมเท่านั้น



ท้าวกระโดด 11.6 เท่า: ประสิทธิภาพที่เพิ่มขึ้นโดยไม่สูญเสียความแม่นยำ

Abstract-CoT สามารถทำคะแนนเทียบเท่าหรือดีกว่า SFT+RL แบบดั้งเดิม โดยใช้ปริมาณการคำนวณเพียงเศษเสี้ยว



การทำงานที่ครอบคลุม: จากคณิตศาสตร์สู่การให้เหตุผลแบบหลายขั้นตอน

ทดสอบบนโมเดล Qwen3-8B (อ้างอิงจากข้อมูลการทดลองหลัก)

MATH-500
(Verifiable)



ใช้โทเคนลดลง **11.6 เท่า**
เทียบกับ Verbal CoT

AlpacaEval
(Instruction Following)



เพิ่มขีดความสามารถใน
ในการทำตามคำสั่ง
(Instruction Following)

HotpotQA
(Multi-hop)




ใช้โทเคนลดลง **4 เท่า**
ในการคิดแบบหลายขั้นตอน
(Multi-hop)


การค้นพบ: LLM สร้าง "ภาษาเอเลียน" ของตัวเอง

ระหว่างกระบวนการ RL โมเดลพัฒนารูปแบบการใช้คำศัพท์ที่คล้ายกับกฎของ Zipf (Power-law) ในภาษาเมนุษย์ โดยกำหนดความหมายและรูปแบบการใช้ซ้ำให้กับโทเคนนามธรรม

การพัฒนาความถี่โทเคนตามขั้นตอน RL




การกระจายโทเคนตามอันดับ (Zipf's Law)



บทพิสูจน์ของการ "คิด": การทดสอบ Compositionality

โมเดลไม่ได้แค่จำคำตอบ แต่กำลัง "คิด" เป็นลำดับขั้นตอน
หากทำลายโครงสร้างของโทเคนนามธรรม ประสิทธิภาพจะลดลงทันที


Permutation (การสลับตำแหน่ง)



Accuracy Drops (-7.8%)

พิสูจน์ว่าลำดับและไวยากรณ์ในภาษาแฟงมีความสำคัญ


Truncation (การตัดจบกลางคัน)



Accuracy degrades gracefully (-6.0%)


ต่างจาก Verbal CoT ที่จะพังทลายทันทีเมื่อถูกตัดจบ

ขนาดของคำศัพท์: โมเดลต้องการโทเค็นที่ตัวในการคิด?




สังเคราะห์: จุดกึ่งกลางที่สมบูรณ์แบบสำหรับการสเกล Inference

ปลดล็อกศักยภาพการขยายขนาดการอนุมาน (Inference Scaling)
สำหรับงานที่มนุษย์ไม่จำเป็นต้องอ่านและทำความเข้าใจกระบวนการคิด



บทสรุป (Key Takeaways)



1. ประสิทธิภาพ
โทเคน (**Token Efficiency**): ลด
ต้นทุนการให้เหตุผล
ระดับกลางลงกว่า
10 เท่า โดยยังรักษา
ประสิทธิภาพระดับ
SFT+RL ไว้ได้



2. โฟสต์เทรนนิ่ง
**100% (Post-
Training Only)**: ไม่
ต้องทำ Pre-training
ใหม่ทั้งหมด สามารถ
บรรลุผลได้ผ่าน
กระบวนการ **SFT** และ
GRPO แบบเฉพาะ



3. พรอมแดนใหม่ของ
**AI (A New
Frontier)**: พิสูจน์
แล้วว่า LLM สามารถ
เรียนรู้และปรับแต่ง
"ภาษาที่ไม่ใช่คำพูด"
ของตัวเองเพื่อใช้แก้
ปัญหาที่ซับซ้อนได้
อย่างอิสระ