


จุดเริ่มต้นของยุคการหลอมรวม Vision AI

โมเดลภาษา (LLMs) ก้าวสู่อิสรภาพ
ด้วย BPE (Byte Pair Encoding)
ที่แปลงทุกตัวอักษรเป็นหนึ่ง
มาตรฐาน


Vision AI ยังคงติดอยู่ใน
ข้อจำกัดของมิติภาพและรูปแบบ
งานที่แยกส่วนกัน

ATOKEN คือ Visual Tokenizer
ตัวแรกที่ทลายกำแพงระหว่างภาพ,
วิดีโอ และ 3D ในสถาปัตยกรรมเดียว




ปัญหาความแตกต่างในโลกของ Visual Representation

โลกของข้อความ (Text): ประสบความสำเร็จ
ด้วยโทเคนมาตรฐานเดียวที่รองรับทุกข้อมูล




โลกของการมองเห็น (Vision):
ถูกจำกัดด้วยความแตกต่างเชิงโครงสร้าง



ทางแยกที่ต้องเลือก: ความละเอียด หรือ ความเข้าใจ

Reconstruction (SD-VAE, VQGAN)



รักษาความละเอียดระดับพิกเซล (Low-level details)
แต่สูญเสียความหมายเชิงความเข้าใจ (Semantics)

Understanding (CLIP, SigLIP2)



สกัดฟีเจอร์ระดับสูงเพื่อเชื่อมโยงกับข้อความ
แต่ไม่สามารถสร้างภาพย้อนกลับได้ (Cannot reconstruct)


สมการเดียวที่รวมทุกมิติ การมองเห็นเข้าด้วยกัน

ขอแนะนำ ATOKEN

โมเดลที่เข้ารหัสภาพ, วิดีโอ และ 3D ลงใน
Sparse 4D Latent Space ร่วมกัน

ทลายข้อจำกัดเดิม: ทำได้ทั้งความเข้าใจ
(Understanding) และการสร้างภาพ
(Generation) ในตัวเดียว

รองรับความละเอียดแบบ Native และ
ความยาวของเวลาอย่างอิสระผ่าน
สถาปัตยกรรม Pure Transformer



ATOKEN เป็นโมเดลเดียวที่ครอบคลุมทุก Modality, ทุก Task และรองรับทั้ง Continuous/Discrete Tokens โดยปราศจาก GAN


Models	MODALITY:			TASK:		TOKEN:		FEATURES:	
	2D	Video	3D	Recon	Understand	Discrete	Cont.	GAN-free	Native Res
SD-VAE		✗	✗		✗		✗	✗	
VQGAN		✗	✗		✗		✗	✗	
OmniTokenizer								✗	✗
Trellis-SLAT									
SigLIP2	✗	✗	✗	✗			✗		✗
VILA-U			✗	✗					
ATOKEN	✓	✓	✓	✓	✓	✓	✓	✓	✓

การเปรียบเทียบความสามารถตาม Modality, Task, Token และคุณสมบัติเฉพาะ

มิติ 4D Latent Space: ที่อยู่อาศัยของทุกสรรพสิ่ง


แทนที่จะแยกโมเดล ATOKEN ใช้ Sparse Representation เพื่อวางข้อมูลแต่ละประเภทลงใน Subspace ของตัวเองอย่างเป็นธรรมชาติ

ขับเคลื่อนด้วย 4D Rotary Position Embeddings (RoPE) ที่ทำให้ Transformer เข้าใจตำแหน่งสัมพันธ์ข้ามมิติได้อย่างแม่นยำ



t = เวลา, x,y = พิกัดเชิงพื้นที่, z = ความลึก

สายพานการผลิตแบบรวมศูนย์ (The Unified Architecture)




การเชื่อม 3D เข้าสู่ระบบ Tokenizer

การประมวลผล 3D อาศัยการ
เรนเดอร์ภาพจากหลายมุมมอง
(Multi-view Renderings)

ดึงแพทช์ภาพ (RGB patches)
จากมุมมองที่ใกล้ที่สุดมาบรรจุลงใน
3D Voxel


ถอดรหัสด้วย Gaussian Splatting
เพื่อสร้าง 3D Asset กลับมาได้อย่าง
สมจริงโดยใช้โครงสร้างเดียวกับ 2D



Multi-view → Voxel Mapping → Gaussian Projection

พลังของ Dual-Head Projection


ฟีเจอร์ที่ถูกเข้ารหัส (z) ถูกฉายออกเป็นสองเส้นทางคู่ขนานโดยไม่ต้องแยกสถาปัตยกรรม



คอขวดทางเทคนิค: ความล้มเหลวของโครงข่าย GAN


Transformer-based Visual Tokenizers
มักล้มเหลวเมื่อขยายขนาดพารามิเตอร์

- ต้นเหตุ: โครงข่ายแบบเปรียบเทียบ (Adversarial Training / GANs) ขาดความเสถียร
- Discriminator มีพลังมากเกินไป กดทับ Generator จนเกิดสถานะ Mode Collapse และความผิดเพี้ยนของภาพ




ทางออกใหม่: Adversarial-Free Training ด้วย Gram Loss

- ATOken ตัด GAN ที่อย่างสิ้นเชิง
- อาศัยการรวม Perceptual Loss และ Gram Matrix Loss
- เจาะจงแก้ปัญหาที่ Feature Covariance (ซึ่งส่งผลต่อ Texture และ Style ถึง 86.6% ของค่า Error)
- สร้างภาพคุณภาพสูงสุด (State-of-the-Art rFTD) พร้อมความเสถียรในการฝึกสอนตั้งแต่ต้นจนจบ



บันไดแห่งการเรียนรู้ (Progressive Training Curriculum)

การฝึกสอนแบบค่อยเป็นค่อยไป
เริ่มจากพื้นฐาน 2D ไปสู่มิติที่ซับซ้อนขึ้น




ปรากฏการณ์ Multimodal Regularization (The Aha Moment)

คำถาม: การบังคับให้โมเดลทำได้ทุกอย่าง
จะทำให้คุณภาพในแต่ละด้านลดลงหรือไม่?

ความจริงที่ค้นพบ: ตรงกันข้ามอย่างสิ้นเชิง!

การเรียนรู้พลวัตของเวลา (Video) และ
โครงสร้างเชิงปริมาตร (3D)
ช่วยเพิ่มประสิทธิภาพให้กับความสามารถ
พื้นฐาน 2D

ฟิสิกส์ของการมองเห็นเชื่อมโยงกัน ฐานข้อมูล
4D สร้างรากฐานที่ 'ฉลาดขึ้น' ไม่ใช่แค่ 'กว้างขึ้น'




ข้อพิสูจน์เชิงประจักษ์: ประสิทธิภาพระดับ State-of-the-Art

ความสามารถระดับสูงในทุกมิติ โดยยังคงความเข้าใจเชิงความหมายที่แม่นยำ รองรับตั้งแต่ Continuous Latents ความละเอียดสูง ไปจนถึง Discrete Tokens เพื่อการทำงานร่วมกับ AI ยุคใหม่



(2D Images)

2D Image: 0.21 rFID |
82.2% ImageNet Acc



(Time/Video)

Video: 3.01 rFVD |
40.2% MSRVTT Retrieval



(3D Depth)

3D Asset: 28.28 PSNR |
90.9% 3D Classification

รากฐานใหม่สำหรับ Multimodal AI แห่งอนาคต

ATOKEN ไม่ใช่แค่ Tokenizer
แต่คือโครงสร้างพื้นฐาน (Foundation)
ของระบบ AI ยุคต่อไป

เข้าใจทุกสิ่ง: ถอดรหัสความหมายของโลก
จากทุกมุมมอง

สร้างสรรค์ทุกมิติ: สร้างเคราะห์ภาพ วิดีโอ
และ 3D จากแกนกลางเดียวกัน

หมดยุคของการแยกส่วน (Fragmentation)
สู่ยุคทองของการหลอมรวมระบบ AI อย่าง
แท้จริง (The Grand Unification)

