


D-AR: สถาปัตยกรรมทางเลือกใหม่ ผสาน Diffusion สู่ Autoregressive แบบดั้งเดิม


เมื่อกระบวนการสร้างภาพถูกเปลี่ยนเป็นภาษาแบบ Next-Token Prediction



ไม่ต้องดัดแปลงสถาปัตยกรรม LLM พื้นฐานใดๆ

ภาษา (Autoregressive)


การมองเห็น (Diffusion)



1D Sequence

- โครงสร้าง 1 มิติ (1D Linear)
- ข้อมูลแบบไม่ต่อเนื่อง (Discrete)
- สร้างทีละคำ (Next-Token)




ปัญหาหลัก: ภาพไม่มีจุดเริ่มต้นและจุดจบแบบ 1 มิติเหมือนข้อความ การพยายามนำภาพไปใส่ใน LLM มักต้องจบลงด้วยการ ‘ดัดแปลง’ สถาปัตยกรรมโมเดลอย่างหลีกเลี่ยงไม่ได้



2D Spatial Grid

- โครงสร้าง 2 มิติ (2D Spatial)
- ข้อมูลแบบต่อเนื่อง (Continuous)
- สร้างแบบองค์รวม (Dense)


The Generative Paradigms Matrix

	Patch-level Diffusion (เช่น MAR)	Image-level Diffusion (เช่น DART)	D-AR (Ours)
การดัดแปลง สถาปัตยกรรม	✗ ต้องดัดแปลง AR 	✗ ต้องดัดแปลง AR 	✓ Vanilla AR (ไม่ต้องดัดแปลง) 
รูปแบบข้อมูล	Continuous	Continuous	Discrete Tokens 
วิธีการฝึกสอน	Diffusion Gradients	Diffusion Gradients	Σ Cross Entropy

จุดเด่นของ D-AR: นำผลลัพธ์แบบต่อเนื่องมาถอดรหัสเป็นลำดับ (Sequentially)
ทำให้สามารถใช้ความสามารถของ Vanilla AR ควบคู่กับ Diffusion Tokenizer ได้อย่างสมบูรณ์แบบ


แนวคิดพลิกวงการ: การแปลงภาพ 2 มิติให้เป็นมิติเดียวด้วย "แกนเวลา"

กระบวนการ Diffusion แบบ Coarse-to-fine




**ภาพไม่ใช่เส้นตรง แต่กระบวนการเปลี่ยนภาพจากเบลอไปชัด ‘เป็นเส้นตรงตามเวลา’
เราจึงใช้แกนเวลานี้เป็น 1D Sequence สำหรับโมเดล AR ได้โดยตรง**

สถาปัตยกรรม D-AR: สองโลกทำงานสอดคล้องประสานกัน




Deep Dive: เครื่องยนต์ Sequential Diffusion Tokenizer



กลุ่มโทเค็น (เช่น 8 กลุ่ม) จะถูกทยอยดึงมาใช้เป็น Condition ให้กับ Diffusion Decoder ที่ไล่ขึ้นตามตารางเวลา

ความงดงามของสถาปัตยกรรมแบบ 'Vanilla'



✓ ไม่มี Continuous I/O

ใช้ Discrete Tokens ปกติ ไม่ต้องปรับลอจิก Input/Output ของโมเดลภาษา

✓ ไม่มี Custom Attention Masks

ไม่ต้องสร้าง Mask ชับซ้อนเฉพาะทางสำหรับภาพ ใช้ Causal Mask ปกติ

✓ ไม่มี 2D Positional Embeddings


ใช้ 1D RoPE ตามโครงสร้างดั้งเดิมของ LLM ทุกประการ

✓ Standard Loss Function

ฝึกสอนโมเดลง่ายๆ ด้วย Cross Entropy Loss แบบดั้งเดิม


ผลลัพธ์: การเป็น Vanilla AR 100% หมายความว่าเราสามารถนำโมเดลนี้ไปสวมเข้ากับโครงสร้างพื้นฐานการฝึก (Training Loop) และระบบเสิร์ฟ (Serving) ของ LLM ในปัจจุบันได้ทันที

Magic Property #1: Streaming Previews



D-AR อาศัยทฤษฎี Jump-estimation ของ Diffusion เพื่อแสดงผล ‘ภาพร่าง’ (Preview) ออกมาได้ทันทีอย่างต่อเนื่อง แม้ว่าโมเดล AR จะเพิ่งทยอยสร้าง Token ออกมาได้เพียงบางส่วน โดยกระบวนการนี้ไม่สร้างภาระการคำนวณเพิ่มเติมใดๆ (Zero extra cost)

Magic Property #2: KV-Cache Friendly & Hardware Acceleration




Native Compatibility: เนื่องจากการทำงานยังคงสืบทอดประโยชน์ของการคาดเดาคำถัดไป (Next-token prediction) แบบ 1D อย่างเคร่งครัด สถาปัตยกรรมของตัวโมเดลจึงแยกไม่ออกระหว่างข้อความหรือภาพ

Inherited Optimizations: D-AR ได้รับมรดกทางซอฟต์แวร์เร่งความเร็วทั้งหมดของวงการ LLM กันที่ ไม่ว่าจะเป็นระบบจัดการหน่วยความจำเช่น KV-Cache (เช่น PagedAttention) หรือโมดูลเร่งความเร็วทางคณิตศาสตร์อื่นๆ

ไม่จำเป็นต้องเขียน Custom Kernel หรือสร้างระบบคิวแบบใหม่เฉพาะสำหรับ Vision Generation อีกต่อไป

Magic Property #3: Zero-Shot Layout Control



16 Prefix Tokens ถูกล็อก → ควบคุมโครงร่างและท่าทาง (Layout / Pose)

Tokens อีสระ → กำหนดสไตล์และพื้นผิวตาม Text Label

Label: Panda



Label: Golden Retriever




Label: Otter



ผลลัพธ์: เพียงแค่ล็อก Prefix Tokens ชุดเดียวกัน เราสามารถเปลี่ยนสายพันธุ์และสไตล์ของสัตว์ได้ในขณะที่ยังรักษาโครงสร้างและองค์ประกอบไว้ได้โดยไม่ต้องทำการฝึกสอนโมเดลใหม่เลย


Benchmark Performance: จ้าวแต่แจ่วบน Pareto Frontier



ข้อค้นพบสำคัญ:

- ทำสถิติ 2.09 FID บน ImageNet 256x256
- สามารถเอาชนะ LlamaGen รุ่น XXL (1.4B) ด้วยจำนวนพารามิเตอร์ที่น้อยกว่าเกือบครึ่งหนึ่ง
- พิสูจน์ให้เห็นว่าโครงสร้างพื้นฐานแบบ Vanilla AR ทรงพลังมากพอที่จะแข่งขันกับโมเดลแบบ Tailored AR ได้อย่างทัดเทียม

คุณภาพการสร้างสรรค์เชิงประจักษ์ (Uncurated Samples)



ตัวอย่างผลลัพธ์แบบสุ่ม (Uncurated) จากโมเดล D-AR-XL ที่ความละเอียด 256x256 แสดงให้เห็นถึงความหลากหลายของรายละเอียดพื้นผิว (Textures) และความเข้าใจทางเรขาคณิต (CFG = 4.0)

ร่องรอยการวาดภาพ: Generation Trajectories

$t \rightarrow 0$ (โครงสร้างหลัก)


$t \rightarrow 0.5$ (เริ่มเห็นสีและแสง)

$t \rightarrow 1$ (รายละเอียดสมบูรณ์)



ภาพร่างเหล่านี้ไม่ใช่ภาพ
ที่ถูกวาดแยกกัน แต่
เป็นผลพลอยได้ทาง
ธรรมชาติจากกลไก
'Sequential Decoding'
ทำให้โทเค็นส่วนแรกบังคับ
เค้าโครง (Coarse) และ
โทเค็นส่วนหลังทำหน้าที่
เติมรายละเอียด (Fine)

จิ๊กซอว์ชิ้นสุดท้ายสู่ Native Multimodal LLMs



— ๒๒ —

D-AR ไม่ใช่แค่เทคนิคการสร้างภาพใหม่ แต่เป็นเสมือน **'Rosetta Stone'** ที่ช่วยแปลภาษาการวาดภาพแบบ **2D Diffusion** ให้อยู่ในรูปแบบ **1D Sequence** ที่ LLM ดั้งเดิมเข้าใจ ปูทางสู่ Foundation Models ในอนาคตที่สามารถคิดเป็นข้อความและฝันเป็นภาพได้ภายในโครงข่ายประสาทตัวเดียว

Technical Summary & Resources



Vanilla AR Backbone

ทำลายข้อจำกัดเดิมด้วยการใช้
Next-token prediction
บนสถาปัตยกรรม AR ดั้งเดิม
โดยสมบูรณ์ ไม่ต้องปรับแต่ง
แต่งโครงสร้างโมเดลใดๆ



Time over Space

แก้ปัญหาค่าความไร้มิติเชิงเส้นของภาพ
ด้วยการจัดเรียง Token
ผ่านมิติเวลาของการทำ Diffusion
(Coarse-to-fine)



Emergent Properties

นำมาซึ่งคุณสมบัติพิเศษเหนือความ
คาดหมาย เช่น การสตรีมภาพล่อง
หน้า, การรองรับ KV-Cache
อย่างเป็นธรรมชาติ, และการควบคุม
โครงสร้างภาพแบบ Zero-shot



Arxiv Paper: <https://arxiv.org/abs/2505.23660>

GitHub Repository: <https://github.com/showlab/D-AR>