





SENSEMATH: AI มี สัญชาตญาณทางคณิตศาสตร์ หรือแค่คิดเลขเร็ว?

แกะรอยระบบความคิดและข้อจำกัดของ LLMs ภายใต้ภาพลวงตาของความแม่นยำ

ภาพลวงตาของความสำเเร็จ

GSM8K:



MATH:




LLMs ทำคะแนนสอบคณิตศาสตร์ได้เทียบเท่ามนุษย์

ความจริงภายใต้เปลือก



แต่โมเดลเหล่านี้ เข้าใจ โครงสร้างของตัวเลขจริงๆ
หรือเป็นเพียงแค่การใช้พลังประมวลผลมหาศาลเพื่อ
แก้โจทย์ตามขั้นตอนตายตัว?

สัญชาตญาณทางคณิตศาสตร์ คืออะไร?



สัญชาตญาณทางคณิตศาสตร์ ไม่ใช่การคิดเลขถูก แต่คือความยืดหยุ่นในการมองเห็นโครงสร้าง และเลือกใช้ ทางลัด ที่เหมาะสมที่สุดเพื่อลดภาระการคำนวณ

เครื่องมือวิจัย SENSEMATH



ชุดทดสอบ 4,800 ข้อ: ทดสอบการใช้เหตุผลเชิงโครงสร้าง






8 หมวดหมู่ทางคณิตศาสตร์: ครอบคลุมการประมาณค่าถึงการตัดตัวเลือก




การทดสอบความทนทาน (Digit Scales): เพิ่มจำนวนหลักตัวเลขเพื่อดูพฤติกรรม AI

8 หมวดหมู่ทางคณิตศาสตร์ (Shortcut Categories)

หมวดหมู่ (Category)	คำอธิบาย (Description)	ตัวอย่าง (Examples)
1. การประมาณค่า (Estimation)	การประมาณค่าโดยเร็ว	 $(40 * 50)$ ประมาณ 2000.  $(99 * 101)$ ประมาณ 10000.
2. การตัดตัวเลือก (Option Elimination)	การใช้เหตุผลเพื่อตัดคำตอบที่ผิดออก	 ถ้ามีตัวเลือก 1200, 1250, 1300, 2500.  ถ้าคำตอบคือประมาณ 1200 กว่าๆ, ตัด 2500 ออก
3. การกระจาย (Distribution)	การแยกตัวเลขเพื่อคำนวณง่ายขึ้น	 $(98 * 14) = (100 - 2) * 14 = 1400 - 28$ 
4. การจัดกลุ่ม (Grouping)	การจัดกลุ่มตัวเลขเพื่อคำนวณง่ายขึ้น	 $3 + 7 + 6 + 4 = (3 + 7) + (6 + 4) = 10 + 10$ 
5. การเปรียบเทียบ (Comparison)	การใช้การเปรียบเทียบกับค่าอ้างอิง	 $9/10 > 4/5$ (เพราะ $4/5 = 8/10$) 
6. ความสมมาตร (Symmetry)	การใช้ความสมมาตรเพื่อคำนวณ	 $(x-a)(x+a) = x^2 - a^2$ 
7. การทำให้เป็นศูนย์ (Making Zero)	การหาผลรวมที่เป็นศูนย์	 $(-5 + 8 + 5) = 8$ 
8. การทำให้เป็นหนึ่ง (Making One)	การหาผลคูณที่เป็นหนึ่ง	 $(2/3 * 3/2 * 4/5) = 4/5$ 

กลไกการดักจับ: The Matched Variant Trap



โครงสร้างโจทย์เหมือนกันทุกประการ เปลี่ยนแค่ตัวเลข
AI ไม่สามารถใช้การจำรูปแบบได้ แต่ต้องรู้ว่า เมื่อไหร่ ควรใช้ทางลัด


บันได 3 ขั้นสู่การรู้คิด

ขั้นที่ 3: การสร้างสรรค์ (Create) -
AI แต่งโจทย์ใหม่ที่ใช้ทางลัดได้หรือไม่?

ขั้นที่ 2: การวิเคราะห์ (Analyze) -
AI รู้หรือไม่ว่าสถานการณ์ไหนควรใช้ทางลัด?

ขั้นที่ 1: การใช้งาน (Apply) -
AI สามารถใช้ทางลัดได้หรือไม่?

Level 1: การใช้งานโดยสัญชาตญาณ (Spontaneous Use)




- อัตราการใช้ทางลัดต่ำกว่า 40% (ในสภาวะปกติ)
- เมื่อปล่อยให้คิดเอง LLMs แทนจะไม่ใช้ทางลัดเลย โมเดลเลือกใช้วิธีคำนวณแบบยัดเยียดและกินพลังงาน (Brute-force) แม้จะมีทางลัดที่สวยงามวางอยู่ตรงหน้า

Level 1: เมื่อถูกบังคับให้ใช้ทางลัด (Prompted Use)


การใช้ Prompt สั่งให้วิเคราะห์เชิงโครงสร้าง

โมเดลขนาดใหญ่ (GPT-4.1-mini, Qwen3-30B)



เมื่อถูกบังคับ โมเดลประสิทธิภาพสูงสามารถใช้ทางลัดได้ และความแม่นยำเพิ่มขึ้นอย่างก้าวกระโดด

โมเดลขนาดเล็ก (Llama 3.1 8B, Qwen3-8B)



โมเดลขนาดเล็กล้มเหลว ความแม่นยำลดลงอย่างหนักเมื่อถูกบังคับให้เปลี่ยนกระบวนการคิด

เมตริกซ์ประเมินขีดความสามารถ

	คิดทางลัดเองได้	บังคับแล้วดีขึ้น	รับมือตัวเลขขนาดใหญ่ได้
GPT-4.1-mini	✓	✓	✓
GPT-4o-mini	✓	✗	✓
Qwen3-30B	✓	✓	✗
Qwen3-8B	✗	✓	✗
Llama-3.1-8B	✗	✗	✗

มีเพียงโมเดลระดับท็อปเท่านั้นที่ได้ประโยชน์จากการคิดเชิงโครงสร้าง
โมเดลทั่วไปยังคงติดหล่มอยู่กับการคำนวณเชิงเส้น

Level 2: อคติแห่งการตอบรับ (The YES Bias)

100%


GPT-4o-mini
ตอบ YES
กับโจทย์หลอก
(Control Items)

AI ไม่สามารถประเมินได้ว่า ‘เมื่อไหร่ไม่ควรใช้ทางลัด’
พวกมันพยายามยึดเยียดรูปแบบทางลัดให้กับทุกโจทย์
ทำให้ความแม่นยำในโจทย์ธรรมดาลดลงถึง 12%
AI รู้จักวิธีใช้ทางลัด แต่ขาดวิจารณญาณ




Level 3: ภาพลวงตาของโครงสร้าง

เมื่อสั่งให้ AI แต่งโจทย์
คณิตศาสตร์ที่มีทางลัดซ่อนอยู่
AI สามารถเลียนแบบ
รูปแบบภายนอก
ได้อย่างแม่นยำ
แต่ล้มเหลวอย่างสิ้นเชิงในการวาง
ข้อจำกัดทางคณิตศาสตร์
ที่ทำให้ทางลัดนั้นใช้งานได้จริง




Pass Rate:
ต่ำเพียง 2-24%

จุดคอขวดของความล้มเหลว



AI เข้าใจว่าโจทย์หน้าตาเป็นอย่างไร
แต่ไม่เข้าใจว่า ทำไม ทางลัดถึงทำงานได้

บทสรุป: ความคล่องแคล่ว ไม่เท่ากับ ความเข้าใจ



ความสามารถในการรันสคริปต์คำนวณได้อย่างไร้ที่ติ ไม่ได้แปลว่า AI มีสัญชาตญาณทางตัวเลข
ทักษะเชิงประจักษ์ของโมเดลปัจจุบันยังเป็นเพียงการเลียนแบบกระบวนการที่ปราศจากรากฐานทางโครงสร้าง

ผลกระทบต่อวงการ EdTech



การสอนต้องการมากกว่าการคำนวณ:
ตัวเตอร AI ที่ดีต้องสามารถบอกเด็กได้ว่า ทำไม
วิธีนี้ถึงเหมาะสม และวิธีไหนไม่ควรใช้

อันตรายจากการตอบ YES เสมอ:
การที่ AI ไร้วิจารณญาณในการเลือกใช้ทฤษฎี
อาจนำไปสู่การสอนแนวคิดที่ผิดพลาดให้กับนักเรียน

ข้อควรระวัง: การนำ LLMs มาเป็นตัวเตอร
คณิตศาสตร์อัตโนมัติเต็มรูปแบบในปัจจุบัน
ยังมีความเสี่ยงสูงมาก

3 ข้อเท็จจริงที่ต้องตระหนัก



คะแนน Benchmark ลงตา
การตอบถูกไม่ได้แปลว่ามีวิธีคิด
ที่ถูกต้องหรือมีตรรกะที่สมบูรณ์
เสมอไป

สัญชาตญาณต้องถูกกระตุ้น
Number Sense ใน AI จะไม่
ทำงานเองหากปราศจาก Prompt
ที่บังคับโครงสร้างอย่างจงใจ

พรมแดนที่ยังไปไม่ถึง
การประเมินสถานการณ์ (Analyze)
และการสร้างสรรค์โจทย์ (Create)
ยังคงเป็นช่องโหว่ทางปัญญา
ขนาดใหญ่