


ถอดรหัสกลไกเมื่อ AI ถูกออกแบบให้คิดวนซ้ำ


สถาปัตยกรรมภายในและปรากฏการณ์วงโคจรของ Looped Reasoning Language Models




การเปลี่ยนผ่านจากเส้นตรงสู่วงโคจร

แทนที่จะเพิ่มจำนวน Layer เพื่อให้ AI ฉลาดขึ้น สถาปัตยกรรม Looped Language Models นำ Layer เดิมมาซ้ำ (Recurrence in depth) เพื่อขยายความสามารถในการให้เหตุผล (Reasoning) ตามโจทย์ที่ซับซ้อน ณ เวลา Test-Time

Standard Transformers (Scale = พารามิเตอร์มหาศาล)





Looped Transformers (Scale = Test-Time Compute)




แบบฝึกบ็อกซ์ของสมองที่คิดวนซ้ำ: เกิดอะไรขึ้นใน Latent Space?

เมื่อไม่นานมานี้พบว่าการคิดวนซ้ำเพิ่มขีดความสามารถได้
คำถามสำคัญระดับกลไกคือ เมื่อข้อมูลชุดเดิมไหลผ่าน Weight
ชุดเดิมซ้ำแล้วซ้ำเล่า สภาวะแฝง (Latent States) ภายในจะ
พังทลายเป็นความโกลาหล หรือสามารถจัดระเบียบตัวเองได้?

⚠ สมมติฐาน A: สัญญาณรบกวนจนเกิด Chaos



✅ สมมติฐาน B: หาจุดสมดุลใหม่



จุดตรึงแบบวนรอบ (Cyclic Fixed Point): บทสรุปของวงโคจร

1

ผลลัพธ์จากการลดมิติ (PCA) ของ Latent States แสดงให้เห็นชัดเจนว่า Output จาก Recurrent block ไม่ได้แกว่งแบบสุ่ม แต่มีแนวโน้มพุ่งเป้าไปสู่เส้นทางที่คงที่ใน Latent Space


2

เมื่อโมเดลเข้าใกล้จุด Fixed Point การพยากรณ์จะเสถียรขึ้น โมเดลหยุดค้นหาและเริ่มปรับแต่งคำตอบให้แม่นยำ

Cyclic Fixed Point
(จุดตรึงแบบวนรอบ)

Early Loop
(เริ่มวนซ้ำ)

Late Loop
(ปรับแต่งข้อมูล)



พฤติกรรม Attention ที่เสถียรสร้างรูปแบบการคิดที่คาดเดาได้

Mechanism Explanation


เมื่อค่า Latent States เสถียรขึ้น รูปแบบความสนใจ (Attention Patterns) ของแต่ละ Layer จะเริ่มมีพฤติกรรมคงที่ในทุกๆ รอบการวนซ้ำ (Recurrences)

Evidence

แผนผัง Frobenius Norm แสดงให้เห็นเส้นทแยงมุมที่ชัดเจน ซึ่งพิสูจน์ว่า Attention Matrix ของ Layer เดิมในรอบที่ต่างกัน มีความคล้ายคลึงกันอย่างสมบูรณ์




$$S_\ell(X_{\ell,t}) \approx S_\ell(X_{\ell,t-1})$$




ลำดับชั้นการให้เหตุผล (Stages of Inference) ที่ถูกบีบอัดและวนซ้ำ

โมเดล Feedforward ปกติจะมี ลำดับการคิด (Stages of Inference) ที่ชัดเจนจากต้นน้ำสู่ปลายน้ำ สิ่งที่น่าสนใจคือ โมเดล Looped สามารถสะท้อน ลำดับชั้นเหล่านี้ได้อย่างสมบูรณ์แบบ โดยบีบอัดมันไว้ในวงรูปเดียว และประมวลผลกระบวนการ (A→B→C) ซ้ำๆ ในทุกรอบ





ปรากฏการณ์ Self-Organization: สัญชาตญาณของการสร้างภาษา

- **The Discovery:**
ลำดับชั้นการคิดเหล่านี้ไม่ได้เกิดจากการบังคับด้วย Loss Function พิเศษ แต่เป็นโครงสร้างที่โมเดลจัดระเบียบตัวเอง (Self-Organize) ขึ้นมาจากการเทรนตั้งแต่เริ่มต้น (Train from scratch)
- **Conclusion:**
โครงสร้างการผสมข้อมูล (Mixing Stages) แบบนี้คือสถานะที่เหมาะสมที่สุด (Optimal) สำหรับการทำความเข้าใจและสร้างภาษา



ทางแยกของสถาปัตยกรรม: ไม่ใช่ทุกโมเดลที่จะถึงจุดเสถียรภาพ

- The Reality Check: แม้ธรรมชาติของโมเดลพยายามจะวิ่งเข้าหาความเสถียร แต่โมเดลอย่าง Ouro กลับลี้มเหลวในการหา Fixed Point และแกว่งตัวเป็นวงโคจรที่ไม่รู้จบ (Orbits)
- The Question: ปัจจัยเชิงสถาปัตยกรรม (Architectural Choices) ไດก่อนการเทรนที่เป็นตัวกำหนดความเป็นหรือตายของความเสถียรนี้?



ถอดรหัส DNA สถาปัตยกรรม: Matrix การเปรียบเทียบ

Key Takeaway: ความแตกต่างเพียงเล็กน้อยในการจัดวาง Normalization และ Input Injection คือกุญแจที่กำหนดพฤติกรรมของ Latent Space ทั้งหมด

สถาปัตยกรรม (Model)	โครงสร้าง Norm	การฉีดข้อมูล (Input Injection)	บัสสุ Fixed Point?	การทำงานเมื่อเร่ง Loop (Extrapolation)
Retrofitted Llama	Pre-norm	มี (Yes)	บัสสุ (Stable)	รักษาลำดับขั้นได้ (Maintained)
Huginn-0125	Sandwich (Residual)	มี (Yes)	บัสสุ (Stable)	ลำดับขั้นพังทลาย (No clear stages)
Ouro 1.4B	Sandwich (Attn/MLP)	ไม่มี (No)	ไม่บัสสุ (Chaotic)	ประสิทธิภาพตกลง (Diverges)

CORRELATION: INPUT INJECTION & STABILITY

CORRELATION: NORM STRUCTURE & EXTRAPOLATION


สูตรลับประการที่ 1: Input Injection คือ สมอเรือ

The Mechanism:


การทำงานที่ไร้จุดอ้างอิงจะทำให้สภาวะ
แผ่ลอยกว้างและสะสม Error แต่
Input Injection ทำหน้าที่ส่งข้อมูล
ตั้งต้นเข้าสู่กระบวนการใหม่ทุกรอบวง

The Result:


มันทำหน้าที่เป็น **สมอเชิงโครงสร้าง**
(Structural Anchor) ที่บังคับให้
Recurrent Layer ลู่เข้าหาจุดตรึง
อย่างแม่นยำในทุกสภาพแวดล้อม



No Injection



Input Injection





ปัญหาของ Norm: ทำไม Huginn ถึงไร้ลำดับชั้นการคิด?

The Error in Design:


Huginn-0125 เลือกใช้ Sandwich Norm โดยทำการ Normalize *Residual Stream* ซ้ำๆ ในทุกรอบวง

The Consequence:

การกดทับนี้ป้องกันไม่ให้ Activation Magnitude เติบโต ซึ่งการเติบโตนี้คือกลไกทางฟิสิกส์ประสาท (Neural physics) ที่จำเป็นอย่างยิ่งอย่างยวดในการบีบอัดข้อมูล และสร้างลำดับชั้นการให้เหตุผลอย่างสมบูรณ์แบบ



Huginn: Repeated Residual Normalization



Ouro/Llama: Permitted Growth (Attention Sinks)

ทดสอบขีดจำกัด: เมื่อเร่ง Test-Time Compute เกินขอบเขตเทรนนิ่ง


The Ultimate Test:

โมเดลที่มีโครงสร้าง Fixed Point ที่เสถียร จะสามารถรักษาลำดับขั้นการให้เหตุผล (Inference Stages) ไว้ได้แม่นยำแม้จะถูกสั่งให้คิดวนซ้ำเป็นร้อยรอบ


The Risk:

สถาปัตยกรรมที่ไม่เสถียร เมื่อเจอการขยาย Compute เกินกว่าจุดที่เทรนมา สภาพแวดล้อมภายในจะพังทลาย นำไปสู่การประมวลผลที่ผิดพลาด

Stable Extrapolation (Retrofitted Llama)



Unstable Divergence (Ouro)



พิมพ์เขียวสำหรับวิศวกร: Best Practices ในการออกแบบ Looped LLM



DATA: 120304
DATA: 123
MAC87: 28.2975
H5839: 304%
DE50: 10K:26.9
DATA: 0.267

ANCHOR
POINT

Rule 1: ใช้ Input Injection เสมอ เพื่อรับประกันการลู่เข้าสู่จุดตรึง (Fixed Point Convergence) และป้องกัน Latent Drift

Early loop Mid loop Late loop




DATA: 100335
DATA: 199
MEAN7: 20.0873
RBNUS: 57.28
RGS87: 36.1028
DATA: 0.485

TARGET:
ATTN/MLP OUT


Rule 2: วาง Normalization ไว้ที่ Output ของ Attention/MLP เท่านั้น ห้าม Normalize ตัว Residual Stream หลัก เพื่อเปิดทางให้ระบบสร้างลำดับขั้นการบีบอัดข้อมูล

Early loop Mid loop Late loop



Rule 3: ความเสถียรของ Fixed-Point คือเครื่องการันตีเรียกว่า โมเดลจะสามารถ Scale ความฉลาดผ่าน Test-Time Compute ได้อย่างปลอดภัยโดยไม่พังทลาย

จาก การลองผิดลองถูก สู่วิศวกรรมที่คาดเดาได้



Conclusion:	The Horizon:
การทำความเข้าใจกลไกเชิงลึก (Mechanistic Analysis) ของ Looped Language Models พิสูจน์ให้เห็นว่ากระบวนการให้เหตุผลของ AI ไม่ใช่เวทมนตร์ แต่เป็นฟิสิกส์ของโครงสร้างที่จัดการได้	การออกแบบสถาปัตยกรรมตามหลักฟิสิกส์นี้ คือก้าวต่อไปที่จะปลดล็อก AI ที่มีความสามารถในการใช้ Test-Time Compute เพื่อแก้ปัญหาขั้นสูงได้อย่างมีประสิทธิภาพ ไร้ขีดจำกัด และปลอดภัยอย่างแท้จริง