



DeepEyes: วิวัฒนาการของการใช้เหตุผลแบบ Multimodal

ก้าวข้ามขีดจำกัดของ Vision-Language Models
ด้วยการ ‘คิดเป็นภาพ’ ผ่าน Reinforcement Learning

The Physical View

CURRENT VLM: PASSIVE PERCEPTION



The AI's Mind

INTERNAL REASONING (TEXT-ONLY)

[illegible]

คอขวดของ VLM ในปัจจุบัน: ข้อจำกัดของการ ‘มอง’ เพียงฉับใจเดียว



Passive Perception:

มองภาพรวมเพียงครั้งเดียว
แล้วแปลงเป็น Text เพื่อหาคำตอบ
(Text-based Reasoning)



The Resolution Trap:

พลาดรายละเอียดที่เล็ก ซบซ้อน
หรืออยู่ในภาพที่มีความละเอียดสูง



The Hallucination Effect:

เมื่อมองไม่ชัด โมเดลจะเลือก
โมเดลจะเลือก 'เดา' จากบริบท
แทนที่จะหาหลักฐานความจริง

Paradigm Shift: สู่วิธีการรับรู้แบบตื่นตัว (Active Perception)

	Standard VLMs	Workflow-based VLMs	DeepEyes (iMCoT)
Perception Type	Passive (มองภาพรวมครั้งเดียว)	Rigid (ทำตามขั้นตอนโปรแกรมตายตัว)	Active & Autonomous (สำรวจและซูมภาพแบบ End-to-End)
Flexibility	ต่ำ (เดาเมื่อมองไม่ชัด)	ปานกลาง (ยึดติดกับโมดูลภายนอก)	สูง (ปรับเปลี่ยนอัตโนมัติตามความยาก)
Training Data Needed	Question-Answer Pairs	Cold-start SFT Data (สร้างยาก/แพง)	QA Pairs + Reinforcement Learning


iMCoT: การผสานภาพและตัวอักษรเป็นหนึ่งเดียว

Interleaved Multimodal Chain-of-Thought (iMCoT) คือการให้ AI คิดสลับไปมาระหว่าง 'การวิเคราะห์ด้วยข้อความ' และ 'การลงมือชมเพื่อหาหลักฐาน'



กลไกการทำงาน: iMCoT Loop

Integration
นำภาพย่อกลับเข้า
Context เพื่อใช้
เหตุผลในรอบถัดไป



Incentivizing the AI: โครงสร้างรางวัลแบบมีเงื่อนไข


$$R_{\text{total}} = R_{\text{acc}} + R_{\text{format}} + I \cdot R_{\text{tool}}$$

MISSION COMPLETE SCORECARD

	R_acc (Accuracy Reward) + คะแนน (ตอบคำถามถูกต้องตรงประเด็น)	+ 100 pts
	R_format (Format Reward) - หักคะแนน (หากตอบผิดรูปแบบที่กำหนด)	- 20 pts
	I · R_tool (Conditional Tool Bonus) + โบนัสพิเศษ (ให้คะแนนก็ต่อเมื่อตอบถูก และ มีการใช้เครื่องมือ Zoom-in อย่างมีประสิทธิภาพ)	+ 50 pts 

Why the condition matters? หากให้โบนัสการใช้ Tool ใดๆ AI จะซูมรูปภาพรัวๆ เพื่อโกงคะแนน เงื่อนไขนี้บังคับให้ AI ใช้ Tool ‘เพื่อแก้ปัญหาให้สำเร็จเท่านั้น’

สร้างสภาพแวดล้อมเพื่อ กระตุ้นการใช้ Tool



- 1. Managing Difficulties
- 2. Ensuring Verifiability
- 3. Tool Integration Filtering

Stream 1

Fine-Grained Data (47%)

ภาพความละเอียดสูงที่ต้องค้นหา
รายละเอียดเล็กๆ เพื่อกระตุ้น
Visual Search

Stream 2

Chart Data (30%)

กราฟและแผนภูมิที่ซับซ้อน เพื่อ
ฝึกการหาความสัมพันธ์เชิงพื้นที่
(Spatial Relationship)

Stream 3

Reason Data (23%)

ข้อมูลเชิงตรรกะและคณิต
ศาสตร์ เพื่อรักษาสมดุลทักษะ
การคิดวิเคราะห์



HUD Note: ข้อมูลทุกชิ้นต้องผ่านคิกรองว่า
“การชุมภาพมีผลเปลี่ยนจากการตอบผิด
เป็นตอบถูกได้จริง”

The Evolution of Mastery: จากผู้ใช้มือใหม่สู่ปรมาจารย์

Stage 1: Exploration (การสำรวจ)

- Tool Calls เพิ่มขึ้น | Response ยาว
- Grounding IoU ต่ำ

“ฉันลองชมดูทุกที่และอธิบายยืดยาว
แต่ยังไม่เข้าใจว่ากำลังมองหาอะไร...”

Stage 2: High-Frequency (การใช้ที่จัด)

- Tool Calls ทะลุเพดาน
- Response ยาวที่สุด
- IoU เริ่มสูงขึ้น

“ฉันสแกนภาพแบบปูพรม ชมรัวๆ
เพื่อเก็บข้อมูลให้มากที่สุด
แม้จะเปลืองแรง...”

Stage 3: Exploitation (การใช้อย่างแม่นยำ)

- Tool Calls เข้าสู่จุดสมดุล
- Response สั้นกระชับ
- IoU และ Accuracy สูงสุด

“ฉันรู้แล้วว่าต้องมองที่ไหน
ชมเฉพาะจุดสำคัญ ยืนยันข้อมูล
แล้วสรุปคำตอบอย่างเฉียบขาด”

Cognitive Patterns: การคิดวิเคราะห์แบบมนุษย์ (1/2)

Pattern 1: Visual Search (การค้นหาด้วยสายตา)





AI Monologue (Observation Blue italics):

“มองไม่เห็นนาฬิกา... ขอซูมไปที่ชั้นหนังสือ”

Verdict: “ซูมหาจุดที่น่าจะเป็นเป้าหมายในภาพกว้าง
เมื่อเจอรายละเอียดขนาดเล็กจึงสามารถตอบได้อย่างมั่นใจ”

Pattern 2: Visual Comparison (การเปรียบเทียบเชิงลึก)




AI Monologue (Observation Blue italics):

“ขอซูมดูกราฟทีละภาพเพื่อดูความกว้างและเปรียบเทียบเส้นประ”

Verdict: “โมเดลสแกนและเปรียบเทียบข้อมูลความละเอียดสูง
จากหลายตำแหน่ง เพื่อหาข้อสรุปที่แม่นยำที่สุด”

Cognitive Patterns: การคิดวิเคราะห์แบบมนุษย์ (2/2)

Pattern 3: Visual Confirmation (การยืนยันข้อสงสัย)



AI Monologue (Observation Blue italics):


“ดูเหมือนจะเป็นหน้าต่างสีเหลี่ยม แต่ขอซูมเพื่อยืนยันรูปทรงให้ชัดเจน”

Verdict: “เมื่อไม่แน่ใจ AI จะไม่เดา แต่จะสร้างพิกัดเพื่อเรียกซูมตรวจสอบซ้ำจนกว่าจะมั่นใจ”



Uncertainty Resolution (กำจัดความคลุมเครือ)

Pattern 4: Hallucination Mitigation (การลดอาการหลอน)



AI Monologue (Observation Blue italics):

“ตอนแรกคิดว่าเสื้อสีดำ แต่เมื่อซูมดูชัดๆ พบว่าเป็นกางเกงสีดำและเสื้อสีแดง”


Verdict: “การดึงภาพย่อยกลับมา ช่วยดึงสติ AI ให้ยึดติดกับความจริงเชิงประจักษ์ แทนที่จะปล่อยให้ภาษาพาดำเนินเรื่องจนหลอน”



Factual Grounding (ความแม่นยำของคำอธิบาย)

Performance Impact: ผลลัพธ์จากการเรียนรู้

High-Resolution Dominance (V* Bench)



Outperforming Heavyweights:
ประสิทธิภาพแซงหน้าโมเดลคู่แข่งที่ใช้
Workflow สำเร็จรูป

Holistic Improvement:
เพิ่มคะแนนในหมวด Visual Grounding
และ Math Problem Solving

พารามิเตอร์น้อยกว่า แต่ฉลาดกว่า
ด้วยสัญชาตญาณการใช้เครื่องมือ

The Future is Active Perception



No Manual Workflows

ก้าวข้ามข้อจำกัดของการเขียน Pipeline
ยุ่งยาก ด้วยพลังของ End-to-End
Reinforcement Learning

Native Emergence

ความสามารถในการ “คิดเป็นภาพ”
เกิดขึ้นเองตามธรรมชาติ เมื่อกำหนด
โครงสร้าง Reward อย่างถูกต้อง

True Multimodal Reasoning

ผสาน Visual และ Textual ไร้รอยต่อ
สู่ AI ที่ตรวจสอบ เปรียบเทียบ
และตั้งข้อสงสัยได้ใกล้เคียงมนุษย์

**DeepEyes ได้พิสูจน์แล้วว่า AI ที่ทรงพลังที่สุด ไม่ใช่ AI ที่มองเห็นได้กว้างที่สุด...
แต่คือ AI ที่รู้ว่า "เมื่อไหร่ควรเพ่งมอง"**