



RASTER SCAN



CAUSAL FLOW




DeepSeek-OCR 2: วิวัฒนาการสู่ Visual Causal Flow

Fixed Sequential Processing.
Non-adaptive.

เปลี่ยนจากการสแกนแบบคงที่
สู่การอ่านด้วยตรรกะเหตุและผล

Logic-Driven Connection.
Context-Adaptive.



ช่องว่างระหว่าง ‘การมองเห็นของมนุษย์’ และ ‘เครื่องจักร’



scan_path: logical

Causal (มีเหตุผล):

สายตามนุษย์เคลื่อนที่ตามความเข้าใจเชิงตรรกะ



scan_path: raster

Rigid (แข็งทื่อ): โมเดลทั่วไปสแกนแบบ Raster (Top-left to Bottom-right) โดยไม่สนใจบริบท


การบังคับให้ภาพ 2D กลายเป็นลำดับ 1D แบบตายตัว ทำให้สูญเสียความหมายของโครงสร้างเอกสาร

ความท้าทายของเอกสารที่มีความซับซ้อน

FORMULA

$$\begin{aligned} \int_0^1 f(x)^2 dx &= \frac{1}{2} \frac{\partial^2 \pi(1-1)}{\partial_{\frac{1}{2}}^2 \pi(1-1)} dx \\ &= \frac{1}{2} \sum_{k=1}^{\infty} \frac{1}{(n + \sqrt{2n + \sqrt{l}})} \\ &= \frac{1}{2} \sum_{k=1}^{\infty} \frac{34.7 \pi(\sqrt{3} - 1)^2 n}{2k} \\ &= \frac{1}{2} \sum_{i=1}^{\infty} \left(1 + \sqrt{\frac{17}{2}} \right) \end{aligned}$$

MULTI-COLUMN

[illegible]

Excer poun doler sht smet, coonse-
bort selphing oft, wretter coosed
meit bediffence onloo megen nistm.
rtilest of lileetwrettesegne, diti

Stöðunn útsætt af öðru, compositæ soð
trætt en óvættar þáð ómættuðus
lættuðuðuðuð. Þóttu af öðru lóttuðuð.

[illegible][illegible]

Tarece poam dulce sit omat, coaceste
răsună câmpieșeg ești, dinorin omimod
ferme înădădoctă hătece magne ești.
Intrăm înădădoctă de lăuntru mureș, dă

MERGED CELLS

SCAN FAIL

[illegible]

SCAN FAIL

Non-Linear Layouts:


เอกสารจริงไม่ได้เรียง บรรทัดเสมอไป (Forms, Tables, Charts)

The Failure Mode:

การระบุตำแหน่งแบบเดิม (Positional Encoding)

ไม่สามารถจับความสัมพันธ์
เชิงพื้นที่ที่ซับซ้อนได้


ขอแนะนำ DeepSeek-OCR 2 และ DeepEncoder V2



1. The Shift: เปลี่ยน Vision Encoder จาก CLIP (Static) เป็น Language Model (Dynamic)


2. The Result: โมเดลสามารถ 'คิด' และ 'จัดลำดับ' ข้อมูลภาพก่อนที่จะส่งไปประมวลผล

ภาพรวมสถาปัตยกรรม (Architecture Overview)




การทำงานร่วมกันของ ‘ผู้อ่าน’ (Encoder) และ ‘ผู้เขียน’ (Decoder) ที่มีความเป็นเหตุเป็นผล (Causal) ทั้งคู่

DeepEncoder V2: เมื่อ Encoder มีสมองเป็นของตัวเอง



- **Base Model:** Qwen2-0.5B (ขนาด 500M Parameters เทียบเท่า CLIP แต่ฉลาดกว่า)
- **Mechanism:** ใช้ learnable queries ในการจัดลำดับ Visual Tokens ใหม่ตามความสำคัญ


Vision Tokenizer: การย่อขยายข้อมูลอย่างมีประสิทธิภาพ



- **Structure:** SAM-base (80M params) + 2 Convolutional Layers
- **Compression:** ลดจำนวน Token ลง 16 เท่า (Factor of 16)
- **Dimension:** ลดจาก 1024 เหลือ 896 เพื่อความเข้ากันได้กับ Pipeline


Takeaway: รักษาข้อมูลสำคัญไว้ครบถ้วนในขนาดที่เล็กลง เพื่อความเร็วในการประมวลผล

Causal Flow Queries: การกำหนดลำดับการมองเห็น



Attention Mask: การมองเห็นสองแบบในเวลาเดียว

Bidirectional: Visual Tokens
เห็นภาพรวมทั้งหมดพร้อมกัน




Causal: Queries มองเห็น
เฉพาะสิ่งที่เกิดขึ้นก่อนหน้า

Equation 1: Specific Mask Structure

ผสมผสาน 'การเห็นภาพรวม' (Global) เข้ากับ 'การอ่านตามลำดับ' (Sequential) อย่างลงตัว

กลยุทธ์การฝึกฝน 3 ขั้นตอน (3-Stage Training Pipeline)




ฝึกให้ Encoder เข้าใจความสัมพันธ์ของภาพและภาษา (Image-Text Alignment)

แช่แข็ง Tokenizer, ฝึก Encoder และ Decoder ให้จัดลำดับข้อมูลเก่งขึ้น

แช่แข็ง Encoder, ฝึกเฉพาะ LLM เพื่อความแม่นยำในการสร้างข้อความสูงสุด

ผลลัพธ์การทดสอบบน OmniDocBench v1.5

Model Performance



Using 1120 Visual Tokens

ชนะคู่แข่งที่ใช้ Token เยอะกว่า
ด้วยสถาปัตยกรรมที่ฉลาดกว่า


การเข้าใจ ‘ลำดับการอ่าน’ (Reading Order Mastery)

R-order Edit Distance

DeepSeek-OCR: 0.085



DeepSeek-OCR 2: 0.057



Logical Flow

การลดลงของ Edit Distance ยืนยันว่า DeepEncoder V2 สามารถเรียงลำดับข้อความตามตรรกะได้ดีขึ้นจริง ไม่ใช่แค่สแกนตามบรรทัด

ประสิทธิภาพระดับ Production (Practical Readiness)

Token Budget

Sarabun, Deep Slate

256 - 1120
tokens

JetBrains Mono, Deep Slate
Low Cost

Repetition Rate (Online Logs)

Sarabun

4.17% ↓ 6.25%


Repetition Rate (PDFs)

Sarabun


2.88% ↓ 3.69%

ลดปัญหาการผลิตซ้ำ (Hallucination/Repetition)
และประหยัดทรัพยากรในการรันจริง

อนาคต: มุ่งสู่ Genuine 2D Reasoning และ Native Multimodality



การใช้ 1D Causal Model สองตัวต่อกัน (Encoder + Decoder) ช่วยให้เข้าใจโครงสร้าง 2D ได้ลึกซึ้งขึ้น




บทสรุป (Key Takeaways)



DeepEncoder V2

การใช้ LLM เป็นดวงตา
ช่วยให้เห็นความสัมพันธ์เชิงเหตุผล



Causal Visual Flow

เปลี่ยนการสแกนพิกเซล
เป็นการอ่านด้วยความเข้าใจ



Efficiency

ประสิทธิภาพสูงขึ้น
แต่ใช้ทรัพยากร (Tokens) น้อยลง

ก้าวสำคัญสู่ปัญญาประดิษฐ์ที่ ‘อ่าน’ ได้เหมือนมนุษย์อย่างแท้จริง