




The Resolving Canvas

Technical Explainer & Architecture Teardown

DiffusionGemma: การก้าวกระโดดสู่ยุค Text Diffusion


โมเดล 26B MoE จาก Google ที่เปลี่ยน
กระบวนการสร้างข้อความทีละ
โทเค็น สู่การประมวลผลแบบขนาน
(Parallel Generation)

ปัญหาคอขวด ของการประมวลผล




โครงสร้างแบบ Sequential

โมเดลภาษาแบบ
Autoregressive
สร้างทีละโทเค็นจากซ้ายไป
ขวา ต้องพินิจสิ่งที่สร้าง
มาก่อนหน้าเสมอ




Memory Bandwidth คือตัวถ่วง

ในการรันบน Local GPU
ปัญหาไม่ใช่พลังประมวลผล
แต่เป็นการดึงน้ำหนักโมเดล
จากหน่วยความจำซ้ำๆ ทำให้
Tensor Cores ต้องอยู่ใน
สถานะรอ (Idle)




จาก Sequential สู่ Parallel: ความต่างของระบบทศน์

Autoregressive



วางทีละบล็อก (Token-by-Token)
ประมวลผลเป็นเส้นตรงแบบทางเดียว

Diffusion



สร้างทีละบล็อกพร้อมกัน (Parallel)
ปรับแก้โทเค็นทั้งหมดไปพร้อมๆ กันบนผ้าใบ

ประสิทธิภาพ

สร้างข้อความได้เร็วกว่าสูงสุด 4 เท่า
(Up to 4x Faster) บน Dedicated GPU


สถาปัตยกรรมระดับ 26B บนพื้นฐาน Gemma 4

Parameters

26B MoE (Mixture of Experts) / ใช้งานจริงเพียง 3.8B Active Parameters ต่อรอบ

Context Window

รองรับบริบทความยาว
256K Tokens
และสนับสนุนกว่า 140+ ภาษา








Inputs & Outputs

Multimodal Input
(ข้อความ, รูปภาพ, วิดีโอ)
แปลงสู่ผลลัพธ์เป็นข้อความ

Open Weights

Apache 2.0
(พร้อมสำหรับการนำไป
พัฒนาต่ออย่างอิสระ)

Uniform State Diffusion ทำงานอย่างไร?



1. The Noise Canvas

โมเดลเริ่มต้นด้วยผ้าใบที่เต็มไปด้วย
โทเค็นแบบสุ่มความยาว 256 โทเค็น


2. Iterative Refinement

กวาดสายตามนผ้าใบ ล็อกโทเค็นที่มี
ความมั่นใจสูง ยืนยันเฉลี่ย 15-20
โทเค็น ต่อหนึ่ง Forward Pass


3. Convergence

ข้อความทั้งหมดจะถูกปรับแต่งจน
สมบูรณ์ชัดเจนในรูปแบบ Parallel

พลังพิเศษ: การแก้ไขตัวเองแบบ Real-time (Self-Correction)



ตรวจพบความมั่นใจต่ำ (Low Confidence)



Re-noising (ทำลายเพื่อสร้างใหม่)




แก้ไขและเลือกโทเค็นใหม่ให้ถูกต้อง

Bidirectional Attention

ทุกโทเค็นสามารถสังเกตโทเค็นอื่นๆ
ได้ทุกทิศทาง ระบบจึงสามารถย้อนกลับ
ไปแก้ไขสิ่งที่ผิดพลาดได้ ซึ่งโมเดล
แบบเก่า (Autoregressive) ทำไม่ได้
เพราะโทเค็นถูกสร้างแล้วจะตายตัวทันที

Block Autoregressive Diffusion

การจัดการข้อความยาวที่เกินขนาดผ้าใบ (Long Context)



Step 1:

เมื่อผ้าใบขนาด 256 โทเค็น
แรกถูกสร้างจนสมบูรณ์


Step 2:

ข้อมูลบริบททั้งหมดจะถูกจัด
เก็บลงใน KV Cache


Step 3:

สร้างแผ่นใหม่โดยอ้างอิงประวัติจากบล็อกก่อนหน้า
ผสานความเร็วแบบ Parallel และความเสถียรแบบลำดับขั้น

ย้ายคอขวดจาก Memory สู่ Compute



Full Tensor Core Utilization



Hardware Insight: การประมวลผลผ้าใบ 256 โทเค็นพร้อมกัน เป็นการป้อนปริมาณงานให้ Tensor Cores ทำงานเต็มประสิทธิภาพ 100%

Accessibility: สามารถรันได้ภายในหน่วยความจำ 18GB VRAM (ผ่านการ Quantize แบบ NVFP4)

ตัดสินใจเลือก: DiffusionGemma vs. Standard Gemma 4

คุณสมบัติ	DiffusionGemma (26B)	Standard Gemma 4
วิธีสร้าง (Generation)	Parallel Diffusion	Autoregressive
ข้อจำกัดฮาร์ดแวร์	Compute-bound	Memory-bandwidth
ประเภท Attention	Bidirectional (สองทิศทาง)	Causal (ย้อนหลังเท่านั้น)
การแก้ไขตัวเอง	มี (ผ่าน Re-noising)	ไม่มี (Commit ตายตัว)
ความเร็วบน GPU	เร็วกว่าสูงสุด 4x	Baseline มาตรฐาน
รูปแบบงานที่เหมาะสม	Local, ตอบสนองไวแบบโต้ตอบ	High-QPS Cloud Serving

ข้อได้เปรียบในงานที่มีข้อจำกัดซับซ้อน (Constrained Generation)


Autoregressive
(ความแม่นยำ 0%)
- ตัดสินใจพลาดแล้วแก้ไม่ได้

	2	1	1	9	3	4	7	
7	3	6	6	4	9	2		5
4	7	5	2	1	6		9	1
5	1	2	3	6		7	8	6
7	8	1	4		8	4	3	7
3	6	7		2	9	5	6	4
8	7		7	4	6	2	1	5
		3	5	2	7	1	4	6
	6	1	9	3	4	8	3	7

Fine-tuned Diffusion
(ความแม่นยำ 80%) -
ประเมินเงื่อนไขภาพรวมได้

Insight: การมองเห็นบริบทแบบสองทิศทาง (Bidirectional) ช่วยให้โมเดลสามารถหยุดพักและประเมินเงื่อนไขทั้งหมดได้ก่อนจะสิ้นสุดการทำงาน เหมาะกับโจทย์คณิตศาสตร์ โค้ดดิ้ง และตรรกะ

กรณีการใช้งานที่เหมาะสมที่สุด (Optimal Use Cases)



In-line Editing & Code Infilling

โครงสร้างข้อความแบบ Non-linear ได้รับประโยชน์สูงสุดจากการอ่านบริบทแบบสองทิศทาง




Local Rapid Iteration

ความหน่วงต่ำ (Low Latency) เหมาะสำหรับงานพัฒนาและทดสอบโค้ดบนเครื่องนักพัฒนาคนเดียว



OCR & Document Parsing


รองรับการป้อนข้อมูลภาพ (Multimodal) และมี Context Window ขนาดใหญ่ถึง 256K



Agentic Workflows

รองรับการเรียกใช้เครื่องมือ (Tool Calling) ภายในสถาปัตยกรรม Local Agents


ข้อควรระวัง: สภาพแวดล้อมคือตัวแปรสำคัญ




สภาพแวดล้อมในอุดมคติ โมเดลสามารถใช้
Compute ของ GPU ได้อย่างเต็มประสิทธิภาพ
สร้างประสบการณ์แบบโต้ตอบ (Interactive) ได้ดีเยี่ยม

ในระบบที่มีผู้ใช้งานพร้อมกันจำนวนมาก
โมเดลแบบเดิม (Autoregressive) จัดการทรัพยากรคุ้มค่ากว่า
การใช้ Diffusion ในจุดนี้อาจเพิ่มต้นทุนโดยไม่จำเป็น

การสนับสนุนจาก Ecosystem ตั้งแต่วันแรก





ทิศทางใหม่ของการประมวลผล AI ระดับ Local

DiffusionGemma พิสูจน์ให้เห็นว่า อนาคตของ AI ไม่ได้ขึ้นอยู่กับขนาดโมเดลเพียงอย่างเดียว แต่คือการเปลี่ยนวิธีการถอดรหัสของ GPU โดยสิ้นเชิง

ด้วยการปลดล็อกข้อจำกัดทาง Memory สู่การใช้ Compute เต็มศักยภาพ Text Diffusion เปิดประตูสู่ยุคใหม่ของแอปพลิเคชัน Real-time บน Consumer Hardware อย่างแท้จริง