


คิดด้วยภาพ, ไหวพริบคิดด้วยข้อความ

จิ๊กซอว์ชิ้นสุดท้ายสู่การให้เหตุผลระดับ AGI



```
"[[0, 1, 2],  
[3, 4, 5]]"
```


ARC-AGI: บททดสอบสติปัญญาในระดับสูงสุด



ความสามารถเฉพาะทาง
(NLP, Computer Vision)



การให้เหตุผลเชิงตรรกะเบื้องต้น
(Current LLMs)




การเรียนรู้กฎเกณฑ์นามธรรม
จากตัวอย่างเพียงหยิบมือ
(Human-like IQ Test)


**โมเดลระดับแนวหน้าอย่าง GPT-5 และ Grok 4 ยังคงล้มเหลวในการสรุปกฎเกณฑ์จากภาพ 2D
นี่คือคอขวดสำคัญสู่ AGI**

"ข้อบกพร่องใน AI ปัจจุบัน: ปัญหา 'Nested List'" data-bbox="167 35 830 117"/>

วิธีที่มนุษย์มองเห็น (การเชื่อมโยงเชิงพื้นที่ 2D)



Blind Spot Visualizer




วิธีที่ AI มองเห็น (ข้อความ 1 มิติที่แบนราบ)

```
[...,  
 [..., 0, 4, 0, ...],  
 [..., 0, 5, 0, ...],  
 ...],  
 [...,  
 [..., 0, 4, 0, ...],  
 [..., 0, 5, 0, ...]  
 ...],  
 [...,  
 [..., 0, 4, 0, ...],  
 [..., 0, 5, 0, ...]  
 ...]  
]
```


⚠️
สูญเสียบริบทเชิงพื้นที่อย่างสิ้นเชิง

"ความขัดแย้งของภาพ: ทำไมการใช้ภาพอย่างเดียวจึงล้มเหลว?"




การรับรู้ด้วยภาพขาดความแม่นยำ
ในการจัดการข้อมูลระดับเซลล์พิทเซล
(Exact cell manipulation)

"Modality Diagnostic Matrix: จุดแข็งที่เติมเต็มซึ่งกันและกัน"


	Visual Modality (มิตินภาพ)	Textual Modality (มิตินข้อความ)
Perception Style	 ภาพรวม (Holistic)	 จุดต่อจุด (Independent)
Spatial Preservation	 โครงสร้าง 2D (2D Grid)	 เส้นตรงลำดับ (Linear)
Encoding Efficiency	 สูง (ภาพเดียว)	 ต่ำ (ใช้ Token มหาศาล)
Execution Precision	 ต่ำ (คลุมเครือ)	 สูง (แม่นยำระดับเซลล์)

ภาพ = เหมาะที่สุดสำหรับการสรุปกฎ (Rule Summarization) | ข้อความ = เหมาะที่สุดสำหรับการประยุกต์ใช้กฎ (Rule Application)

เลนส์คู่ประสานญาณทัศน์: The Synergy Framework



"กลไกที่ 1: Vision-Language Synergy Reasoning (VLSR)"




แบ่งแยกและปกครอง (Divide-and-Conquer): ลดความซับซ้อนโดยให้แต่ละมิตินำหน้าที่ที่ตนเองถนัดที่สุด

ประจักษ์พยานแห่ง VLSR (VLSR in Action)

"Count how many times each number appears..."



ตรรกะแบบนับความถี่ที่ผิดพลาด
(Incorrect frequency-based heuristic)



"Identify larger blocks of similar colors and consolidate them..."



การรับรู้รูปแบบพื้นที่ที่แม่นยำ
(Accurate spatial pattern recognition)


"ภาวะกลืนไม่เข้าคายไม่ออกของการแก้ไขตัวเอง"




"LLMs fail at intrinsic self-correction (Confirmation Bias)."

AI ไม่สามารถหาข้อผิดพลาดของตนเองได้ หากยังใช้ ‘มิตี’ เดียวกับที่สร้างความผิดพลาดนั้นขึ้นมา


กลไกที่ 2: Modalfy-Switch Self-Correction (MSSSC)



"ข้อพิสูจน์เชิงประจักษ์ 1: ภาพรวมเหนือกว่าจุดเดียว (The Global Perspective)"




Input 1 13x15




Input 2 13x12




Input 3 12x16



Test 1 13x14



Output 1 6x6



Output 2 6x6



Output 3 6x6




รับรู้ภาพรวม (Vision): มองเห็น 'ไม้กางเขนสี' ที่อยู่ตรงกลางและเข้าใจการเคลื่อนที่ของแต่ละจุดภาคได้ทันที




มองแบบจุดเดียว (Text): มองไม่เห็นกางเขน แต่พยายามสุ่มตัดแถวศูนย์ถึงอย่างไร้ความหมาย

Vision immediately grasps holistic structures that text ignores.


ข้อพิสูจน์เชิงประจักษ์ 2: การรักษาโครงสร้าง 2D (2D Structure Preservation)




Input 1 15x6




Input 2 20x8



Output 1 15x6




Output 2 20x8




Input 1 15x6



Input 3 18x7



Output 1 15x6



Output 3 18x7



Test 1 28x7

?




ตรรกะแบบกลุ่ม (Vision):
แก้ปริศนาได้สำเร็จด้วยการคิดแบบ
'Block-by-block'
(รักษาความสัมพันธ์เชิงพื้นที่ 2D
ได้อย่างยืดหยุ่น)



ตรรกะเชิงเส้น (Text):
บังคับใช้ตรรกะที่ผิดพลาดแบบ
'Row-by-row'
ทำลายความเชื่อมโยงระหว่างแถว


Text flattens reality into linear sequences; Vision preserves true spatial dynamics.

ยกระดับขีดความสามารถอย่างก้าวกระโดด (Quantitative Breakthroughs)




MSSC delivers **iterative monotonic gains**, while **text-only self-correction** degrades performance.

จุดบอดทางกระบวนการคิด ต้องแก้ด้วยการสลับมิติ



มิติเดียว = อคติยืนยันและความเปราะบาง
(Single Modality = Confirmation Bias & Fragility)



การผสานพลัง = ความยืดหยุ่นและแก้ไขตนเองได้แบบมนุษย์
(Synergy = Human-like Flexibility & Self-Correction)

AI ไม่สามารถเป็น AGI ได้หากถูกขังอยู่ในมิติเดียว การสลับมิติคือวงจรตัดไฟทางปัญญา
(Cognitive Circuit Breaker) ที่ทำให้ระบบสามารถตรวจสอบผลงานตัวเองได้เหมือนมนุษย์

ก้าวต่อไปสู่ AGI ไปสู่ AGI (The New Paradigm)



Beyond Inference (Fine-Tuning)

Qwen3-8B เอาชนะ GPT-4o
(+5.0% gain) ได้เมื่อถูกฝึกฝน
ด้วยกระบวนการ VL synergy



The Golden Rule

ใช้ภาพสำหรับกลยุทธ์
(Summarization) และใช้ข้อความ
สำหรับการลงมือทำ (Application)



Open Source

โค้ดทั้งหมดเปิดสาธารณะเพื่อ
เปลี่ยนผ่าน Foundation
Models ไปสู่กระบวนการใหม่

```
> git clone github.com/InternLM/ARC-VL
```