


Evolution Strategies at the Hyperscale (EGGROLL)

กระบวนการค้นหาลำโพงการเทรนโมเดล AI ระดับพันล้านพารามิเตอร์โดยไม่จ้อ Backpropagation




eshyperscale.github.io

Oxford | MILA | NVIDIA

สรุปภาพรวม: เมื่อวิวัฒนาการข้ามขีดจำกัดของฮาร์ดแวร์


กำแพงของวงการ

Evolution Strategies (ES) ทรงพลังและแก้ปัญหา Black-box ได้ แต่กินหน่วยความจำมหาศาลและสร้างปัญหาคอขวดบน GPU เมื่อประยุกต์ใช้กับ Large Language Models




กุญแจทะลุวงข้อจำกัด

Eggroll แปลงการสุ่มเมทริกซ์ขนาดใหญ่ให้เป็น Low-rank perturbations แบบ Rank-1 ช่วยประหยัดหน่วยความจำและเพิ่มประสิทธิภาพการคำนวณขั้นสูงสุด




ผลลัพธ์เชิงประจักษ์

ฝึกสอนโมเดลได้เร็วขึ้น 100 เท่า แข่งหน้า GRPO ในงานคณิตศาสตร์เชิงตรรกะ และสร้างประวัติศาสตร์ปลดล็อกการเทรน Pure Integer LLMs ได้สำเร็จ




โลกที่ถูกจองจำด้วย Backpropagation

ภายใต้ร่มเงาของ Backprop



- Differentiability: ต้องการสมการที่หาอนุพันธ์ได้เสมอ
- Precision Limits: สูญเสียความเสถียรอย่างรุนแรงเมื่อทำงานกับ Low-precision data types
- The Bottleneck: ปัญหาคอขวดในการรอส่งผ่าน Gradient ข้ามคลัสเตอร์ GPU


อิสระภาพของ Evolution Strategies (ES)



- Zero-Order: ทำงานได้ทันทีโดยไม่ต้องพึ่งพา Gradient
- Discrete Mastery: รองรับฟังก์ชันแบบไม่ต่อเนื่องและโครงสร้างชิปแบบ Int8 อย่างสมบูรณ์
- Infinite Scale: ขยายขอบเขตการประมวลผลแบบคู่ขนานได้อย่างไร้ขีดจำกัดและทนทานต่อ Noise

สู่ทางตัน: ทำไม Naive ES ถึงไปไม่รอดในสเกลไฮเปอร์?

ในระดับพันล้านพารามิเตอร์ ต้นทุน Memory และ Compute ของ Naive ES คืออุปสรรคที่ข้ามไม่ได้



1

Memory Explosion

- การปรับเปลี่ยนพารามิเตอร์ (Mutation) แต่ละครั้ง ต้องสร้าง Full-rank Matrix ใหม่ทั้งหมด ซึ่งกินพื้นที่หน่วยความจำทวีคูณตามจำนวนประชากร

2

Compute Starvation

- โครงสร้างข้อมูลแบบสุ่มไร้ระเบียบ ทำให้ GPU ต้องเสียเวลาดึงข้อมูลจาก Memory มากกว่าการคำนวณจริง ทำให้เกิดสถานะ Memory Bound ชันวิกฤต


EGGROLL: บีบอัดความซับซ้อนด้วย Low-Rank Blueprint

$$E = \frac{1}{\sqrt{r}} (AB^T)$$

The diagram illustrates the decomposition of a dense matrix E (size $m \times n$) into two low-rank matrices, A (size $m \times r$) and B^T (size $r \times n$), using the formula $E = \frac{1}{\sqrt{r}} (AB^T)$. The matrix E is shown as a green grid. The matrix A is shown as a vertical purple and brown bar. The matrix B^T is shown as a horizontal brown and purple bar. Arrows indicate the flow from E to the product of A and B^T .


กระบวนการยุบรวมมิติ (Dimensionality Collapse)

แทนที่จะสร้างเมทริกซ์ที่ขนาด $E \in \mathbb{R}^{m \times n}$
อัลกอริทึมจะสุ่มสร้างเพียงเมทริกซ์แนวตั้ง
(**A**) และแนวนอน (**B**) ขนาดเล็กพิเศษ
โดยที่ค่า Rank $r \ll \min(m, n)$





ผลลัพธ์การบีบอัดเชิงเรขาคณิต

พื้นที่จัดเก็บ Perturbation matrix
หายไปมหาศาล ลดลงจากสมการ
จะสมการ ($m \times n$) เหลือเพียง $(m+n)r$
ต่อหนึ่งชั้นเลเยอร์การประมวลผล



The Zero-Memory Trick: สถาปัตยกรรมการทำงานแบบคู่ขนาน






The Evolution Matrix: จุดบรรจบของทฤษฎีและฮาร์ดแวร์

EGGROLL นำข้อดีแบบ Black-box ของ ES มารวมกับประสิทธิภาพฮาร์ดแวร์ระดับ Backprop

มิติการวิเคราะห์ (Dimensions)	Backpropagation	Naive ES	EGGROLL (กระบวนทัศน์ใหม่)
ไม่ต้องการ Differentiability?	✗	✓	✓
รองรับสถาปัตยกรรมแบบ Discrete (Int8)?	⚠ (ต้องใช้ Trick พิเศษ)	✓	✓
ปัญหา Memory Explosion?	✗ (กินพื้นที่สูง)	✗ (กินพื้นที่มหาศาล)	✓ (Zero Overhead)
ความคุ้มค่าของการคำนวณ (Arithmetic Intensity)	✓ (สูง)	✗ (ต่ำมาก)	✓ (สูงเทียบเท่า Batched LoRA)
ศักยภาพการขยายสู่ Billion Parameters	✓	✗	✓



ทฤษฎีบทการลู่เข้า: เมื่อมิติเพิ่มขึ้น ความแม่นยำยิ่งทวีคูณ



The Linearisation Effect

ในมิติที่สูงมาก อัลกอริทึม Gaussian ES จะเกิดปรากฏการณ์ลู่เข้าสู่ 'อนุพันธ์อันดับหนึ่ง' โดยอัตโนมัติ ทำให้ได้ทิศทางที่แม่นยำดุจ Backprop


Critical Noise Scaling

การตั้งค่าสเกลของ Noise ที่ระดับ $\sigma_d = o(d^{-1/2})$ คือจุดสมดุลทางทฤษฎีที่ทำให้การอัปเดตของ EGGROLL มีความเสถียรและแม่นยำระดับสูงสุด

Mathematical Robustness

ทฤษฎีนี้ครอบคลุมถึงฟังก์ชันเป้าหมายที่มีความไม่ต่อเนื่อง (Discontinuous) อย่างรุนแรง ซึ่งเป็นจุดที่ระบบ Gradient ปกติล้มเหลวอย่างสิ้นเชิง

พลังแห่ง Rank-1: ความเรียบง่ายที่ทรงประสิทธิภาพ



อัตราการลู่เข้าความเร็วสูง

การอัปเดตแบบ EGGROLL จะลู่เข้าสู่ Full-rank Gaussian ES ด้วยอัตรา $O(r^{r-1})$ ซึ่งเร็วกว่าทฤษฎี Central Limit Theorem ทั่วไปอย่างมีนัยสำคัญ


ความมหัศจรรย์ของ Rank=1

แม้ตั้งค่า Rank ให้ต่ำที่สุดเพียง 1 ผลลัพธ์ทางทฤษฎีและการปฏิบัติก็ใกล้เคียงกับอุดมคติอย่างมาก เป็นกุญแจสำคัญที่ทำให้ระบบใช้หน่วยความจำน้อยที่สุด

จุดอ้อมตัวที่ $r=50$

เมื่อเพิ่มค่า Rank ถึงระดับ 50 เส้นโค้งทฤษฎีจะทับซ้อนกับ Full-rank จนแยกด้วยตาเปล่าไม่ออก ยืนยันว่า Rank ต่ำเพียงพอสำหรับการเทรนโมเดลขนาดใหญ่

หลักฐานที่ 1: ทลายขีดจำกัดความเร็ว 100 เท่า



Throughput เหนือชั้น

สร้าง Throughput มหาศาลทะลุถึง 91% ของขีดจำกัดสูงสุดในการทำ Pure Batch Inference ทั่วไปบนฮาร์ดแวร์ชุดเดียวกัน

ทิ้งห่าง OpenES


เมื่อเปรียบเทียบกับอัลกอริทึม OpenES ดั้งเดิม EGGROLL สามารถทำความเร็วสัมพัทธ์ได้เร็วกว่าถึง 100 เท่า

Batched LoRA Power


ถูกใจความเร็วคือการออกแบบโครงสร้างที่เข้ากันได้ดีกับ Batched LoRA Inference ทำให้รีดพลัง GPU ออกมาได้เต็ม 100%

หลักฐานที่ 2: เหนือกว่า GRPO ในงาน Math Reasoning

การมอบ Reward โดยตรงจากผลลัพธ์ปลายทาง (Outcome-only) ทรงพลังกว่าสมการอนุพันธ์



Resource Efficiency: โมเดล RWKV-7g1.5B (Countdown Task) EGGROLL สามารถรันแบบขนานได้ถึง 1024 Generations/GPU เทียบกับ GRPO ที่ทำได้เพียง 64




Accuracy Leap: ทะยานสู่ความแม่นยำ 30% (AIME24) ในโมเดล 14B ภายใต้งบประมาณการคิดเพียง 5000 Tokens (เทรนบน 32 GPUs ใช้เวลา 12 ชั่วโมง)


หลักฐานที่ 3: จอศักดิ์สิทธิ์แห่ง Pure Integer LMs

ฝึกสอนโมเดลที่ไม่ใช้ Activation Function และทำงานด้วยเลขจำนวนเต็ม 100% จากศูนย์

EGG (Evolved Generative GRU) Architecture



Pure Integer Pretraining




EGGROLL's Victory: ด้วยประชากรระดับไฮเปอร์สเกล (1,048,576) EGGROLL สามารถเทรนโมเดล Int8 ให้ทำ Cross-entropy Test Loss แข่งหน้า fp32 Transformer ของ Backprop (3.40 vs 3.58 bits/byte) ได้สำเร็จ

หลักฐานที่ 4: ความอเนกประสงค์ไร้ขีดจำกัด


เครื่องมือ Optimization อเนกประสงค์ที่พร้อมทำงานทุกสภาพแวดล้อม

Tabula Rasa Reinforcement Learning




เสถียรภาพระดับสูงในงาน Control สามารถแข่งขันได้สูสีหรือเหนือกว่า PPO และ OpenES ในสภาพแวดล้อมจำลองกว่า 16 รูปแบบ โดยใช้เวลา Wall-clock น้อยกว่าอย่างเห็นได้ชัด

Quantised Model Distillation



การถ่ายทอดองค์ความรู้: ใช้ EGGROLL ดึงสติปัญญาจากโมเดลขนาดใหญ่ สู่โมเดลที่ถูก Quantize เหลือเพียงช่วงแคบๆ (Int8 [-127, 127]) ทำให้โมเดลเริ่มแก้โจทย์คณิตศาสตร์ GSM8K ได้สำเร็จ

Synthesis: จุดกำเนิดสถาปัตยกรรมแห่งอนาคต



ปลดล็อกศักยภาพ AI สู่มิติใหม่

1. Maximum Efficiency

ทำลายคอกขวด Memory และ Compute อย่างราบคาบด้วย Low-rank approximations สร้างอัตราเร่งทะลุขีดจำกัดกว่า 100 เท่า

2. Hyperscale Capability

พิสูจน์แล้วในงานระดับพันล้านพารามิเตอร์ ทั้งการ Fine-tuning Language Models อันซับซ้อน และภารกิจ Tabula rasa RL

3. A True Paradigm Shift

สร้างสิ่งที่ Backprop ทำไม่ได้—บุกเบิกการเทรน Pure Integer Models จากศูนย์ และกรุยทางสู่ระบบ Neurosymbolic อัจฉริยะแห่งอนาคต

> Explore the code and hyperscale your models:
> GitHub: [eshyperscale.github.io](https://github.com/eshyperscale)