


EMPO2: สะพานเชื่อม วิวัฒนาการของ AI Agent

ก้าวข้ามขีดจำกัดด้านการ
สำรวจของ LLM ด้วย Hybrid
On- and Off-Policy Optim-
ization



ปัญหาข้อขัดแย้ง: ทำไม LLM Agent ถึงติดหล่ม?



การยึดติดกับความรู้เดิม:

โมเดลพึ่งพาข้อมูล Pre-training มากเกินไป ทำให้ไม่กล้าทดลองสิ่งใหม่




ทางตันของการเรียนรู้แบบเดิม:

RL แสวงหา Reward สูงสุดแบบสั้นๆ ทำให้หลงทางในสภาพแวดล้อมที่ซับซ้อน




ข้อจำกัดของ Memory:


การใช้ Prompt ใส่ความจำแบบเดิมๆ ถึงจุดอิ่มตัวเร็วเพราะไม่มีการอัปเดตน้ำหนักของโมเดล



กรณีศึกษา: กับดักหลอดไฟสีแดง (The ScienceWorld Failure)



GRPO (ไม่มีความจำ): ทำตามคำสั่งตรงตัว
ล้มเหลวซ้ำซาก ขาดการวิเคราะห์สาเหตุ




EMPO2 (มีความจำนำทาง): สร้าง Tips
จากความล้มเหลว ขยายขอบเขตการสำรวจ
และค้นพบวิธีการใหม่

วิวัฒนาการของ LLM Agent (The Agent Landscape)

Methodology	สร้าง Memory อัตโนมัติ?	อัปเดต Parameters?	ความสามารถในการสำรวจ	ปรับตัวเข้ากับงานใหม่
Standard RL (PPO/GRPO)	✗	✓	Low	Low
External Memory (Reflexion)	✓	✗	Medium	Medium
Offline RL (Retrospecx)	✗	✓	Low	Low
Hybrid Optimization (EMPO2)	✓	✓	High	High

จุดเปลี่ยน: การหลอมรวมสองโลกการเรียนรู้



EMPO² ผสานการสำรวจด้วยหน่วยความจำ (Non-parametric) เข้ากับการปรับปรุงโครงสร้างโมเดลหลัก (Parametric) ทำให้ AI ไม่เพียงแค่จำได้ แต่สามารถสกัดความรู้เข้าไปในน้ำหนัก (Weights) ของตัวเองได้อย่างถาวร

กลไกการเรียนรู้แบบ EMP02 (The Act-Reflect-Internalize Loop)

Internalize (ตกผลึกความรู้):
อัปเดตโครงสร้างข่ายประสาท




Act (ลงมือทำ):
ปฏิสัมพันธ์กับสภาพแวดล้อม

Reflect (สะท้อนความคิด):
สร้าง Tips จากผลลัพธ์


ข้อสังเกต: Tips ไม่ได้ถูกเขียนโดยมนุษย์
แต่ถูกสร้างขึ้นจาก Policy
ของโมเดลเองที่พัฒนาขึ้นเรื่อยๆ

สถาปัตยกรรมแบบ Hybrid (The Three Learning Modes)



ถอดนั้งร้าน: ความลับของ Off-Policy Update

Phase 1




Teacher/Student Metaphor:
โมเดลที่ใช้ Tips ทำหน้าที่เป็นครู
สาธิตเส้นทางที่ถูกต้องให้โมเดลหลัก

Phase 2




Reward-Guided Distillation:
ข้อมูลที่มี Reward สูง
จะถูกบังคับให้ซึมซับลงไปโมเดลหลัก

Phase 3




ผลลัพธ์ (Inference):
เมื่อนำไปใช้งานจริง โมเดลจะเก่งขึ้นโดย
ไม่ต้องพึ่งพาความจำ (Tips) อีกต่อไป

การรักษาสมดุลของระบบ (Stabilizing the Engine)



Token Masking:
ตัด Token ที่มีความน่าจะเป็น
ต่ำเกินไปเพื่อลดความผันผวน ป้องกันไม่ให้ระบบพัง



Intrinsic Rewards:
ให้รางวัลพิเศษเมื่อ AI ค้นพบ State ใหม่ๆ
กระตุ้นความอยากรู้อยากเห็นและการสำรวจ

ก้าวกระโดดของประสิทธิภาพ (Benchmarking Triumphs)

ScienceWorld
+128.6%



ทดสอบการวางแผนระยะยาว
การแก้ปัญหาทางวิทยาศาสตร์ และการใช้เครื่องมือ


WebShop
+11.3%



สภาพแวดล้อมจำลอง E-commerce
ทดสอบการค้นหาและการตัดสินใจ

EMPO2 ทำคะแนนสูงสุด ชนะขาดทั้ง Offline RL, Online RL แบบดั้งเดิม และ Non-parametric methods

ทำลายเพดานการเรียนรู้ (Breaking the Plateau)




GRPO: ล้มเหลวในการขยายขอบเขตความรู้
รับหาคำตอบจนติดอยู่ใน Local Minima

EMPO2: พลังการสำรวจผ่านการ
อัปเดตความจำ ทำให้เกิดพัฒนาการ
อย่างต่อเนื่องจนบรรลุเป้าหมาย

การปรับตัวข้ามสายงาน (Out-of-Distribution Adaptation)


Card 1

ชีววิทยา (Biology) → ชีววิทยา 2



Card 2

ชีววิทยา (Biology) → ไฟฟ้า (Electricity)



Card 3

ไฟฟ้า (Electricity) → เคมี (Chemistry)



Zero-Weight Updates: ความสามารถในการแก้ปัญหาที่ไม่เคยเจอมาก่อน โดยใช้เพียงแค่หน่วยความจำที่สะสมไว้ ไม่ต้อง Retrain โมเดลใหม่

Fast Adaptation: เมื่อเปิดใช้งาน Memory โมเดล EMPO2 สามารถปรับตัวเข้ากับโดเมนใหม่ได้เร็วกว่า GRPO อย่างมีนัยสำคัญ

วิวัฒนาการขั้นถัดไปของ Autonomous Agents



การสำรวจอย่างเป็นระบบ

ข้ามข้อจำกัดของ Pre-trained Data ด้วยการลองผิดลองถูกอย่างมีทิศทาง

การผนวกความจำสู่สติปัญญา

ไม่ใช่แค่การจดจำชั่วคราว แต่เป็นการตกผลึกความรู้ฝังรากลึกในโมเดล

ปูทางสู่อนาคต

สถาปัตยกรรมต้นแบบสำหรับ AI Agent ที่สามารถวิวัฒนาการตัวเองได้อย่างต่อเนื่อง