






Conditional Memory: แกนความเบาบาง (Sparsity) มิติใหม่ของ Large Language Models

พลิกโฉมสถาปัตยกรรม LLM จากการจำลองความรู้ด้วย 'การคำนวณ'
สู่กลไกการดึงข้อมูลแบบ $O(1)$ Lookup ด้วยโมดูล Engram

การสูญเสียพลังงานคำนวณเพื่อ 'ฟื้นความจำ' (The Wasted Compute Problem)




สองแกนหลักแห่งความเบาบาง (The Two Axes of Sparsity)

มิติการเปรียบเทียบ (Dimensions)	Conditional Compute (MoE)	Conditional Memory (Engram)
เป้าหมายทางภาษา (Target Signal)	การให้เหตุผลและการจัดองค์ประกอบ (Compositional Reasoning)	ความรู้และรูปแบบภาษาที่ตายตัว (Static Knowledge)
กลไกการทำงาน (Mechanism)	การสลับเส้นทางข้อมูลแบบพลวัต (Dynamic Routing)	การค้นหาข้อมูลด้วยเวลาคงที่ (O(1) Hash Lookup)
การจัดสรรฮาร์ดแวร์ (Hardware Mapping)	ทำงานบน GPU Compute อย่างเข้มข้น	ดึงข้อมูลล่วงหน้าจาก CPU / Host DRAM อย่างไร้รอยต่อ

Key Insight: Engram ไม่ได้มาแทนที่ MoE แต่คือฟันเฟืองชิ้นที่สองที่ทำให้เครื่องยนต์สมบูรณ์


สถาปัตยกรรมไต้โมดูล Engram (The Precision Pipeline)

Step 1: การบีบอัด Tokenizer (Tokenizer Compression)




ยุบรวม ID ของ Token ที่มีความหมายเดียวกัน (เช่น 'Apple' และ 'apple') ให้เป็นมาตรฐานเดียว เพิ่มความหนาแน่นทางความหมายถึง 23%

Step 2: การแฮชแบบหลายหัว (O(1) Multi-Head Hashing)




ใช้ N-gram ของคำศัพท์เป็นกุญแจค้นหา ข้อมูลจากตาราง Embedding ระดับหลายหมื่นล้านพารามิเตอร์แบบ O(1)

Step 3: การกรองด้วยบริบท (Context-Aware Gating)




ใช้สถานะปัจจุบันของโมเดล (Dynamic Query) ควบคุมและกลั่นกรองความรู้ที่ดึงมา (Static Value) เพื่อจำกัดความกำกวมของคำศัพท์

การทำงานในสถานะจริง: แม่นยำเฉพาะเมื่อจำเป็น




Key Takeaway: สัญญาณ Gating จะทำงานก็ต่อเมื่อโมเดลค้นพบ ‘รูปแบบตายตัว’ หรือ ‘ชื่อเฉพาะ’ (Named Entities / Idioms) เท่านั้น พิสูจน์ว่า Engram ปลดปล่อยภาระการจำออกจาก Transformer Backbone ได้จริง

กฎการจัดสรรความเบาบาง (The Sparsity Allocation Law)



ผลลัพธ์: Validation Loss ต่ำที่สุด เอาชนะโมเดลแบบ Pure MoE ได้อย่างหมดจดภายใต้ข้อจำกัด Parameter และ FLOPs ที่เท่ากันทุกประการ

'ความลึกเสมือน': ข้ามขีดจำกัดของโครงข่าย (Effective Depth)




1 ปรัชญาการข้ามชั้น

ข้อมูลจากศูนย์กลางวิเคราะห์ CKA และ LogitLens แสดงให้เห็นชัดเจนว่า การนำ Engram เข้ามาใน Layer ที่ 2 หรือ 5 ทำให้โมเดลมีสถานะความเข้าใจเทียบเท่า Layer ที่ 12 ของโมเดลปกติ

2 กลไก (The 'Why')

เมื่อโมเดลไม่ต้องเสียเวลาใน Layer แรกๆ กับการประกอบร่างคำศัพท์และความรู้ตัว มันจึงสามารถใช้ Layer ที่เหลือในการประมวลผลตรรกะที่ซับซ้อนได้อย่างเต็มที่ ตั้งแต่นั้นๆ

สถาปัตยกรรมฮาร์ดแวร์อัจฉริยะ (Infrastructure-Aware Offloading)




Prefetch-and-Overlap Strategy

เนื่องจาก ID ของ Engram สามารถถูกกำหนดได้ทันทีจาก Tokenizer ระบบจึงสามารถสั่ง 'ดึงข้อมูล' (Prefetch) จาก CPU ได้ล่วงหน้า

ในขณะที่ข้อมูลกำลังเดินทางผ่าน PCIe, GPU กำลังคำนวณ Layer 1 อย่างเต็มกำลัง

Impact: สามารถ Offload พารามิเตอร์ระดับ 1 แสนล้านตัว โดยมี Latency Overhead น้อยกว่า 3% (Zero Inference Penalty)

วิเคราะห์เชิงลึก: เกิดอะไรขึ้นเมื่อเรา 'ปิด' Engram?



ก้าวข้ามขีดจำกัดในทุกมิติการทดสอบ (Empirical Dominance)

ความรู้ทั่วไป
(Knowledge)

MMLU
(+3.4)

CMMLU
(+4.0)

คาดการณ์ได้: โมดูลหน่วยความจำ
ย่อมเก่งเรื่องความจำ

การให้เหตุผล
(General Reasoning)

BBH
(+5.0)

ARC-Challenge
(+3.7)

เชอร์ไพรส์: การมีความรู้พร้อมใช้
ช่วยให้เหตุผลได้ดีขึ้นอย่างก้าวกระโดด

คณิตศาสตร์และการเขียนโค้ด
(Math & Code)

HumanEval
(+3.0)

MATH
(+2.4)

บทสรุป: เมื่อโมเดล 'สืกขึ้น' ในเชิง
ประสิทธิภาพ ความสามารถในการแก้
ตรรกะซับซ้อนก็เพิ่มขึ้นตามไปด้วย

ปลดล็อกศักยภาพบริบททางภาษา (The Long-Context Superpower)

RULER Benchmark Multi-Query NIAH Scores

MoE-27B

84.2

Engram-27B

97.0%


การพิทักษ์ขีดความสามารถของ Attention (Preserving Attention Capacity)

การประมวลผล Context ยาวๆ
จำเป็นต้องใช้พื้นที่ Attention มหาศาล

Engram ช่วยโยกย้ายภาระการจัดการ
‘บริบทเฉพาะที่’ (Local
Dependencies) ไปไว้ที่ระบบ Lookup

ผลลัพธ์คือ Transformer หัวใจหลัก
มีพื้นที่และขีดความสามารถเหลือเพื่อการเชื่อมโยง
‘บริบทภาพรวม’ (Global Context)
จากข้อความนับหมื่นๆ คำได้อย่างไร้รอยต่อ

The Blueprint: สถาปัตยกรรม AI แห่งอนาคต




1. โครงสร้างสอดคล้องกับภาษา (Linguistic Duality)

ไม่ดันทุรังใช้คอมพิวเตอร์คำนวณ
สิ่งที่ควรใช้ความจำอีกต่อไป


2. ประสิทธิภาพที่จับต้องได้จริง (U-Shaped Allocation)

ทฤษฎีเหนือ Pure MoE
ในทุกมิติ ภายใต้ต้นทุน
FLOPs ที่เท่ากัน



3. ปลดแอกข้อจำกัดฮาร์ดแวร์ (Infinite Memory Regime)

สเกลความจุพารามิเตอร์ระดับ
100B+ ได้ยึดจำกัดผ่านโฮสต์
หน่วยความจำ (Host DRAM)



Final Takeaway: Conditional Memory (Engram) ไม่ใช่แค่ทางเลือกเสริม แต่คือ 'มิติแห่งความเบาเบงแแกนที่สอง' ที่จะเป็มาตรฐานใหม่ (Indispensable Primitive) ของ Frontier Models ในยุคถัดไป