



Experiential Reinforcement Learning (ERL): การเรียนรู้จากประสบการณ์เพื่อพัฒนา AI Agents

เปลี่ยนจากระบบลองผิดลองถูกแบบดั้งเดิม (Trial-and-Error)
สู่โครงสร้างการคิดวิเคราะห์และปรับปรุงตัวเอง (Cognitive Loop) ยั่งยืน



ข้อจำกัดของ Reinforcement Learning แบบดั้งเดิม (RLVR)

The Amnesia Loop




สุ่มทำซ้ำๆ แบบไร้ทิศทาง (Blind Trial-and-Error): RLVR พึ่งพาแค่ผลลัพธ์ที่เป็นตัวเลข (Scalar Reward) ตอนจบเกมเท่านั้น

ปรากฏการณ์ความจำเสื่อม (Amnesia in Agents): โมเดลไม่รู้ว่าทำไมถึงพลาด ทำให้เกิดการสุ่มทำผิดซ้ำเดิมในงานที่ต้องวางแผนซับซ้อน (Agentic Tasks)

สูญเสียทรัพยากร (Sample Inefficiency): ไม่มีการปรับปรุงโครงสร้างพฤติกรรมระหว่างทาง ทำให้กินเวลาและทรัพยากรในการเทรนสูงมาก

เมื่อ Agent ได้รับความจำ: การลองผิดลองถูก VS การคิดวิเคราะห์

RLVR: Forget & Retry




ERL: Reflect & Adapt



แทนที่จะรอรับแค่คะแนนตอนจบ Agent ที่ดีควรเรียนรู้เหตุผลของความล้มเหลวระหว่างทาง และนำมาปรับแผนทันทีในรอบถัดไป

วิวัฒนาการของการเรียนรู้ของ Large Language Models

Evolutionary Timeline



ERL คือการยกระดับจากการแค่รับผลคะแนน เป็นการสอนให้โมเดลสร้างประสบการณ์และทบทวนตัวเองอย่างเป็นระบบ

สถาปัตยกรรม ERL: วงจรการเรียนรู้เสมือนมนุษย์ (Cognitive Loop)




โมเดลไม่ได้ปรับปรุงจากตัวเลขคะแนน แต่เปลี่ยน **Feedback** ให้เป็น **โครงสร้างคำอธิบาย** ที่มันสร้างขึ้นเพื่อสอนตัวเอง

Cross-Episode Memory: ส่งต่อปัญญาข้ามรอบการฝึก



ความสำเร็จไม่ได้หายไปเมื่อจบด่าน! **ERL** จัดเก็บ **Reflection** ที่ถูกต้องเพื่อเป็นไกด์ไลน์เร่งความเร็วในการเรียนรู้ข้ามรอบ (Episodes) ช่วยลดการสุ่มซ้ำซ้อนและสร้างพฤติกรรมที่เสถียรขึ้นอย่างรวดเร็ว

ถอดรหัสการทำงานที่ไร้ต้นทุน: The Internalization Funnel



จุดแข็งที่สุดของ ERL คือมันไม่ต้องคิดต่างๆ ตอนใช้งานจริง กระบวนการสอนให้โมเดลเลียนแบบความสำเร็จของตัวเองในรอบสุดท้าย ทำให้ความรู้ฝังเป็นสัญชาตญาณ (Zero Inference Tax)

Paradigm Diagnostic Matrix: เปรียบเทียบกระบวนการเรียนรู้

	1. Direct Learning (SFT)	2. Standard RL (RLVR)	3. Experiential RL (ERL)
กลไกหลัก (Core Mechanism)	Imitation	Trial & Error	Experience Loop
รูปแบบ Feedback	None	Implicit (Scalar)	Explicit (Verbal Reflection)
การแก้ไขพฤติกรรม (Behavioral Correction)	None	Cross-episode only	Within-episode + Cross-episode
ต้นทุนทรัพยากรตอนใช้งาน (Inference Cost)	Low	Low	Low (via Internalization)


ชัยชนะในสภาพแวดล้อมที่ซับซ้อน (Agentic Control)

+81%
ก้าวหน้ากระโดด


Qwen3-4B-Instruct-2507
Sokoban Final Reward:

ERL: 0.87 **RLVR: 0.06**

SOKOBAN



FROZENLAKE



ในการกิจที่ต้องวางแผนล่วงหน้า (Long-horizon) และไม่รู้จักพลวัตของเกม (Unknown dynamics)
การรอแค่คะแนนตอนจบทำให้โมเดลแบบเดิมล้มเหลวโดยสิ้นเชิง แต่ ERL สามารถวิเคราะห์เงื่อนไขและเล่นเกมได้อย่างเด็ดขาด


การยกระดับในการกิจการใช้เครื่องมือ (Tool-using Reasoning)

+11% ประสิทธิภาพ

Training Convergence



HOTPOTQA



สำหรับงานดึงข้อมูลที่ค่อนข้างตรงไปตรงมา RLVR ทำได้ดีระดับหนึ่งแล้ว ทว่า ERL ยังคงมอบประสิทธิภาพที่เหนือกว่าและเสถียรกว่า พิสูจน์ว่าโครงสร้างการทบทวนตัวเองมีประโยชน์ในทุกมิติของ Agentic Tasks

Insight: ยิ่งโลกซับซ้อน ERL ยิ่งทวีความสำคัญ



ข้อมูลชี้ให้เห็นกฎเกณฑ์ที่ชัดเจน: เมื่อ Agent ต้องเผชิญกับโลกที่ซับซ้อนเร้น (Unknown Dynamics) และต้องคาดเดาผลลัพธ์ระยะยาว การทบทวนตัวเองอย่างเป็นระบบไม่ใช่แค่ตัวช่วย แต่เป็นสิ่งจำเป็น (Prerequisite) ในการเรียนรู้

บทสรุป: ก้าวต่อไปของระบบ Autonomous Agents

1. ฉลาดขึ้นจากความผิดพลาด
(Feedback into Strategy):
เปลี่ยนผลลัพธ์ที่ว่างเปล่า ให้เป็น
คำแนะนำเชิงพฤติกรรม

2. ข้ามขีดจำกัดของงานซับซ้อน
(Ready for Complex Worlds):
ปลดล็อกความสามารถในงานที่ระบบ
สุ่มแบบดั้งเดิม (RLVR) เข้าไม่ถึง

3. คงความเร็วสูงสุด (Zero
Inference Tax): ความรู้
ถูกฝังรากลึก ไม่ถึงทรัพยากร
(Compute) เมื่อนำไปใช้งานจริง



**Experiential Reinforcement Learning ไม่ใช่แค่อัลกอริทึมใหม่ แต่คือรากฐานในการ
สร้าง AI ที่สามารถปรับตัวและเอาชีวิตรอดในโลกแห่งความเป็นจริงได้อย่างแท้จริง**