



GPT-oss from the Ground Up

ชำแหละสถาปัตยกรรม
Open-Weight LLM จาก OpenAI

A Technical Teardown of
Architecture, Reasoning,
and Alignment



GPT-oss At a Glance: ภาพรวมพิมพ์เขียวสถาปัตยกรรม



Diagnostic Matrix: เปรียบเทียบสเปกโมเดล


Feature	GPT-oss-20b	GPT-oss-120b
Total Parameters	20B	120B
Active Parameters	3.6B	5.1B
Total Experts	32	128
VRAM Requirement (MXFP4)	~16GB	80GB (Single GPU)
Comparable Performance	o3-mini	o4-mini

ประสิทธิภาพสูงสุดจาก
การทำงานจริง:
ใช้งานพารามิเตอร์เพียง
เล็กน้อยด้วยระบบ MoE
(Mixture-of-Experts)




Key Takeaway: ประสิทธิภาพระดับ Frontier Model ที่สามารถรันได้บน Local Hardware เครื่องเดียว

The Decoder Block Blueprint




Attention Efficiency: การจัดการพลังงานประมวลผล

Grouped-Query Attention (GQA)




Sliding Window Attention




Layer Configuration: จัดเรียงแบบสลับ 1:1 Ratio (Dense 1 ชั้น สลับ Sparse 1 ชั้น) เพื่อรักษาสมดุลระหว่างความฉลาดและความรวดเร็ว


Solving the Attention Sink




Mixture-of-Experts (MoE) Routing



The Harmony Prompt Format



Instruction Hierarchy: ลำดับชั้นของคำสั่ง




Risk Mitigation Note:

โครงสร้างอำนาจนี้ถูกฝังอย่างแน่นหนาในขั้นตอน Post-training ป้องกันปัญหา Prompt Injection อย่างเด็ดขาด (User ไม่สามารถล้วงเล็กคำสั่งของ Developer ได้)

Scaling Context to 131k (RoPE & YaRN)

Short Context (High Freq) - ไม่แทรกแซง รักษาความละเอียด



Long Context (Low Freq) - ขยายสัดส่วนคลื่นความถี่ (Interpolation)


1. Core Concept: RoPE

Rotary Position Embedding
ฝังข้อมูลระยะห่างสัมพัทธ์
(Relative Distance) เข้าไปใน
กลไก Attention ของโมเดล

The Upgrade: YaRN

เทคนิค NTK-by-parts
Interpolation ปรับขยาย Base
Frequency แบบไดนามิกตาม
ความยาวคลื่น ทำให้โมเดลจดจำ
บริบทได้ยาวถึง 131,000 Tokens
โดยไม่สูญเสียความแม่นยำ

Training the Reasoning Mind



Crucial Rule: No Direct Supervision on CoT

ห้ามเข้าไควควบคุมสิ่งที่โมเดลคิดระหว่างทาง เพื่อป้องกันไม่ให้โมเดล “ซ่อน” ความคิดที่แท้จริงและเลี่ยงการตรวจสอบ


High-Compute RLVR

(Reinforcement Learning from Verifiable Rewards)

ให้รางวัลเมื่อโมเดลตอบถูกต้องตามหลักเกณฑ์ที่ตรวจสอบได้ 100% (เช่น คณิตศาสตร์/เขียนโค้ด)




Inference-Time Scaling



Insight: กฎ Scaling Law ได้เปลี่ยนผ่านยุคสมัย—จากเดิมที่ต้องอัด Compute ตอน Training เปลี่ยนเป็นการอัด Compute ตอน Inference แทน (ยิ่งคิดนาน ยิ่งฉลาด)

Deliberative Alignment: ความปลอดภัยที่ผ่านการไตร่ตรอง



กลไก Deliberative Alignment ฝึกให้โมเดลใช้ CoT เพื่อคิดทบทวน 'กฎความปลอดภัย' อย่างเป็นระบบก่อนจะให้คำตอบ เป็นการสร้างภูมิคุ้มกันทางตรรกะที่แข็งแกร่งกว่าการปิดกั้นคำสั่งแบบเดิม

Risk Assessment: Malicious Fine-Tuning (MFT)

Threat Assessment Matrix

การทดสอบจงใจจูนโมเดลเพื่อลบระบบ Safety ที่ทั้งหมด (Worst-case scenarios)

[1] Anti-refusal



Status: Compromised

- ทำสำเร็จ: อัตราการปฏิเสธคำสั่งเหลือ 0%

[2] Biological Risks



Status: Secure

- ปลอดภัย: ความสามารถไม่เกินโมเดลเดิมที่มีอยู่แล้วในตลาด (ทักษะต่ำกว่าระดับ o3)

[3] Cybersecurity



Status: Secure

- ปลอดภัย: ทำผลงานได้แย่มากเมื่อเจอกับชุดทดสอบแบบ Capture-the-Flag

Final Verdict

การเปิด Open-Weight ของ GPT-oss ไม่ได้สร้างความเสี่ยงใหม่ที่เป็นภัยคุกคามร้ายแรง (No significant added threat)
ความพยายามดัดแปลงโมเดลในระดับสูงไม่ส่งผลให้ขีดความสามารถด้านมิดเพิ่มขึ้นอย่างมีนัยสำคัญ



The Ultimate Synthesis: The Blueprint of an Agentic Mind


1. The Engine (MoE + MXFP4)

สถาปัตยกรรมที่ให้สติปัญญา
ระดับสูงแต่รันได้บน Local GPU
ด้วยการเข้ารหัสแบบ 4-bit
Quantization

3. The Brain (RLVR + Deliberative Alignment)

กลไกการให้เหตุผลที่คิดอย่างมี
ตรรกะ และสามารถใคร่ครวญถึง
ความปลอดภัยด้วยสติของตัวเอง

Assembled
Blueprint



2. The Interface (Harmony Format)

ระบบต่อข้อมูลอัจฉริยะที่
รองรับการเป็น Agent สั่งการ
เครื่องมือภายนอก และจัด
ลำดับชั้นความสำคัญได้เด็ดขาด

GPT-oss ไม่ใช่แค่โมเดลภาษาที่เปิดให้นักให้ใช้ แต่คือพิมพ์เขียวระบบปฏิบัติการ AI
ที่ออกแบบโครงสร้างจากรากฐานเพื่อยุคสมัยของ Agentic Workflow อย่างแท้จริง