





การใช้ GRPO เพื่อยกระดับการให้เหตุผลทางกฎหมายไทย

เจาะลึกเทคนิค Efficient Alignment สำหรับระบบ RAG

Technical Report Review based on "Can Group Relative Policy Optimization Improve Thai Legal Reasoning?"

BROKEN PROCESS



Context:

Instruction Tuning (SFT) แบบดั้งเดิมยังไม่เพียงพอสำหรับงานกฎหมายที่มีความซับซ้อน

GOAL




Verifiable Citations
(การอ้างอิงที่ตรวจสอบได้)



High-Quality Reasoning
(การให้เหตุผลคุณภาพสูง)

GRPO: การปรับแต่งโมเดลด้วยการให้รางวัล



- Concept: แตกต่างจาก SFT ที่สอนแค่ 'คำตอบคืออะไร' GRPO สอนให้โมเดลเรียนรู้ผ่าน 'การให้รางวัล' เมื่อทำตามกฎ
- Mechanism: สร้างคำตอบหลายแบบ -> ให้คะแนน -> ปรับปรุงนโยบายโดยไม่ต้องใช้ Critic Model (PPO) ทำให้ประหยัดทรัพยากร

สมการแห่งความถูกต้อง (The Accuracy Equation)



Format Reward

โครงสร้าง XML ต้องถูกต้อง

```
<reasoning>...  
<answer>...  
<citation>
```


Citation Reward

ต้องไม่ 'หลอน' และอ้างอิงมาตรา
ที่มีอยู่จริงใน Context เท่านั้น



Response Quality


เนื้อหาคำตอบต้องตรงกับ
Ground Truth



การเตรียมการทดลอง (Experimental Setup)


Models (โมเดล)	Training (การเทรน)	Datasets (ชุดข้อมูล)
- Base: Qwen2.5-7B (Generic) - Thai-Specialized: Typhoon2 & OpenThaiGPT 1.5	- SFT (Instruction Tuning) vs. - GRPO (Reinforcement Learning)	- Nitibench-CCL: กฎหมายแพ่งและพาณิชย์ (In-Domain) - Nitibench-Tax: ภาษีอากร (Complex Reasoning)

ความท้าทายเรื่องต้นทุน (The Cost/Quality Dilemma)



Insight: การใช้โมเดลขนาดใหญ่ (72B) เป็นกรรมกรตัดสินมีค่าใช้จ่ายสูงมาก เราจะใช้ 'ความคล้ายคลึงทางความหมาย' (Semantic Similarity) แทนได้หรือไม่?

GRPO ชนะขาดลอยในงาน In-Domain



Key Insight

SFT เพียงอย่างเดียวไม่เพียงพอต่อการบังคับระเบียบวินัยในการอ้างอิงกฎหมาย




พื้นฐานภาษาไทยสำคัญที่สุด (Thai Language Priors are Critical)



Result: Typhoon2 และ OpenThaiGPT ทำผลงานได้ดีกว่า Qwen2.5-7B ในทุกการทดลอง
Insight: GRPO ช่วยเพิ่มประสิทธิภาพการ Sampling แต่โมเดลต้องมีความเข้าใจบริบทภาษาและวัฒนธรรมไทยมาก่อนแล้ว




ประสิทธิภาพที่จับต้องได้ (Tangible Efficiency Gains)




ลดเวลาการเทรนลง 2.5 เท่า และลดต้นทุนกว่า 60% โดยใช้ BGE-M3 แทน LLM Judge

ข้อจำกัดของ Semantic Reward (Limitations of Semantic Rewards)





In-Domain (CCL): ความคล้ายคลึงของ
ประโยคสัมพันธ์กับความถูกต้อง



Complex (Tax): ความสัมพันธ์หายไป—คำตอบที่
'ดูเหมือนถูก' อาจผิดกฎหมายภาษีที่ซับซ้อน

ความซับซ้อนของกฎหมาย (The Complexity of Tax Law)



Insight: งานด้านภาษีต้องใช้การอ้างอิงหลายมาตรา และคำตอบที่ยาวกว่าถึง 8 เท่า



ความสมดุลของรางวัล (The Balance of Rewards)



Takeaway: ต้องปรับจูนทั้ง ‘รูปแบบ’ และ ‘เนื้อหา’ ไปพร้อมกัน



บทสรุปผลการวิจัย (Key Research Findings)

GRPO > SFT

จำเป็นอย่างยิ่งสำหรับ
งานที่ต้องการความ
แม่นยำในการอ้างอิง

Thai Priors

โมเดลพื้นฐานภาษาไทย
(Typhoon/OTG)
สำคัญต่อความสำเร็จ

Cost-Efficiency

Semantic Rewards
ประหยัดต้นทุนได้จริง
สำหรับงานทั่วไป



คำแนะนำสำหรับการนำไปใช้ (Implementation Recommendations)



ใช้ **GRPO** เมื่อต้องการบังคับ **Format XML**
และการอ้างอิงที่เคร่งครัด



ใช้ **Semantic Reward** เพื่อความเร็วในการเทรน
แต่ต้องระวังในงานที่ซับซ้อนสูง



เริ่มต้นด้วย **Thai-Base Model** เสมอ

สู่อนาคต AI กฎหมายไทย (Towards the Future of Thai Legal AI)



การสร้างระบบ AI กฎหมายที่ 'ตรวจสอบได้' 'เข้าถึงได้' และ 'แม่นยำ'
เป็นไปได้จริงด้วยเทคนิคการปรับปรุงที่มีประสิทธิภาพ