

HarnessX: แหล่งกำเนิดของ Evolvable AI Agents


ก้าวข้ามโค้ดที่ตายตัว
สู่สถาปัตยกรรม Agent
ที่ปรับเปลี่ยนและวิวัฒนาการตัวเองได้



คอขวดของการพัฒนา AI Agent ในปัจจุบัน


AI Models มีความฉลาดเพิ่มขึ้นมหาศาล แต่ 'Harness' (ระบบ Prompts, Tools และ Memory) ที่ครอบมันอยู่ยังคงถูกเขียนด้วยมือ ตายตัว และเชื่อมโยงกันอย่างซับซ้อน (Entangled)

ข้อจำกัดปัจจุบัน



- การขยายขนาด Model (Scaling) เพียงอย่างเดียวไม่เพียงพอ
- ประสิทธิภาพ (Traces) ที่ได้จากการทำงานจริงถูกทิ้งไปอย่างเปล่าประโยชน์
- เปลี่ยน Model ใหม่ = ต้องรื้อเขียน Harness ใหม่ทั้งหมด

สถาปัตยกรรมในอุดมคติ




ยกระดับ Harness ให้เป็น 'First-Class Object'

HarnessX เปลี่ยนกระบวนการทัศน์จากการฮาร์ดโค้ด เป็นระบบนิเวศที่วิวัฒนาการได้เองผ่าน 3 เสาหลัก:

1. Compose (ประกอบ)

สร้างสถาปัตยกรรมจากชิ้นส่วนพื้นฐานที่ถอดเปลี่ยนได้ (Pluggable primitives) อย่างอิสระ





3. Evolve (วิวัฒนาการ)

พัฒนาความสามารถของ Model และ Harness ไปพร้อมกันในลูบเดียว

2. Adapt (ปรับตัว)

ค้นหาและปรับโครงสร้าง Harness อัตโนมัติจาก Log การทำงานจริง





			Project number	Revision date
			Drawing title	16:9

สถาปัตยกรรม 9 มิติของ Harness

Harness ไม่ใช่ Spaghetti Code อีกต่อไป แต่เป็น Algebra ของ 9 มิติการทำงานที่เป็นอิสระต่อกัน (Orthogonal) สามารถถอดเปลี่ยนได้เหมือนเลโก้ โดยไม่ทำให้ระบบพัง


1. Model



2. Context



3. Memory



4. Tools



5. Sandbox



6. Reward



7. Control



8. Observe




9. Train



			Project number	Revision
			Drawing title	Revision date

Processor Abstraction การันตีความเสถียรของระบบ

- ทุกพฤติกรรมคือ 'Processor': อ่าน เขียน หรือแปลงข้อมูลเฉพาะจุด
- เชื่อมต่อผ่าน 'Hooks': จุดเชื่อมต่อที่กำหนดจังหวะการทำงานชัดเจน
- Type-Safety ที่เข้มงวด: การันตีว่าเมื่อ AI แก้ไขโค้ด สถาปัตยกรรมหลักจะไม่พังทลาย




	Harness Structure: Architectural Terracotta
	Model/Cognition: Muted Sage Green
	Secondary Structure: Slate Blue

Project number		Revision date	
Drawing title		16:9	

AEGIS: เครื่องยนต์ปรับตัวจากประสบการณ์จริง

Agents พัฒนาตัวเองด้วยการอ่าน Log (Traces) แล้วเขียนตัวเองใหม่ผ่าน 4 ขั้นตอน:



					Project
					Project
					15/9
Revision	Block		Rev	Date	

The Operational Mirror (ทฤษฎีกระจกสะท้อน)

กลไกการวิวัฒนาการ Harness ทำงานเหมือน Reinforcement Learning
แต่เกิดขึ้นใน 'โลกของโค้ด' (Symbolic Space)

Standard RL (การเรียนรู้แบบเสริมกำลังดั้งเดิม)	Symbolic Harness Evolution (การวิวัฒนาการสถาปัตยกรรมโค้ด)
Policy	แผนและกระบวนการอัปเดต Harness
State	โครงสร้างปัจจุบัน + ประวัติการทำงาน (Traces)
Action	การแก้ไขโค้ดและการจัดเตรียม Processor ใหม่
Reward	คะแนนที่ได้จาก Verifier ในการทดสอบ

				Project number	Revision date
				Drawing title	16.8
Revised	Beck		Rev	90c	Dats


เกราะป้องกันความผิดพลาดจากวิวัฒนาการ

เมื่อใช้หลักการ RL ในการแก้โค้ด ย่อมเกิดอาการผิดปกติ (Pathologies) AEGIS จึงมีกลไกป้องกันเฉพาะเจาะจง:

	Reward Hacking (หาช่องโหว่ของคะแนน) ป้องกันโดย Critic ที่ตรวจสอบความสมเหตุสมผลของการได้คะแนน
	Catastrophic Forgetting (ลืมสิ่งที่เคยทำได้) ป้องกันโดย Deterministic Gate (กฎ Seesaw: อัปเดตใหม่ต้องไม่ทำให้งานเก่าพัง)
	Under-exploration (ยึดติดกับวิธีเดิม) ป้องกันโดย Planner ที่คอยกำหนดทิศทางการค้นหาวิธีการใหม่ๆ โครงสร้างใหม่ๆ

Project Number:	Drawing Title:	Revision Date:	Sheet:
AEGIS-EVO-DEF	Evolutionary Safety Mechanisms	20.10	16.8

การแยกสายวิวัฒนาการ (Variant Isolation)



Project Number:

AEGIS-EVO-DEF

Drawing Title:

Variant Isolation and
Ensemble Routing

Revision Date:


20.10

Sheet:

16.8

ทะลุวงขีดจำกัดด้วย Harness-Model Co-Evolution


Harness ที่ดีไม่สามารถแก้ปัญหาให้ Model ที่ไร้ความสามารถ และ Model ที่ฉลาดก็ไร้ค่าหาก Harness ช้อนเครื่องมือไว้
เราต้องวิวัฒนาการทั้ง 'สมอง' และ 'ร่างกาย' ไปพร้อมกัน



Project Number: AEGIS-EVO-DEF	
Drawing Title: Harness-Model Co-Evolution & Ceiling Breakthrough	
Revision Date: 20.10	Sheet: 16.9

The Ultimate Loop (Cross-Harness GRPO)

ข้อมูลจากการทำงานเพียงรอบเดียว สร้างประโยชน์ถึงสองต่อโดยไม่ต้องรันซ้ำ:



Project Number: AEGIS-EVO-DEF	Drawing Title: The Ultimate Loop (Cross-Harness GRPO)
Revision Date: 20.10	Sheet: 16.10


ผลลัพธ์เชิงประจักษ์ (The Proof)

+14.5%

Average Gain ข้าม 5 Benchmarks และ 3 โมเดล

+44.0%

Max Gain (ALFWorld: สภาพแวดล้อมที่ต้องการการวางแผนซับซ้อน)



Baseline


Evolved Harness

ปรับปรุงเสถียรภาพและความแม่นยำได้ทั่วกระโดด
โดยไม่ต้องพึ่งพาการเพิ่มพารามิเตอร์ของโมเดล

Project Number: AEGIS-EVO-DEF		Drawing Title: Performance Proof & Benchmarking	
		Revision Date: 20.10	Sheet: 17.0


กฎการแปรผกผัน (The Inverse Scaling Insight)

สิ่งที่ค้นพบ: 'ยิ่งโมเดลขนาดเล็ก ยิ่งได้ประโยชน์มหาศาล'



Harness ที่ผ่านการวิวัฒนาการแล้ว จะทำหน้าที่อุดช่องโหว่ด้านพฤติกรรม (Behavioral gaps) ที่โมเดลขนาดเล็กไม่สามารถแก้ไขเองได้ ทำให้ Qwen3.5-9B แข่งหน้าข้อจำกัดทางขนาดของตัวเอง

อนาคตของการพัฒนา AI Agent



- ความก้าวหน้าของ AI ไม่จำเป็นต้องผูกติดอยู่กับการขยายขนาด Model เพียงอย่างเดียว
- HarnessX เปลี่ยน ‘ประสบการณ์จากการรัน’ (Experience) ให้กลายเป็น ‘ขีดความสามารถ’ (Capability)
- ระบบที่ประกอบร่างและวิวัฒนาการตัวเองได้ คือกุญแจสำคัญสู่ AI ที่ชาญฉลาดและเสถียรในโลกแห่งความจริง