




Kimi K2.5: ก้าวข้ามขีดจำกัดของ Visual Agentic Intelligence


สถาปัตยกรรมแบบเปิดที่ผสานความสามารถด้านภาพ ภาษา
และการประมวลผลแบบคู่ขนาน (Agent Swarm)

2 เสาหลักแห่งนวัตกรรมของ Kimi K2.5



Joint Optimization of Text and Vision


การประสานการทำงานของภาพและภาษาตั้งแต่เริ่มต้น (Early Fusion) บนโมเดล 15 Trillion tokens เพื่อลดข้อขัดแย้งระหว่างโมดัลลิตี้



Parallel Agent Orchestration

เปลี่ยนผ่านจากการทำงานแบบทีละขั้นตอน (Sequential) สู่การกระจายงานย่อยให้ Sub-agents ทำงานพร้อมกันแบบคู่ขนาน


ประสิทธิภาพระดับแนวหน้าเทียบเท่าโมเดลชั้นนำระดับโลก



Kimi K2.5 ทำคะแนนได้ทัดเทียมหรือเหนือกว่า GPT-5.2 (xhigh), Claude Opus 4.5 และ Gemini 3 Pro ในทุกมิติ

- Agents: ชนขาดลอยใน BrowseComp และ DeepSearchQA
- Coding: นำหน้าใน SWE-bench
- Vision/Video: ครองตำแหน่งสูงสุดใน MMMU Pro และ VideoMMMU

ทลายกำแพงระหว่างภาพและภาษาด้วย Native Multimodal Pre-Training



Early Fusion Strategy

การรวมข้อมูล Vision ในสัดส่วนที่ต่ำตั้งแต่ช่วงต้นของการเทรน ให้ผลลัพธ์ดีกว่าการโหมใส่ข้อมูลในช่วงท้าย

MoonViT-3D Encoder

รองรับความละเอียดภาพแบบ Native ด้วยกลยุทธ Patch n' Pack


Video Compression

บีบอัดเฟรมวิดีโอระดับ Temporal ได้ถึง 4 เท่าโดยแชร์น้ำหนักกับภาพนิ่ง รองรับวิดีโอที่ยาวขึ้น

ปลูกพลังการมองเห็นด้วย Zero-Vision SFT

Zero-Vision SFT

ใช้เพียงข้อมูล Text ล้วน
ในการทำ SFT ก็เพียงพอ
ที่จะกระตุ้นความสามารถ
ด้าน Visual reasoning
และ Tool-use




Bidirectional Enhancement

การทำ Visual RL ไม่ได้ลด
ทอนความสามารถด้านภาษา
แต่กลับช่วยยกระดับคะแนน
Text benchmark:

- MMLU-Pro: เพิ่มขึ้นจาก 84.7% สู่ 86.4%
- GPQA-Diamond: เพิ่มขึ้นจาก 84.3% สู่ 86.4%

ข้อจำกัดของการทำงานแบบลำดับขั้น (The Sequential Bottleneck)



โครงสร้างแบบเดิม

โมเดล Agent ปัจจุบันพึ่งพาการทำงานแบบทีละขั้นตอน (Sequential Execution)


ปัญหาที่พบ

เมื่อความซับซ้อนของงานเพิ่มขึ้น
ระยะเวลา (Inference time) จะ
ขยายตัวเป็นเส้นตรง (Linear
scaling)

ผลลัพธ์

เกิดความล่าช้ามหาศาล ขยับสะสม
จนล้น และกินโควต้า Tool-call
จนหมดก่อนแก้ปัญหาสำเร็จ

ขอแนะนำ Agent Swarm: การกระจายศูนย์งานแบบคู่ขนาน



Orchestrator

ตัวควบคุมที่สามารถวิเคราะห์
แบ่งงาน และสร้าง Subagents
ออกมาจัดการปัญหาย่อย



Frozen Subagents

โมเดลย่อยที่ถูกแช่แข็งค่าน้ำหนัก
(Frozen) ทำหน้าที่รับคำสั่งเฉพาะทาง
ทำงานพร้อมกันหลายสิบตัว

Decoupled Architecture

แยกตรรกะการประสานงานระดับสูง
ออกจากการปฏิบัติงานระดับล่าง
เพื่อลดความสับสนในการให้คะแนน
(Credit assignment) ระหว่างการเทรน

Parallel-Agent Reinforcement Learning (PARL)



Learned Parallelism

โมเดลไม่ได้ถูกบังคับให้ทำงานคู่ขนาน
แต่เรียนรู้ว่า ‘เมื่อใดและอย่างไร’
จึงควรทำผ่าน RL

Critical Steps Metric

ใช้การนับ ‘Critical Steps’ (เส้นทางที่
ยาวที่สุด) แทนการนับจำนวนก้าวทั้งหมด
เพื่อบีบให้โมเดลหาวิธีขนานงานให้เร็วที่สุด

Rewards

ให้รางวัลทั้งจากการสร้าง Subagent
(หลีกเลี่ยง Serial collapse)
และอัตราความสำเร็จของงานย่อย

การสร้างเครือข่าย Subagent ที่เชี่ยวชาญเฉพาะด้าน

Dynamic Instantiation

Subagents ไม่ได้ถูกกำหนดไว้ตายตัว
แต่สร้างขึ้นแบบ Real-time ตามความ
ต้องการของหน้างาน

Proactive Context Management

แทนที่จะตัด Context ทิ้งเมื่อข้อมูลล้น
(Context Truncation) Agent Swarm ใช้วิธี
Context Sharding

Local Memory

Subagent แต่ละตัวมีหน่วยความจำแยกส่วนกัน และส่งกลับเฉพาะผลลัพธ์ที่สำคัญ ทำให้ Orchestrator ไม่สูญเสียความเข้าใจภาพรวม



ปลดล็อกขีดจำกัดความเร็ว: เร็วขึ้นสูงสุด 4.5 เท่า

4.5x

Faster Execution (WideSearch)

17.8%

Performance Jump (BrowseComp)

Latency Reduction


ในงานค้นหาข้อมูลเชิงลึก (WideSearch) Agent Swarm ลดเวลาประมวลผลได้ 3.0x – 4.5x เมื่อเทียบกับ Single-agent ยิ่งโจทย์ยากขึ้น กราฟเวลาของ Single-agent จะพุ่งสูงปรี๊ด ใน Swarm ทำเวลาได้คงที่

BrowseComp Benchmark


- Single-agent (K2.5): 60.6%
- Agent Swarm: 78.4% (สูงกว่า GPT-5.2 Pro ที่ทำได้ 77.9%)

Token-Efficient RL: การใช้ทรัพยากรอย่างคุ้มค่าด้วย Toggle

Performance (%)



Token Usage



Scaling Dilemma

ยิ่งโมเดลคิดนาน (Token มาก) ยิ่งเก่ง
แต่กินทรัพยากรมหาศาล


Toggle Algorithm

สลับเฟสการเทรนระหว่าง 'อนุญาตใช้ Token เต็มที่' กับ 'บังคับให้แก้ปัญหใน Token จำกัด (Budget-constrained)'

ผลลัพธ์

ลดจำนวน Token ขาดออกได้ 25-30% โดยที่ประสิทธิภาพ (Accuracy) ของโมเดลไม่ลดลง และขจัดพฤติกรรมกรออธิบายซ้ำซ้อน

เบื้องหลังความสำเร็จ: สถาปัตยกรรม Unified Agent RL



- **Massive Concurrency**

รองรับการทำ Agent tasks พร้อมกันถึง 100,000 งาน ผ่านมาตรฐาน Gym-like interface

- **Decoupled Encoder Process (DEP)**

แยกส่วนการประมวลผล Vision ออกจากแกนหลักของ Text

- **90% Efficiency**

รีดประสิทธิภาพการเทรนแบบ Multimodal ได้สูงถึง 90% เมื่อเทียบกับการเทรน Text เพียงอย่างเดียว ช่วยลดคอขวดของหน่วยความจำ

ความสามารถด้านตรรกะ และการเขียนโค้ดระดับโลก

96.1%

AIME 2025

เหนือกว่า Claude Opus
4.5 (92.8%) และ
Gemini 3 Pro (95.0%)

76.8%

SWE-Bench Verified

แสดงถึงความสามารถระดับ
Software Engineer
ในการแก้ไข Bug บน
Repository จริงที่ซับซ้อน

50.2%

HLE-Full (w/ tools)

คะแนนสูงสุดในฝั่งข้อสอบ
คะแนนสูงสุดในฝั่งข้อสอบ
Humanity's Last Exam
เมื่ออนุญาตให้ใช้เครื่องมือ

ความเข้าใจภาพ วิดีโอ และการสั่งงานคอมพิวเตอร์แบบก้าวกระโดด



Vision (MMMU-Pro: 78.5%)

เข้าใจเอกสาร ชอร์สโค้ด กราฟ และ OCR แบบหลายหน้าต่าง
ได้อย่างแม่นยำ (OCRBench 92.3%)



Long Video (LongVideoBench: 79.8%)

รองรับการป้อนเฟรมภาพกว่า 2,000 เฟรม
เพื่อทำความเข้าใจวิดีโอขนาดยาวระดับชั่วโมง



Computer Use (OSWorld-Verified: 63.3%)

ควบคุม GUI ตั้งแต่เริ่มของระบบปฏิบัติการได้เหนือกว่า OpenAI
Operator (42.9%) และก้าวทัน Claude Opus 4.5

ผลิตภัณฑ์วงการสู่ General Agentic Intelligence อย่างเปิดเผย



Kimi K2.5 พิสูจน์ให้เห็นว่าปัญญาประดิษฐ์ระดับแนวหน้า สามารถสร้างได้ด้วยการรวมพลังระหว่าง Vision-Language และ Agent Swarm

Open-Source Release: ปล่อย Checkpoint ของ Kimi K2.5 ให้กับนักวิจัยและนักพัฒนาทั่วโลกนำไปต่อยอด

มาร่วมกันพัฒนาระบบนิเวศ Agent ที่ทำงานคู่ขนานและรองรับสเกลขนาดใหญ่ เพื่ออนาคตของ AI ที่ทุกคนเข้าถึงได้