


LLM2VEC-GEN: Generative Embeddings

กระบวนการทัศน์ใหม่ของการสร้าง Text Encoders ผ่าน Frozen LLMs




เปลี่ยนการเข้ารหัส "คำถาม" สู่การเข้ารหัส "คำตอบ"
เพื่อพื้นที่แฝง (Latent Space) ที่โปร่งใสและทรงพลัง

ปัญหาหลัก: ช่องว่างระหว่าง Input และ Output


Encoders แบบดั้งเดิมมุ่งเน้นที่การเข้ารหัส ****Input**** ทำให้ยากต่อการเชื่อมโยงคำถามที่หลากหลายเข้าหาเป้าหมายเดียวกันโดยปราศจากข้อมูลจับคู่ (Paired Data) จำนวนมหาศาล

The Problem



Input-Centric (Traditional): คำถามที่แตกต่างกันถูกวางไว้ห่างกันใน Vector Space

The Solution



Response-Centric (The Solution): คำตอบของ LLM ต่อคำถามเหล่านั้น มักจะมีจุดร่วมที่ใกล้เคียงกันเสมอ

การเปลี่ยนกระบวนทัศน์ (The Paradigm Shift)

	Traditional (Input-Centric)	LLM2VEC-GEN (Response-Centric)
สิ่งที่ถูกเข้ารหัส (What it Encodes)	ตัวคำถาม (The Query)	คำตอบที่อาจเกิดขึ้น (The Potential Response)
ข้อมูลที่ต้องการ (Data Needs)	ข้อมูลจับคู่ (Paired Data) ที่มี Labeled ชัดเจน	คำถามที่ไม่มี Label (Unlabeled Queries) ผ่าน Self-supervised learning
ขีดความสามารถ (Capabilities)	การจับคู่ความหมายพื้นฐาน (Semantic Matching)	• สืบทอดการใช้เหตุผล (Reasoning) • และความปลอดภัย (Safety) จาก LLM

แนะนำ LLM2VEC-GEN

สกัด 'คำตอบ' ของ LLM ให้อยู่ในรูปของ Latent Tokens
โดย **ไม่มีการสร้างข้อความ (Text Generation)** เกิดขึ้นจริงในขั้นตอน Inference




1. Frozen LLM Backbone:
โมเดลภาษาหลักไม่มีการ
เปลี่ยนแปลงน้ำหนัก (Weights)

2. Trainable Special Tokens:
เพิ่ม Token พิเศษที่ต่อท้ายคำถาม
เพื่อทำหน้าที่เป็น 'ตัวรับ'
ความหมายของคำตอบ

3. Single Forward Pass:
ทำงานรวดเร็วเทียบเท่า Encoder
ทั่วไป แต่ได้มีความหมายระดับ
LLM

กลไกการทำงาน - ขั้นตอนที่ 1: การสร้างเป้าหมาย (Preparation & Distillation)



****สร้างคำตอบ:****

ใช้ Frozen LLM ตอบคำถามที่ไม่มี Label
(เช่น จากชุดข้อมูล Tulu)


****สร้าง Embedding เป้าหมาย:****

นำคำตอบที่ได้ไปผ่านโมเดล 'Teacher Encoder'
(LLM2Vec) แบบ Unsupervised

ผลลัพธ์ที่ได้คือ Vector อ้างอิงที่บรรจุ 'ความหมายที่สมบูรณ์' ของคำตอบนั้นๆ เพื่อใช้เป็นเป้าหมายในการฝึกสอน

กลไกการทำงาน - ขั้นตอนที่ 2: คอขวดแห่งความหมาย (The Latent Bottleneck)

เราฉีด 'Special Tokens' จำนวน 20 ตัว เข้าไปใน Vocabulary ของโมเดล โดยแบ่งหน้าที่การทำงานอย่างชัดเจน:



Thought Tokens (t1-t10): ทำหน้าที่เป็นพื้นที่พักข้อมูล (Computational Buffer) ให้โมเดลประมวลผล

Compression Tokens (c1-c10):
ทำหน้าที่ดักจับและบีบอัดใจความสำคัญของคำตอบ
ทั้งหมดให้อยู่ในรูปแบบ Vector


เครื่องยนต์ Dual-Objective

เราอัปเดตน้ำหนักเฉพาะ Special Tokens ผ่าน 2 ฟังก์ชัน Loss ควบคู่กัน:



1. Alignment Loss:*

บังคับให้ Vector ของ
Compression Tokens มีค่าตรงกับ
Target Embedding ของ Teacher
(เรียนรู้ความหมายที่บริสุทธิ)



2. Reconstruction Loss:*

บังคับให้โมเดลสามารถสร้างข้อความ
คำตอบเต็มคำตอบ ข้อความคำตอบ
นภาคเดิมกลับมาได้จาก Tokens เหล่านี้
(ยึดโยง Vector ไว้กับภาษามนุษย์)

บทพิสูจน์เชิงประจักษ์: มาตรฐานใหม่บน MTEB (SOTA)

62.1


คะแนนเฉลี่ย Qwen-3-8B
(สถิติใหม่สำหรับ Self-Supervised Models)

+9.3%

Performance Delta
(เอาชนะ Teacher Model ที่ดีที่สุดได้อย่างขาดลอย)

+23.9%

Clustering Gap
(ประสิทธิภาพเพิ่มสูงสุดในงานจัดกลุ่มที่อิงผลลัพธ์)



****Key Takeaway:**** LLM2VEC-GEN ทำหน้าที่เป็น 'Performance Equalizer' ยกระดับประสิทธิภาพได้อย่างก้าวกระโดดในทุกขนาดโมเดล

การสืบทอดความปลอดภัย: AdvBench-IR



ปัญหา:

Encoders ดั้งเดิมมักเข้ารหัส 'เจตนาร้าย' ของผู้ใช้ ทำให้ดึงข้อมูลที่เป็นอันตรายออกมา

ข้อได้เปรียบของ LLM2VEC-GEN:

เข้ารหัส '**การปฏิเสธของ LLM**' (เช่น 'ฉันไม่สามารถช่วยเรื่องนี้ได้') ทำให้ Vector ทนทานต่อการโจมตี (Adversarial Attacks) โดยธรรมชาติ

-43.2%

ลดการดึงข้อมูลที่เป็นอันตรายได้สูงสุดถึง 43.2% (ในรุ่น 1.7B)


การสืบทอดการใช้เหตุผล: BRIGHT Benchmark

การจับคู่ข้อความพื้นฐานไม่เพียงพอสำหรับคำถามที่ซับซ้อน (เช่น ชีววิทยา, การเขียนโค้ด) LLM2VEC-GEN ถึงความสามารถในการใช้เหตุผลเชิงตรรกะของ LLM มาสู่ Vector เดียว

Scaling Insight:: ยิ่งโมเดลมีขนาดใหญ่ ความสามารถในการให้เหตุผลในพื้นที่แฝงยิ่งเพิ่มทวีคูณ

+29.3%

ประสิทธิภาพในงานที่ต้องใช้เหตุผลเพิ่มขึ้น (ในรุ่น 8B) เทียบกับ Teacher Baseline



เลนส์เอ็กซ์เรย์: ความสามารถในการอธิบาย (Interpretability)



ข้อมูลเชิงลึกด้านสถาปัตยกรรม (Ablations)




จำนวน Tokens ที่เหมาะสม:

การใช้ 20 Special Tokens (10 Thought + 10 Compression)
คือจุดสมดุลที่ดีที่สุดระหว่าง
ประสิทธิภาพและความหนาแน่น
ของข้อมูล



การแช่แข็ง (Freezing) ดีกว่า:

การคงสภาพ LLM Backbone ไว้
(Frozen) ให้ผลลัพธ์ดีกว่าการทำ
LoRA Fine-tuning แล้วยังลด
ภาระการประมวลผล



Synergy ของ Teacher:

การใช้ Teacher Model ที่มาจาก
ตระกูลเดียวกัน (In-family) กับ
LLM ให้ประสิทธิภาพ
Embedding สูงสุด

บทสรุป: ทำไมกระบวนการนี้ถึงเหนือกว่า

ประสิทธิภาพพารามิเตอร์สูง:
ฝึกสอนเฉพาะ Special Tokens
หลักสิบล้านพารามิเตอร์
ไม่ต้องแตะต้องโมเดลหลัก

ไม่พึ่งพา Labeled Data:
ใช้งานได้ทันทีกับ Unlabeled Queries
ลดต้นทุนการเตรียมข้อมูลมหาศาล

LLM2VEC-GEN

สืบทอดความฉลาดและความปลอดภัย:
ยกเครื่องความสามารถในการให้เหตุผล
และการป้องกันตัวเองของ LLM มาสู่
พื้นที่ Vector

ความเร็วระดับใช้งานจริง:
เข้ารหัสทั้งหมดจบใน Single Forward
Pass ไม่ต้องเสียเวลา Generate
ข้อความ

พรหมแดนในอนาคต (Future Frontiers)

Full JEPA:

การกำจัด External Teacher โดยให้ LLM ทำหน้าที่เป็นทั้งผู้สร้างและผู้ประเมินในตัวเองอย่างสมบูรณ์

Latent Chaining:

การให้เหตุผลหลายขั้นตอน (Multi-step Reasoning) ผ่าน Latent Space โดยตรงข้ามขีดจำกัดความล่าช้าของ Autoregressive Decoding

Agent Communication:

บอกสื่อสารกันด้วย Dense Latent Tokens ที่มีความหนาแน่นสูง แทนการใช้ข้อความแบบเดิม เพื่อเพิ่มความเร็วและประสิทธิภาพของระบบ Multi-agent