


Mamba-3: สถาปัตยกรรม State Space Model ที่ออกแบบเพื่อการอนุมาน

ทำลายข้อจำกัดของ Memory-Bound Decoding
ด้วย MIMO และ Kernels ระดับฮาร์ดแวร์




การเปลี่ยนผ่านเข้าสู่ยุค Inference-Heavy




เมื่อคอขวดของระบบย้ายมาอยู่ที่การอนุมาน (Inference) อย่างสมบูรณ์ โมเดล SSM ที่ถูกออกแบบเพื่อ Inference ตั้งแต่ต้นจะมีหน้าตาเป็นอย่างไร?

ปัญหาทางโครงสร้าง: ข้อจำกัดของ Fixed State



หน่วยความจำขยายตัวตามความยาว (Exact Storage)




บีบอัดข้อมูลอดีตทั้งหมดลงใน State ขนาดคงที่

จุดเด่นของ Linear Models คือการประมวลผลที่แปรผันตรง (Linear)
แต่ต้องแลกมากับข้อจำกัดในการจำข้อมูลแบบแม่นยำ (Exact Retrieval)
คำถามคือ: เราจะทำให้ Fixed State ที่มีอยู่ ทำงานได้อย่างมีประสิทธิภาพสูงสุดได้อย่างไร?


คอขวดของการอนุมาน (The Inference Bottleneck)

โหมด Training

Tensor Core Compute




Memory I/O




GPU ทำงานเต็มประสิทธิภาพในการคำนวณ

โหมด Inference Decoding

Tensor Core Compute




Memory I/O



GPU ว่างงานจากการคำนวณ แต่คอขวดอยู่ที่การรอเคลื่อนย้ายข้อมูลจากหน่วยความจำ (Memory-Bound)

ทางออกของ Mamba-3: เพิ่มปริมาณงานแบบคู่ขนาน (Parallel Work) และความซับซ้อนทางคณิตศาสตร์เข้าไปในการอัปเดตแต่ละ Token เพื่อใช้ประโยชน์จาก Compute ที่ว่างอยู่ โดยดึงข้อมูลจากหน่วยความจำเท่าเดิม

3 นวัตกรรมหลักของ Mamba-3




01 EXP-TRAPEZOIDAL RECURRENCE

สูตร Recurrence แบบใหม่ที่มีความซับซ้อนและยืดหยุ่นมากขึ้น เพิ่มศักยภาพในการแสดงออก (Expressivity) ของกลไก SSM



02 COMPLEX-VALUED SYSTEM

ขยายขีดความสามารถในการจัดเก็บสถานะ (State-tracking) ด้วยการจำลองระบบ SSM ในรูปแบบ Complex-valued ผ่านโมดูล RoPE



03 MULTI-INPUT, MULTI-OUTPUT (MIMO)

รันหลาย SSM คู่ขนานกัน เพิ่มประสิทธิภาพความแม่นยำสูงขึ้นโดยไม่กระทบความเร็วในการทำ Decode Latency

MAMBA-3 CORE ARCHITECTURE

ผ่าสถาปัตยกรรม: Mamba-2 vs. Mamba-3

COMPONENT	MAMBA-2	MAMBA-3
Primary Goal	Training Speed	Inference Efficiency
Normalization	RMSNorm	QKNorm (BCNorm) - เพิ่มความเสถียรในการฝึกสอน
Short Convolution	External (Essential)	Removed (Implicit via Recurrence)
Output Geometry	Single-Input, Single-Output (SISO)	SISO หรือ MIMO (ทางเลือก)
Network Structure	Pure Linear Layers	Interleaved MLP Layers (ตามมาตรฐาน LLM ยุคใหม่)


บทกลา Short Convolution

The Short Conv X-Ray

ยุค Mamba-1/2

~~External Short Causal Conv~~

เคยเป็นหัวใจสำคัญสำหรับการทำ Induction-style Retrieval



โครงสร้าง Mamba-3

Mamba-3 SSM Block

B/C Biases
(หลัง BCNorm)

Exponential-
Trapezoidal
Recurrence


ทำงานร่วมกันเป็น
Implicit
Convolution
ภายในตัวอัปเดต
State โดยตรง

Note: การนำ External Short Conv กลับมาใส่ใน Mamba-3 ไม่ได้ช่วยเพิ่มประสิทธิภาพ และกลับทำให้ผลลัพธ์โดยรวมลดลงเล็กน้อย


พลังของการประมวลผลแบบขนาน (Enter MIMO)

SISO vs. MIMO Flow Comparison

SISO (Single-Input, Single-Output)



MIMO (Multi-Input, Multi-Output, $r=4$)



The Paradox of MIMO


ฝั่ง Training	ฝั่ง Inference
 จำนวนพารามิเตอร์เพิ่มขึ้น ส่งผลให้ใช้เวลาและทรัพยากรในการ ฝึกสอน (Compute) นานขึ้น	 ความเร็ว (Latency) แทบไม่ลดลง!

กลไกการทำงาน: เนื่องจากกระบวนการ Decode เป็น Memory-bound และมี Tensor Cores ที่ว่างงานอยู่จำนวนมาก MIMO จึงนำ Compute ที่เพิ่มขึ้นไปใส่ใน Cores ที่ว่างเหล่านั้น (Almost Free Work)

ผลลัพธ์ด้านภาษา: ก้าวข้ามขีดจำกัดเดิม

- • Mamba-3 (SISO) ให้ผลลัพธ์เหนือกว่าสถาปัตยกรรม Linear Model ชื่อนำอย่าง Mamba-2 และ Gated DeltaNet (GDN) อย่างชัดเจน ภายใต้เงื่อนไขโครงสร้างและเวลาเทรนที่เท่ากัน
- • Mamba-3 (MIMO) ยกกระดับความแม่นยำขึ้นไปอีกขั้น เพิ่ม Accuracy ในงาน Downstream มากกว่า 1% เมื่อเทียบกับรุ่นปกติ
- • การปรับโครงสร้างเพื่อ Inference ไม่ได้ทำให้คุณภาพของโมเดลลดลง แต่กลับเพิ่มความแม่นยำบนรากฐานคณิตศาสตร์ที่แข็งแกร่งขึ้น

Language Modeling Downstream Language Modeling Downstream
Performance (1.5B Scale)




สถิติความเร็วสูงสุด: Prefill + Decode Latency

ระยะเวลาทำการ (วินาที) บนชิปเดียว H100-SXM 80GB (1.5B Scale)

Model	n=512	1024	2048	4096	16384
vLLM (Llama-3.2-1B)	4.45	9.60	20.37	58.64	976.50
Gated DeltaNet	4.56	9.11	18.22	36.41	145.87
Mamba-2	4.66	9.32	18.62	37.22	149.02
Mamba-3 (SISO)	4.39	8.78	17.57	35.11	140.61
Mamba-3 (MIMO r=4)	4.74	9.48	18.96	37.85	151.81

Mamba-3 (SISO) ครองแชมป์ความเร็วในทุกระดับ Sequence Length
เอาชนะแม้กระทั่ง Transformer ที่ปรับแต่งมาอย่างดีด้วยระบบ vLLM


บทสรุปย่ออนาคต: สถาปัตยกรรม Hybrid



ความจริงที่หลีกเลี่ยงไม่ได้คือ Linear Models มีประสิทธิภาพเป็นรอง Transformer ในงานประเภท Exact Retrieval การผสมผสานสถาปัตยกรรมทั้งสองเข้าด้วยกันจึงเป็นคำตอบแห่งอนาคต

เจาะลึกสถาปัตยกรรมระดับฮาร์ดแวร์ (The Kernel Stack)

ความเร็วระดับแนวหน้าไม่ได้มาจากอัลกอริทึมเท่านั้น แต่มาจากการรีดประสิทธิภาพฮาร์ดแวร์ผ่าน 3 ภาษาหลักที่ผสานการทำงานร่วมกัน:



บทสรุป และ การต่อยอด



อัปเดตโครงสร้างคณิตศาสตร์

แก้ไขปัญหาคอขวดด้วย Exponential-trapezoidal, Complex-valued และสถาปัตยกรรม MIMO



ความเร็วสูงสุดในการอนุมาน

พิสูจน์ด้วยสถิติ Prefill+Decode บน 1.5B Scale ที่เอาชนะทุก Linear Models และ Llama-3.2



Hardware-Optimized

เข้าถึงฮาร์ดแวร์ระดับลึกสุดผ่าน Open-source Kernels (Triton, TileLang, CuTe)

- > อัปเดตเวิร์กโฟลว์ AI ของคุณได้แล้ววันนี้
- > GitHub: `mamba-ssm`
- > Read the full paper: 'Mamba-3'
- > Status: Inference-Ready