


แกะรอยวิวัฒนาการ ความหมายของภาษา ผ่านข้อมูลระดับโลก


การทำแผนที่การเปลี่ยนแปลงความหมาย
ทางคำศัพท์ (Lexical Semantic Change)
ด้วยคลังข้อมูล DHPLT ใน 41 ภาษา

Mariia Fedorova | Andrey Kutuzov | Khonzoda Umarova




คำว่า "AI" ไม่ได้มีความหมายเหมือนเดิมเสมอไป


ยุคปัจจุบัน (2024):
โมเดลภาษาขนาดใหญ่
และ Generative AI



ยุคเปลี่ยนผ่าน (2020-2021):
ขยับสู่หุ่นยนต์และการ
เรียนรู้ของเครื่องจักร




ยุคแรก (2011-2015):
ผูกติดกับตัวละครในวิดีโอเกมและแอนิเมชัน



ภาษาเติบโตและปรับตัวตามโลก
คำถามคือ: เราจะติดตามการเปลี่ยนแปลงนี้
อย่างเป็นระบบในทุกภาษาทั่วโลกได้อย่างไร?

ขอบเขตของงานวิจัยการเปลี่ยนแปลงทางความหมาย (LSCD)



แนะนำ DHPLT: คลังข้อมูลตามช่วงเวลาขนาดมหึมา

41

ภาษา

(ครอบคลุม 12 ตระกูลภาษาหลัก)

59

พันล้านคำ

(จากการสกัดข้อมูลเว็บคุณภาพสูง)

3

ห้วงเวลาสำคัญ

(1 ล้านเอกสารต่อช่วงเวลา
สำหรับแต่ละภาษา)

DHPLT (Diachronic HPLT) คือชุดคลังข้อมูลเปิดที่สร้างขึ้นจาก HPLT v3.0 เพื่ออุดช่องโหว่ของการขาดแคลนข้อมูลในงานวิจัย LSCD แบบหลายภาษา

พลิกโฉมคลังข้อมูล: จดหมายเหตุแบบดั้งเดิม vs ข้อมูลเว็บ (DHPLT)

มิติการเปรียบเทียบ	คลังข้อมูลประวัติศาสตร์ดั้งเดิม	DHPLT (ข้อมูลสกัดจากเว็บ)
แหล่งที่มา	เอกสารสิ่งพิมพ์, หอสมุดแห่งชาติ	เอกสารบนเว็บผ่าน HPLT v3.0
ความครอบคลุมของภาษา	กระดูกตัวแค่มือ (High-resource)	41 ภาษา (ครอบคลุมภาษาที่มีทรัพยากรน้อย)
ความแม่นยำของเวลา	วันที่สร้างเอกสารแน่นอน (Exact)	ขอบเขตบน (Upper Bound) อิงจากเวลาที่ดึงข้อมูล
การเข้าถึง	ลิขสิทธิ์ซับซ้อน, กระจาย	สิทธิ์ CC0 (รวบรวมไว้ทีเดียว)

แม้ความแม่นยำของเวลาจะลดลงเชิงสัมพัทธ์ แต่สิ่งที่ได้กลับมาคือ ‘สเกล’
ระดับมหาศาลที่เปิดประตูสู่งานวิจัยในภาษาที่ไม่เคยทำได้มาก่อน

กุญแจสำคัญ: การใช้เวลาดึงข้อมูล (Crawl Time) เป็น 'ขอบเขตบน'



บทพิสูจน์เชิงตรรกะ แม้เราจะไม่รู้วันที่สร้างที่แท้จริง แต่เราเชื่อมั่น
ว่าเอกสารนี้ไม่มีทางถูกสร้างหลังปี 2015 (Upper Bound Guarantee)

ดังนั้น ชุดข้อมูลของช่วงเวลาที่เก่าที่สุด จะไม่มีเอกสารจากอนาคตหลุดเข้าไปปะปนเด็ดขาด

3 ห้วงเวลาสำคัญ: ข้ามทศวรรษของการเปลี่ยนแปลง

ยุคเริ่มต้น (2011-2015): รวบรวมข้อมูลในช่วงแรกสุดของระบบ มีข้อมูลค่อนข้างน้อยจนถึงปี 2017

ยุคโควิด-19 (2020-2021): ช่วงเวลาที่มีการเปลี่ยนแปลงทางสังคมและภาษาอย่างฉับพลัน พร้อมปริมาณเอกสารที่พุ่งสูงขึ้น

ยุคปัจจุบัน (2024): ภาพสะท้อนของการใช้งานภาษาในยุค AI และเทคโนโลยีล่าสุด

การเว้นระยะห่างระหว่างแต่ละช่วงเวลา (อย่างน้อย 2 ปี) ช่วยให้โมเดลสามารถตรวจจับ 'นวัตกรรมทางภาษา' ได้ชัดเจนยิ่งขึ้น

ทลายข้อจำกัดด้านภาษาด้วยความหลากหลาย 41 ภาษา



เกณฑ์การคัดเลือกภาษา:

1. ต้องมีเอกสารอย่างน้อย 0.5 ล้านฉบับในทุกช่วงเวลา
2. ต้องมีโมเดล HPLT v3.0 T5 รองรับ

ครอบคลุม 12 ตระกูลภาษาหลักทั่วโลก

English (eng_Latn)
Spanish (spa_Latn)
Thai (tha_Thai)
Georgian (kat_Geor)
Tamil (tam_Taml)
Russian (rus_Cyrl)

**นี่ไม่ใช่แค่ข้อมูลสำหรับภาษาฟังตะวันตก
แต่ครอบคลุมสคริปต์และโครงสร้างไวยากรณ์ที่แตกต่างกันทั่วโลก**


สถาปัตยกรรมการสกัดข้อมูล: จากมหาสมุทรเว็บสู่คลังข้อมูลเฉพาะเจาะจง

1. HPLT v3.0 ขั้นต้น




- ข้อมูลดิบ 198 ภาษา
- ขนาดมหึมาถึง 50 TB

2. กระบวนการสุมและคัดกรองเวลา



- ดึงเฉพาะ 41 ภาษาเป้าหมาย
- สุม 1 ล้านเอกสารต่อช่วงเวลา

3. DHPLT Corpora



- ไฟล์ JSONL บีบอัดด้วย zstd
- ขนาดเหลือ 170 GB (59 พันล้านคำ)

สถาปัตยกรรมนี้เปิดเผย Source Code เพื่อให้นักวิจัยสามารถสร้าง Subsets ตามความต้องการเฉพาะของตนเองได้


การคัดกรองคำเป้าหมาย (Target Words) สำหรับแบบจำลอง

ฐานคำศัพท์ (T5 Vocabulary):
เริ่มต้นจากคำศัพท์ในโมเดล T5

การคัดกรองประเภทคำ:
ใช้ Stanza และ ClassIa คัดเฉพาะ
คำนาม, คำกริยา, คำคุณศัพท์

การกรองความถี่และสคริปต์:
คัดคำที่ปรากฏน้อยกว่า 10 ครั้งทั้ง
และตัดอักขระข้ามสคริปต์

ได้คำเป้าหมายเฉลี่ย 18,600 คำต่อภาษา
(พร้อมทำ Lemmatization)



กล่องเครื่องมือสำหรับนักวิจัย: โมเดลตัวแทนความหมายพร้อมใช้งาน



Contextualized Embeddings


เวกเตอร์ระดับ Token จาก T5, XLM-R, และ GPT-BERT เพื่อจับความหมายตามบริบทย่อย (100-1000 ตัวอย่างต่อคำ)



Lexical Substitutes



การหาคำทดแทนด้วย GPT-BERT (Top-15) เพื่อชี้วัดการเปลี่ยนแปลงผ่านคำใกล้เคียง



Static Embeddings (SWE)

โมเดล Word2Vec แบบดั้งเดิม (SGNS) ที่ Alignment ด้วยเทคนิค Procrustes เพื่อเปรียบเทียบข้ามเวลาได้โดยตรง

Frequency Counts



ข้อมูลความถี่ของคำตลอด 3 ช่วงเวลา เพื่อควบคุมตัวแปรและรองรับกฎของ Zipf

DHPLT ประหยัดทรัพยากรการประมวลผลมหาศาล โดยเตรียม Representation เหล่านี้ให้พร้อมสำหรับการ Evaluate กันที่

บทพิสูจน์ที่ 1: เส้นทางความหมายของ "AI" ใน 3 ภาษา

2011-2015

2020-2021

2024

Track 1 (English: "AI")

NPCs, multiplayer, animations → chatbots, IoT, robotics → ChatGPT, generative, LLMs

Track 2 (Spanish: "IA")


jugabilidad (gameplay), BETA, PS → algoritmos, tecnología, learning → generativa, ChatGPT

Track 3 (Russian: "ИИ")

[ไม่มีข้อมูลมากพอในยุคนี้] → интеллект (intellect), роботов, блокчейн → нейросети (neural networks), ChatGPT, алгоритмы

การเปลี่ยนแปลงของเทคโนโลยีถูกสะท้อนผ่านโครงสร้างทางความหมายแบบคั่งงนนานในภาษาที่แตกต่างกันโดยสิ้นเชิง

บทพิสูจน์ที่ 2: ร่องรอยของโรคระบาดในคำว่า 'Remote'



กรอบการวิจัยและข้อจำกัดที่ต้องตระหนัก



1. กฎของขอบเขตบน (Upper Bound Rule)

เอกสารที่มี Timestamp ปี 2024 อาจมีข้อความที่ถูกเขียนขึ้นตั้งแต่ปี 2005 ปะปนอยู่ เนื่องจากความแม่นยำด้านเวลาเป็นแบบอสมมาตร



2. ความจำกัดของเป้าหมาย (Target Constraints)

โมเดลตัวแทนความหมายที่จัดเตรียมไว้ให้ ครอบคลุมเฉพาะกลุ่ม Target Words ที่คัดกรองแล้ว (เฉลี่ย 18,600 คำต่อภาษา) ไม่ได้ครอบคลุมทุกคำในพจนานุกรม



3. การพยากรณ์ข้ามเวลา (Temporal Anachronism)

โมเดลไม่ได้ผูกกับเวลา การพยากรณ์คำในข้อมูลปี 2011 อาจสร้างคำพยากรณ์ที่เป็นชื่อเฉพาะซึ่งเพิ่งเกิดในปี 2024 ออกมาได้

คำแนะนำ: งานวิจัยในอนาคตควรคำนึงถึงบริบทเวลาในขั้นตอนการ Pre-train โมเดลเพื่อความแม่นยำสูงสุด

DHPLT: ทรัพยากรเปิดสำหรับการค้นพบครั้งต่อไปของคุณ

- ทลายกำแพงข้อจำกัดของกลุ่มภาษา High-resource
- คลังข้อมูลตามช่วงเวลาขนาดใหญ่ที่สุดที่เปิดให้ใช้งานฟรี (41 ภาษา)
- เครื่องมือตั้งต้นแบบครบวงจรจัดการการประมวลผลซ้ำซ้อน



เข้าถึงข้อมูลเชิงประวัติศาสตร์ 59 พันล้านคำ ได้แล้ววันนี้ที่:
<https://data.hplt-project.org/three/diachronic/>
Licensed under Creative Commons CC0