





MEMENTO: สอนให้ LLM จัดการ Context ของตัวเอง

นวัตกรรมการบีบอัด Reasoning Blocks เพื่อลดการใช้ KV Cache 2.5 เท่า โดยไม่สูญเสียความแม่นยำ

ภาพจำลองปัญหา (Visual Problem Metaphor)



วิกฤตหน่วยความจำ: เมื่อนักคิดไม่มีระบบจัดระเบียบ

โมเดลสาย Reasoning ในปัจจุบัน (เช่น OpenAI o1, DeepSeek-R1) สร้าง Chain-of-Thought (CoT) ความยาวหลักหมื่น Token ซึ่งเป็นสายข้อมูลที่แบนราบและไร้โครงสร้าง

คอขวดสำคัญ (Key Bottlenecks)


- ❑ **ไร้กลไกการคัดกรอง:** Token ในอดีตทุกตัวอยู่ใน Attention Window ด้วยต้นทุนที่เท่ากันหมด
- ❑ **ไม่รู้จักรงการจดสรุป:** โมเดลไม่มีระบบลบข้อมูลที่ไม่ได้ใช้งานแล้วทิ้งไป

LLM ยุคปัจจุบันคิดเก่งขึ้น แต่ขาดสถาปัตยกรรมในการบริหารจัดการความจำระหว่างทาง

MEMENTO: โมเดลที่รู้จัก ‘ย่อความ’ ระหว่างทาง


1. Segment (แบ่งบล็อก)

แบ่งการคิดเป็นก้อนที่จบในตัว




2. Compress (บีบอัด)

สรุปผลลัพธ์และสมการสำคัญ
ไว้ใน Memento




3. Mask (ปิดบังอดีต)

กากบาททิ้งและทำเบลอก้อน
ความคิดเดิมในระดับ Attention



จากสายน้ำข้อมูลที่ยาวไร้ที่สิ้นสุด สู่ ‘ตู้คอนเทนเนอร์’ ที่ถูกแพ็คเรียบร้อยและมีป้ายสรุปแปะไว้ด้านหน้า
ระบบจึงเคลียร์ของชิ้นใหญ่ออกไปได้

Paradigm Shift: สู่ยุคของ *Self-Managed Context*

มิติการเปรียบเทียบ (Dimension)	Standard CoT	MEMENTO
โครงสร้างความคิด (Structure)	✗ แบบราบ, ไร้รอยต่อ (Unstructured Stream)	✓ แบ่งเป็นบล็อก, มีระบบสรุป (Segmented & Summarized)
การใช้หน่วยความจำ (Peak KV Cache)	✗  พุ่งสูงขึ้นเป็นเส้นตรง (O(N) Growth)	✓  กราฟฟันปลา ประหยัดพื้นที่ได้ถึง 2.5 เท่า
รูปแบบความสนใจ (Attention)	✗  Full Causal Attention (ดูข้อมูลทุกอย่างในอดีต)	✓  Sparse Attention (ดูเฉพาะ Memento และ Block ปัจจุบัน)
ความสามารถในการอธิบาย (Interpretability)	✗ ต้องไล่อ่านย่อหน้ายาวที่ซับซ้อน 	✓ ย่อง่าย สรุปผลเป็นสัดส่วนด้วยภาษาธรรมชาติ 

OpenMementos Dataset: จากความคิดที่ยุ่งเหยิงสู่โครงสร้างที่เป็นระบบ

กระบวนการสร้างชุดข้อมูล 228K Traces จาก OpenThoughts-v3

1. Sentence Splitting

ซอย CoT เป็นประโยคย่อยๆ
ที่สมบูรณ์ในตัว



2. Boundary Scoring


ให้คะแนน 'จุดตัด' โดย LLM Judge
(0=กลางประโยค, 3=เปลี่ยนหัวข้อชัดเจน)

Boundary scoring example — complex-plane geometry trace

[177]	"Hence, this approach again leads to the only solution being zero."	0.0
[178]	"Therefore, unless I made a mistake ... the answer is the trivial solution."	1.5
[179]	"Perhaps the problem's answer is indeed zero, so the distance is zero."	2.0
[180]	"Alternatively, maybe I made an error in interpretation."	3.0
[181]	"Let me check with an example."	0.5
...	...	...
[185]	"Suppose I take $r=2$. Then $u=5$, $v=\pm\sqrt{7}$..."	0.0
[186]	"But $\sqrt{56} \approx 7.48$, $8\sqrt{2} \approx 11.31$, which are not equal."	0.0

3. Algorithmic Segmentation

ค้นหาจุดตัดที่ดีที่สุดด้วยสมการคณิตศาสตร์
เพื่อรักษาสมดุลขนาดของบล็อก



4. Iterative Compression

LLM ย่อความ + Judge ตรวจสอบ
วนลูปแก้ตัวสูงสุด 2 รอบ
(Pass Rate 28% -> 92%)

Memento refinement example — NBA playoff probability trace, Block 2

Block excerpt: "...defines $f(n,a,b)$ as the probability that after n games, Team A has a wins and Team B has b wins. Starting point: $f(0,0,0)=1$. Need $f(6,3,2)$. For Game n : if n is odd, $\text{home}=A$, $P(A \text{ wins})=0.6$; if even, $\text{home}=B$, $P(B \text{ wins})=0.6$..."

Initial memento (pass 1, score 5/10): Defines target probability $P_{JJ}(A,B)=(3,3)$ after 6j. Home team alternates each game; home win prob=0.6. Proposes DP approach and considers enumeration of all sequences.


Judge feedback: Missing formula: recurrence $f(n,a,b)$ with starting condition $f(0,0,0)=1$. Missing: explicit transition probabilities for odd/even games. Replace "proposes DP approach" with the named state variables and recurrence.

Refined memento (pass 2, score 8/10): Defines $f(n,a,b)=P(A \text{ has } a \text{ wins, } B \text{ has } b \text{ wins after } n \text{ games})$; $f(8,0,8)=1$; target $f(6,3,3)$. Home pattern: odd games $\text{home}=A$, even $\text{home}=B$; $p_{\text{homewin}}=0.6$.
Transitions: if $\text{home}=A$,
 $f(n,a,b)=f(n-1,a-1,b)*0.6+f(n-1,a,b-1)*0.4$;
if $\text{home}=B$, swap.

2-Stage SFT Recipe: สอนให้เก่งตามลำดับขั้น

Stage 1: Format Learning (Full Attention)


- **กลไก:** เปิดให้โมเดลมองเห็นทุก Token อย่างอิสระ
- **เป้าหมาย:** เรียนรู้จังหวะการสร้าง Block และ Memento โดยไร้แรงกดดันเรื่องข้อจำกัดด้านความจำ



Full Causal Attention Matrix (Unrestricted)

Stage 2: Context Management (Memento Attention)

- **กลไก:** เมื่อสร้างแท็ก `<|summary end|>` ระบบจะกางหน้าฉาก (Mask) ปิดบัง Block เดิมทันที
- **เป้าหมาย:** บังคับให้ Memento ต้องพึ่งพาตัวเองได้ 100% เพราะจะมองไม่เห็นอดีตอีกต่อไป




Sparse Attention Matrix (Masked Previous Blocks)

เคล็ดลับ: การฝึกแบบแยกส่วนช่วยให้โมเดลไม่สับสนและรักษาความแม่นยำขั้นสูงไว้ได้

Native vLLM Integration: ปลดล็อกความเร็วระดับ Engine

การปรับแก้สถาปัตยกรรมระดับล่าง


- **MEMENTO** ทำงานร่วมกับการดัดแปลง vLLM (V1 Engine) เพื่อรองรับ Block Masking แบบ In-place
- **กลไก:** ลบ KV Cache ของบล็อกทิ้งทางกายภาพ (Physically remove) ทันทีที่การสรุปบล็อกเสร็จสิ้นภายใน Generation Call เดียว



ผลลัพธ์เชิงประจักษ์

- **Throughput +1.75x:** ประมวลผลได้ 4,290 tok/s เทียบกับระบบปกติที่ทำได้เพียง 2,447 tok/s
- **KV Cache ปลดโปร่ง:** ป้องกันปัญหาหน่วยความจำเต็ม (KV-cache-bound) เมื่อใช้ Concurrency สูง

Performance: ลดโหลดมหาศาล แต่รักษาความฉลาดไว้ได้






ลด Peak KV Cache 2.5 เท่า:
จาก 2.71GB เหลือ **1.08GB**
(ใน Qwen3-8B)

ความแม่นยำแทบไม่ตก:
ดรอปลงเพียง **3-6%** บน AIME'26
และยังโมเดลขนาดใหญ่ขึ้น (32B)
การดรอปลงเหลือเพียง **2.6%**

Internal Capability:
โมเดลบูรณาการทักษะการย่อความให้เป็น
ความสามารถในตัวเอง โดยเฉพาะข้อสอบ
คณิตศาสตร์ (MATH-500) ที่คะแนนคงที่

Recovering the Gap: กู้คืนความแม่นยำด้วย RL (CISPO)



The Problem & Evidence

SFT ทำให้ความแม่นยำเดียว (Pass@1) ตกลงเล็กน้อย แต่การทำ Majority Voting แค่ k=2-3 ช่วยให้ชนะ Baseline ได้ แปลว่าคำตอบที่ถูกยังอยู่ในหัวโมเดล


The RL Solution

ใช้เทคนิค CISPO RL (Clipped Importance-Sampled PO) ผสานกับ Rule-based Math Rewards ในการเทรนกับ

The Result


กู้ความแม่นยำบน AIME'26 กลับมาเป็น **64.9%** (จาก 57.3%) โดยที่ประหยัด Peak KV Cache ได้ดีกว่า Baseline ถึง **45%**

The Dual Information Stream: ความลับที่ซ่อนอยู่ใน KV Cache




The Revelation: แม้บล็อกความคิดจะถูกลบทิ้งไปแล้ว แต่ ‘เงา’ ของมันยังคงวิ่งอยู่ในระบบผ่าน KV Cache ของตัว Memento ทำให้ทำงานได้ดีกว่าการจำจากตัวอักษรสรุปเพียงอย่างเดียว

Probing the Implicit Channel: พิสูจน์ร่องรอยของข้อมูลที่ถูกลบ



The Experiment:

- แอบฟังรหัสลับ 5 หลักไว้ใน Block ที่กำลังจะถูกลบทิ้ง
- ใช้ Probe ดักจับรหัสนี้จาก Memento ตัวถัดไปที่ไม่เคยเห็น Block ต้นทางมาก่อน




The Results:

- โมเดลสามารถทายรหัสได้ถึง 26.7% (8B) ซึ่งสูงกว่าการเดาสุ่ม (10%) อย่างมีนัยสำคัญ
- สัญญาณลับนี้ซ่อนอยู่ลึกที่สุดใน Layer ท้ายๆ ของ Transformer


Ablation Study: ทำไมเราถึงเคลียร์ Cache ทั้งทั้งหมดไม่ได้?

วงจร Memento Attention



KV states carry an implicit information channel. Memento KV representations propagate block information across masked boundaries—an architectural effect that complements the explicit memento text and explains why single-pass MEMENTO outperforms restart-based methods.

วงจร Restart + Re-prefill



Core Conclusion: Memento ไม่ใช่แค่ข้อความย่อ แต่คือ ‘ตัวชี้เป้า (Pointer)’ ที่บีบอัดสถานะความคิด หากตัดสาย Implicit KV ทิ้ง โมเดลจะสูญเสียทักษะการใช้เหตุผลทันที (Drop 15.3 pp)





Scalability & Generalization: สากลและรองรับการขยายสเกล

Universal Compatibility:

- ทำงานได้ดีกับสถาปัตยกรรมที่หลากหลาย (Qwen3, Phi-4)
- แม้แต่โมเดลที่มีเลเยอร์แบบ Sliding-Window (Olmoe-3) ก็รองรับ MEMENTO ได้โดยไม่ต้องแก้ไขโครงสร้าง

Stable Compression

- อัตราการบีบอัด (Compression Ratio) เสถียรมากที่ระดับ 5-20 เท่า ในทุกชุดข้อมูล
- ขนาดของ Memento คงที่เฉลี่ย 260-615 ตัวอักษร ไม่ว่าโจทย์จะยาวหรือยากแค่ไหน



Synthesis: บูรณาการกระบวนการทัศน์ใหม่ของ LLM Reasoning



Aha-moment: ความสำเร็จนี้ไม่ได้เกิดจาก Data หรือ Model เพียงอย่างเดียว แต่เกิดจากการประสานงานแบบ End-to-End ตั้งแต่ Data -> Training -> Inference Engine

ก้าวต่อไปของการบีบอัดความจำ (Conclusion & Open Source)

Key Takeaways



Efficiency: ลดการใช้ KV Cache ได้สูงถึง 2.5 เท่า พร้อมเพิ่มความเร็ว Throughput 1.75 เท่า



Capability: รักษาศักยภาพการใช้เหตุผลได้เทียบเท่า Baseline และกู้คืนความแม่นยำสูงสุดด้วย RL



Discovery: ค้นพบช่องทางสื่อสารข้อมูลแบบ Implicit ผ่าน KV Cache กลายข้อจำกัดของ Restart-based methods แบบเดิมๆ

Resources

Call to Action

Code & vLLM Fork:
github.com/microsoft/memento

Dataset:
huggingface.co/datasets/microsoft/OpenMementos



[QR_CODE]

