


[Meta FAIR Research]


[LLM Architecture]

ประวัติโครงสร้าง DNA ของ Large Language Models

ทำไมกระบวนการพัฒนาแบบเดิมถึงล้มเหลว และสถาปัตยกรรม
Self-Improving จาก Meta FAIR กำลังจะกำหนดมาตรฐานใหม่




ข้อบกพร่องของกระบวนการฝึกฝนแบบดั้งเดิม: เราสอนกฎหมายหลังจากที่โมเดลมีอคติไปแล้ว



แม้ว่าพฤติกรรมของโมเดลจะถูกฝังรากลึกตั้งแต่ช่วง Pretraining แต่กระบวนการปัจจุบันกลับพยายามยัดเยียดตรรกะและความปลอดภัยในช่วง SFT/RLHF ซึ่งสายเกินไปและไร้ประสิทธิภาพ


กระบวนการทัศน์ Shift-Left: ดึงความอัจฉริยะกลับไปสู่จุดเริ่มต้นของ Timeline



โซลูชันของ Meta FAIR คือการนำโมเดลที่ผ่านการ Post-Trained มาแล้ว กลับไปเป็น **ครู** เพื่อชี้แนะและให้รางวัลโมเดลใหม่ตั้งแต่ช่วง Pretrain และ Mid-train


การเปลี่ยนผ่านจาก การเดาคำถัดไป สู่ การสร้างบริบทที่สมบูรณ์

กระบวนการขั้นเดิม: Next-Token Prediction



ข้อจำกัด: เรียนรู้แค่รูปแบบผิวเผิน
ขาดความเข้าใจเป้าหมายของทั้งประโยค


กระบวนการขั้นใหม่: Sequence Generation (N=128 tokens)



โมเดลเรียนรู้วิธีการสร้างบริบท (Prefix -> Suffix)
แบบเต็มรูปประโยค ซึ่งสอดคล้องกับการใช้งานจริงมากกว่า

การปรับเป้าหมายจากการทำนายทีละคำ เป็นการทำนายกลุ่มคำ (Chunks)
เปิดทางให้เราสามารถนำโมเดลครูมาประเมิน คุณภาพ ของประโยคเหล่านั้นได้

โมเดลครูผู้สอนสองบทบาท: Rewriter และ LLM-as-a-Judge



วงจรการเรียนรู้แบบเสริมแรง (Reinforcement Loop) ที่ทำงานแบบ Real-time


กระบวนการแบบเรียลไทม์ (Real-time Process)

1. ข้อมูลสตรีมมิ่ง (Streaming Data)
-> แยกเป็น Prefix และ Suffix

2. สุ่มสร้างทางเลือก: Suffix ต้นฉบับ, Suffix ฉบับแก้ไข (Rewrite), และทางเลือกจากโมเดลปัจจุบัน (N Rollouts)

3. Judge ประเมินให้คะแนน
-> อัปเดตโมเดลผ่าน Online DPO / RF-NLL

ข้อมูลเชิงประจักษ์ (Data Evidence)



อัตราการเลือก Rollout: ในช่วงแรก โมเดลจะเรียนรู้จาก Rewrite เป็นหลัก แต่เมื่อโมเดลเก่งขึ้น Judge จะเริ่มให้คะแนนและเลือก Rollout ของตัวโมเดลเองมากขึ้นจนแตะระดับ 100%


ข้อมูลสตรีมมิ่ง

กระบวนการแบบเรียลไทม์

อัปเดตโมเดล

ข้อมูลเชิงประจักษ์

ผลลัพธ์เชิงประจักษ์: คุณภาพ ความปลอดภัย และข้อเท็จจริง




Metric 1: Generation Quality (Win Rate)

พุ่งสูงถึง 86.3% เมื่อเทียบกับ Baseline ในการสร้างข้อความจากบริบททั่วไป



Metric 2: Safety Score

เพิ่มขึ้นจาก 75.5 เป็น 91.1 (โมเดลเรียนรู้ที่จะปลอดภัยตั้งแต่โครงสร้างพื้นฐาน ไม่ใช่แค่ถูกครอบด้วยฟิลเตอร์)



Metric 3: Factuality


ลดอัตราการเกิด Hallucination ดันคะแนนจาก 42.3 เป็น 57.6

การแทรกแซงด้วย RL ตั้งแต่ขั้น Pretraining สร้างโมเดลที่พื้นฐานแน่นกว่า แข็งแกร่งกว่า และปลอดภัยกว่า โดยไม่ต้องพึ่ง SFT นักหั่นวงในภายหลัง

ช่องโหว่ด้านกระบวนการคิด (The Reasoning Gap) ในข้อมูลดิบ


2. The Missing Layer (X-ray): ขาดร่องรอยของความคิด (Explicit Reasoning Traces)

Raw Text Layer: ข้อมูลใน Pretraining มีเพียงข้อเท็จจริงและผลลัพธ์ (เช่นบทความคณิตศาสตร์ที่กระโดดไปสู่คำตอบ)



Core Question:
โมเดลจะเรียนรู้วิธีการคิดวิเคราะห์ได้อย่างไร หากข้อมูลที่มันใช้อ่านมีแต่ผลลัพธ์ แต่ไม่มีวิธีทำ?

โมเดลจึงต้องไปเรียนรู้การคิดเชิงตรรกะอย่างยากลำบากในช่วง Post-training ซึ่งเป็นการแก้ปัญหาที่ปลายเหตุ




โครงสร้าง 3 ขั้นตอนของ Thinking Mid-Training



นี่คือเฟสตัวกลาง (Intermediate Phase)
ที่มาอุดช่องโหว่ระหว่าง Pretraining และ Post-training
เปลี่ยนคลังข้อมูลธรรมดาให้เป็นคลังข้อมูลตรรกะ

ขั้นที่ 1: การถักทอ ความคิด ลงในบริบท (Interleaving Thoughts)




โมเดลครูทำการสอดแทรก กระบวนการคิดเบื้องหลัง (T) ลงในตำแหน่งที่เหมาะสมของข้อความเดิม (X) เปลี่ยนบทความธรรมดาให้กลายเป็นตัวอย่างการใช้เหตุผลแบบ Step-by-step โดยที่ยังคงความสลับไหลของเนื้อหาเดิม

ขั้นที่ 2 & 3: จากการเรียนรู้แบบสุ่มความเชี่ยวชาญเชิงตรรกะ

Continuous Timeline Track

Panel A: SFT (Cold Start)



Mechanism: SFT บนข้อมูล Augmented. โมเดลเรียนรู้จังหว่ว่า เมื่อไหร่ควรคิด และ รูปแบบความคิด หน้าตาเป็นอย่างไร (Cold Start)

Panel B: RL (Optimize)



Mechanism: สร้าง Prefix และให้โมเดลคิดเอง (T) เพื่อทำนาย Suffix (S). Judge ประเมินว่าความคิดนั้น มีประโยชน์ ต่อการทำนายผลลัพธ์ที่ถูกต้องหรือไม่

บังคับให้การคิดมีเป้าหมาย: ความคิดที่ดีต้องนำไปสู่ผลลัพธ์ที่แม่นยำ ไม่ใช่แค่การพิมพ์ข้อความเยิ่นเย้อ

ผลลัพธ์เชิงประจักษ์: ปลดล็อกศักยภาพความสามารถด้านคณิตศาสตร์และตรรกะ

ค่าเฉลี่ยความแม่นยำรวม
(GSM8K, MATH-500, AMC23, GPQA-D)









ประสิทธิภาพเพิ่มขึ้นสูงถึง
3.2 เท่า

(ไร้พลังหากพื้นฐานไม่ดี)


การแนะนำกระบวนการคิดตั้งแต่เนิ่นๆ ไม่เพียงทำให้โมเดลเก่งขึ้นทันที แต่ยังทำให้โมเดลพร้อมรับการฝึกขั้นสูง (RLVR) ได้ดีกว่าเดิมอย่างก้าวกระโดด

สรุปจุดตัด: กระบวนทัศน์แบบคลาสสิก vs Self-Improving Paradigm

	Old Paradigm (กระบวนทัศน์แบบเก่า)	New Paradigm (กระบวนทัศน์แบบใหม่)
Objective (เป้าหมาย)	ทำนายคำถัดไป (Next-Token) 	สร้างบริบท (Sequence Generation) พร้อมคะแนน RL 
Data Quality (ข้อมูล)	พึ่งพาการกรองข้อมูลดิบ (Passive) 	แก้ไขข้อมูลและสอดแทรกตรรกะ แบบ Real-time (Active) 
Reasoning (ตรรกะ)	อัดฉีดช่วงท้าย (Post-train) 	ถักทอเข้ากับข้อมูลพื้นฐานตั้งแต่ Mid-train 
Outcomes (ผลลัพธ์)	เผลอบาง, Hallucinate ง่าย 	ปลอดภัยลึกซึ้ง, ตรรกะเป็นเลิศ, พร้อมต่อยอด 

Continuous Timeline Track

สถาปัตยกรรม Next-Gen LLM ฉบับสมบูรณ์จาก Meta FAIR



โครงสร้างพื้นฐานที่ผนวกรวม RL และ AI-Feedback
เข้าไปในทุกก้าวของวงจรชีวิตโมเดล

3 แกนหลักสู่อนาคตของการพัฒนา AI

