



Multimodal Bottleneck Transformer (MBT)

การจำกัดการไหลเวียนของข้อมูล เพื่อสร้าง AI ที่วิเคราะห์ภาพและเสียงได้ฉลาดและรวดเร็วยิ่งขึ้น


วิจัยและพัฒนาโดย Google Research

ช่องว่างของการรับรู้แบบพหุโมดัล



การรับรู้ของมนุษย์
(Human Perception)

สัญญาณเสียง
(Audio Stream)



สัญญาณภาพ
(Visual Stream)


การรับรู้ของเครื่องจักร
(Machine Perception)

มนุษย์ประมวลผลภาพและเสียงพร้อมกันอย่างสมบูรณ์แบบ แต่โมเดล ML ในปัจจุบันมักแยกการทำงานออกจากกัน ทำให้เกิดปัญหาในการจัดการข้อมูลที่ซ้ำซ้อนและมีโครงสร้างสัญญาณรบกวน (Noise topologies) ที่ต่างกัน เป้าหมายของเราคือการสร้างการรับรู้ที่เป็นหนึ่งเดียวอย่างแท้จริง

วิวัฒนาการของการหลอมรวมข้อมูล (The Evolution of AI Fusion)

	Late Fusion (มาตรฐานเดิม)	Early Fusion (ไร้ข้อจำกัด)	Bottleneck Fusion (นวัตกรรมใหม่)
การโต้ตอบข้ามโมดัล (Cross-Modal Interaction) 	โต้ตอบเฉพาะ ขั้นตอนสุดท้าย (None until classifier)	โต้ตอบในทุกเลเยอร์ (All layers)	โต้ตอบแบบถูกควบคุม ผ่านจุดคอขวด (Controlled)
ต้นทุนการประมวลผล (Compute Cost)	ต้นทุนต่ำ (Low) 	ต้นทุนสูงแบบก้าวกระโดด (Quadratic/High)	ต้นทุนต่ำ (Low) 
คุณภาพของข้อมูล (Information Quality)	ข้อมูลถูกแยกส่วน อย่างสิ้นเชิง (Siloed) 	ข้อมูลเต็มไปด้วย Noise และความซ้ำซ้อน (Noisy/Redundant)	ข้อมูลถูกสกัดเอาเฉพาะ แก่นที่สำคัญ (Distilled) 


ทำไม "ยุ่งเยอะ" ถึงไม่ใช่ "ยุ่งดี"



$O(N^2)$


ข้อมูลวิดีโอและเสียงมีความละเอียดสูงและซับซ้อนมหาศาล การอนุญาตให้ทุก "Visual Token" พุดคุยกับทุก "Audio Token" ในทุกเลเยอร์ ทำให้เกิดภาวะ Overload ของการประมวลผล (Quadratic scaling cost) และทำให้สัญญาณที่สำคัญจริงๆ ถูกกลืนหายไป Noise

เปิดตัว Multimodal Bottleneck Transformer (MBT)




นวัตกรรมหลักของ MBT คือการจำกัดความสนใจข้ามโมดัล (Cross-modal attention) โมดัลของภาพและเสียงจะแลกเปลี่ยนข้อมูลกันได้ ก็ต่อเมื่อต้องบีบอัดข้อมูลผ่านโทเคน "คอขวด" (Fusion Bottlenecks) จำนวนน้อยชนิดนี้เท่านั้น ซึ่งบังคับให้ AI ต้องเลือกเฉพาะข้อมูลที่จำเป็นที่สุด

จากข้อมูลดิบสู่โทเคน



วิธีที่ MBT ย่อยโลกแห่งความเป็นจริง: ใช้สถาปัตยกรรม ViT (Vision Transformer) สำหรับภาพ และ AST (Audio Spectrogram Transformer) สำหรับเสียง เพื่อแปลงอินพุตที่ต่อเนื่องให้เป็นหน่วยข้อมูลย่อย (Tokens) ที่พร้อมสำหรับการประมวลผล

กลยุทธ์การหลอมรวมข้อมูลในชั้นกลาง (Mid-Fusion Strategy)




"ควรหลอมรวมข้อมูลที่จุดไหน?"

MBT บังคับให้เลเยอร์ล่างๆ
เชี่ยวชาญในการดึงรูปแบบ
เฉพาะของแต่ละโมดัล
(เช่น ขอบภาพ, ระดับเสียง)

อย่างอิสระ
และจะเริ่มใช้ขอบเขตเพื่อข้าม
โมดัลในเลเยอร์ที่สูงขึ้น
(Layer 8 เป็นต้นไป)
เพื่อวิเคราะห์ความหมายที่ลึกซึ้ง
(Semantic concepts)

ประสิทธิภาพสูงสุด ภายใต้ต้นทุนที่ต่ำกว่า



กราฟแสดงให้เห็นว่าการรอนจนถึง Layer 8 (Mid-Fusion) แล้วจึงใช้ Bottlenecks ช่วยให้ได้ความแม่นยำสูงสุด (mAP พุ่งสูงขึ้น) ในขณะที่รักษาต้นทุนการคำนวณ (GFLOPs) ให้ต่ำใกล้เคียงกับ Late Fusion แบบดั้งเดิมอย่างน่าทึ่ง

ยกระดับมาตรฐาน State-of-the-Art

AudioSet

+5.9 mAP
(12.7% Jump)

Outperforms previous SOTA
using only 25% (500K) of the
standard training data.

Epic-Kitchens-100

+64.8%
Top-1 Action Acc

Beats models using three
modalities (including optical
flow) by using just audio/visual
bottlenecks.

VGGSound

64.1%
Top-1 Acc

Establishes a massive new
baseline for Audio-Visual
SOTA.

การใช้ข้อจำกัดเชิงโครงสร้างของ MBT ไม่เพียงแต่ประหยัดพลังงาน
แต่ยังทำลายสถิติ SOTA ในทุกชุดข้อมูลทดสอบหลัก

พลังของการทำงานร่วมกัน (Audio + Video > Parts)



ข้อมูลทั้งสองประเภททำหน้าที่ส่งเสริมซึ่งกันและกัน
ลำพังเพียงภาพหรือเสียงไม่เพียงพอต่อความเข้าใจที่สมบูรณ์
การผสมรวมแบบคอดช่วยยกระดับความแม่นยำขึ้นอย่างก้าวกระโดดเมื่อเทียบกับการใช้โมเดลเดี่ยวๆ

การมองเห็นของ AI: จุดโฟกัสที่แม่นยำจดมนุษย์



การหลอมรวมแบบดั้งเดิม (Vanilla Fusion) - โฟกัสกระจายตัว

การหลอมรวมแบบคอขวด (MBT) - โฟกัสแม่นยำที่ต้นกำเนิดเสียง

นี่คือหลักฐานเชิงประจักษ์ เมื่อเราบังคับให้ข้อมูลไหลผ่าน "คอขวด" AI จะเรียนรู้ที่จะกรองเสียงรบกวนรอบข้างทั้ง และพุ่งความสนใจไปที่แหล่งกำเนิดเสียงในภาพได้อย่างแม่นยำ (เช่น ปากของเด็กทารก หรือปลายนิ้วบนเปียโน)

สูตรสำเร็จของ MBT (Optimal Configurations)



ความยาวอินพุต (Input Span): 8 วินาที
(ให้บริบทที่สมบูรณ์ที่สุดโดยไม่สูญเสียความแม่นยำ)




จุดเริ่มต้นการหลอมรวม (Fusion Layer): $L_f = 8$
(Mid-fusion ให้ผลลัพธ์ที่ดีที่สุด)



จำนวนคอขวด (Bottleneck Tokens): $B = 4$ โทเคน
(น่าทึ่งที่การใช้โทเคนเพียง 4 ตัวให้ประสิทธิภาพสูงสุด
มากกว่านี้ไม่ช่วยเพิ่มความแม่นยำ)

ข้อจำกัดคือบ่อเกิดของความชัดเจน (Constraint Breeds Clarity)



01

บังคับให้คัดกรอง

การสร้างคอขวด (Bottlenecks)
บังคับให้โมเดลต้องสกัดและแบ่งปัน
เฉพาะข้อมูลที่สำคัญที่สุดจริงๆ

02

ปลดล็อกประสิทธิภาพ

ก้าวข้ามข้อจำกัด $O(N^2)$
ของสมการ Attention ดั้งเดิม
ทำให้ความแม่นยำระดับ SOTA
เป็นไปได้จริงในทางปฏิบัติ

03

มาตรฐานใหม่

MBT ได้สถาปนาตนเองเป็น
สถาปัตยกรรมพื้นฐาน
(Foundational Architecture) ตัวใหม่
สำหรับ AI แบบพหุโมดัลในอนาคต