


พิมพ์เขียวแห่งขุมพลัง: Nemotron 3 Super

โมเดล Open Hybrid Mamba-Transformer
MoE ที่ออกแบบมาเพื่อ Agentic
Reasoning โดยเฉพาะ




[120B]
พารามิเตอร์รวม

[12B]
พารามิเตอร์ทำงาน
จริง (Active)


[1M]
ความจุ Context
Window

คอขวดของระบบ Multi-Agent ในปัจจุบัน



Context Explosion (วิกฤตข้อมูลล้นระบบ)

ปริมาณ Token ขยายตัว 15 เท่าจากประวัติการแชทและผลลัพธ์ของเครื่องมือ
ทำให้เกิด Goal Drift (AI สลับเป้าหมายหลักเมื่อทำงานระยะยาว) →




The Thinking Tax (ต้นทุนการคิดที่สูงเกินจริง)

การใช้โมเดลขนาดใหญ่สำหรับทุกงานย่อย
ทำให้ระบบช้าและมีค่าใช้จ่ายมหาศาลเกินกว่าจะใช้งานจริงได้




ทางออกระดับสถาปัตยกรรมสำหรับ Agentic AI




**1M Token
Native Context**

มอบหน่วยความจำระยะยาวให้กับ Agent ป้องกัน
ปัญหา Goal Drift สอดคล้องกับเป้าหมายเสมอ



**120B / 12B
Active Parameters**


กลายข้อจำกัดด้านต้นทุนด้วยสถาปัตยกรรม MoE
ทำงานเฉพาะส่วนที่จำเป็น



**2.2x Throughput
vs. gpt-oss-120b**


รองรับ Workload ขนาดใหญ่ (8k in / 64k out)
ด้วยความเร็วที่เหนือกว่าถึง 5 เท่าเมื่อเทียบกับรุ่นก่อนหน้า

ผ่าโครงสร้าง Hybrid Backbone ทั้ง 88 เลเยอร์




นวัตกรรมที่ 1: Latent MoE (ทวิคูณประสิทธิภาพผู้เชี่ยวชาญ)

Standard MoE




Latent MoE



- **การบีบอัด:** บีบอัด Dimension จาก $d=4096$ ลงเหลือ $l=1024$
- **ผลลัพธ์ที่ได้:** เพิ่มผู้เชี่ยวชาญรวมเป็น 512 Experts พร้อมการทำ Top-22 Routing
- **ข้อได้เปรียบ:** ลดคอขวด Memory Bandwidth ได้ความเชี่ยวชาญที่ละเอียดขึ้น (เช่น แยกระหว่าง Python กับ SQL) ภายใต้ต้นทุนเท่าเดิม

นวัตกรรมที่ 2: Multi-Token Prediction (MTP)

กลไกหลัก: ใช้ Shared-weight heads
คาดเดา Token ในอนาคตหลายตัวพร้อมกันใน
Forward pass เดียว



Built-in Speculative Decoding

- เร่งความเร็วได้สูงสุด 3 เท่าสำหรับการเขียนโค้ดและเรียกใช้เครื่องมือ โดยไม่ต้องพึ่ง Draft model แยก

ความแม่นยำสูงขึ้น


- อัตราการยอมรับ (Acceptance length) สูงถึง 3.45 Tokens
- เอาชนะโมเดลชั้นนำด้วยการฝึกให้เข้าใจโครงสร้างระยะยาว

นวัตกรรมที่ 3: ฝึกสอนด้วย NVFP4 แบบ Native ตลอดกระบวนการ


กระบวนการ Quantization ที่ทั่วไป




Native NVFP4 Pretraining



ประมวลผล 25 Trillion Tokens ด้วยความละเอียด 4-bit ตั้งแต่เริ่ม (ผ่านปัญหา Zero-gradient อย่างสมบูรณ์)



ผลลัพธ์ฮาร์ดแวร์:
อนุমানเร็วขึ้น 4 เท่าบนชิป NVIDIA Blackwell (B200) เทียบกับ FP8 บน H100




Insight: โมเดลเรียนรู้ที่จะแม่นยำ 'ภายใต้ข้อจำกัด' ของคณิตศาสตร์ 4-bit ได้ตั้งแต่ก้าวแรก



สรุปจุดเปลี่ยนสถาปัตยกรรม (The Architectural Paradigm Shift)

องค์ประกอบ (Component)	สถาปัตยกรรม LLM ทั่วไป (Standard LLMs)	Nemotron 3 Super
Routing	Direct Routing	Latent Routing (บีบอัดก่อนประมวลผล)
Prediction	Next-Token	Multi-Token (Shared Weight)
Precision	FP8/BF16 Pretraining	Native NVFP4 Pretraining
Backbone	Pure Transformer	Hybrid Mamba/Transformer/MoE
Experts	128 (Top-6/8)	512 (Top-22)

เจาะลึกกระบวนการหล่อหลอม: Pretraining & SFT




Tech Highlight: ใช้เทคนิค WSM Checkpoint Merging (เฉลี่ยน้ำหนักแบบ Sliding window) ลดสัญญาณรบกวน ประสิทธิภาพการคำนวณ 4T Tokens และเพิ่มคะแนน 2-4 แต้ม



Tech Highlight: ใช้ Two-Stage SFT Loss ปรับบรรทัดฐานการสนทนาและยาวให้เท่าเทียมกัน ป้องกันไม่ให้เกิดผลที่ขัดยาวกลบการตอบสนองแบบสั้น

เสริมแกร่งด้วย Multi-Environment Reinforcement Learning



ประสิทธิภาพและความเร็วเหนือระดับ (พร้อมข้อควรระวัง)

Performance Metrics




The Diagnostic Callout



ข้อควรระวัง: ความเย็นเยือกของ Token (The Verbosity Caveat)

- Insight:** สร้าง Token ที่ละเอียดและยืดเยื้อพิเศษ (110M Tokens เทียบกับค่าเฉลี่ย 7.3M)
- Conclusion:** นี่คือธรรมชาติของโมเดลที่เน้น Deep Reasoning ผู้ใช้ควรคำนึงถึงปริมาณ Token เมื่อวางแผนนำไปใช้งานจริง

รูปแบบการใช้งานจริง: The 'Super + Nano' Matrix



Takeaway: การผสานโมเดลทั้งสองขนาดคือสถาปัตยกรรมที่คุ้มค่าและทรงพลังที่สุดสำหรับ Multi-Agent Applications

ระบบนิเวศแบบเปิดกว้าง (The Open Ecosystem)

Layer 3: Deployment & Tuning Cookbooks


รองรับสูตรสำเร็จสำหรับ vLLM, SGLang, TensorRT-LLM และรองรับ LoRA SFT/GRPO ผ่าน NeMo RL.

Layer 2: Model Weights & Platforms


ดาวน์โหลดได้เต็มรูปแบบบน Hugging Face, NVIDIA NIM พร้อม Nemotron Open Model License.

Layer 1: Open Datasets


เข้าถึงข้อมูล 10T Pretraining Tokens และ 40M SFT/RL Samples แบบโปร่งใส.



สมการแห่งความเป็นเลิศ: The Multiplier Effect






แซร์น้ำหนักเพื่อเอา Token อนาคต
เร่งความเร็วหักล้างความซับซ้อน



การบีบอัดข้อมูลตั้งแต่ฐานราก
เปิดทางให้...

ใส่ผู้เชี่ยวชาญได้ 512 คนภายใต้ต้นทุนเดิม
ทำงานร่วมกับ...



The Ultimate Agentic Brain

ไม่ใช่แค่โมเดลที่ใหญ่ขึ้น แต่นี่คืองานออกแบบสถาปัตยกรรมร่วม (Co-design)
ที่เปลี่ยนสมการต้นทุนและความฉลาดของ AI ไปอย่างสิ้นเชิง

เริ่มต้นสร้างระบบ Agentic ของคุณ


ทดลองใช้งาน →

ผ่าน build.nvidia.com
หรือ [Perplexity Pro](#)




ดาวน์โหลด Weights →

ค้นหาบน [Hugging Face](#)
(BF16 & FP8)



ปรับแต่งโมเดล →

ใช้งานผ่าน [NVIDIA NIM](#)
และ [Unsloth](#)



ผสานเข้ากับ Agent →

ตรวจสอบ [GitHub Repository](#)
สำหรับตั้งค่าร่วมกับ
[OpenCode](#), [OpenHands](#)
และ [OpenClaw](#)

