





สถาปัตยกรรม LLM ยุคใหม่: ผ่าลึกเคล็ดลับลดต้นทุน Long-Context



เจาะลึกกลไก `KV Sharing`, `mHC`, และ `Compressed Attention`
จากเส้นทางของ Gemma 4 สู่ DeepSeek V4

Agentic Workflows
& Reasoning
(`128K+ tokens`)



1. `KV-Cache Size`
(Memory constraints)


2. `Memory Traffic`
(Bandwidth limits)

3. `Attention Compute`
(Quadratic FLOPs)

ปัญหาคอขวด ของ LLM


ทำไมสถาปัตยกรรม LLM
จึงต้องเปลี่ยน?
เพราะการขยาย Context
Window
ให้รองรับบริบทที่ยาวขึ้น
ทำให้ต้นทุนการประมวลผลแ
ละการใช้หน่วยความจำพุ่ง
สูงเป็นทวีคูณ
การลดขนาดโมเดลเพียงอย่าง
เดียวไม่พอ เราต้อง "แก้ไข"
โครงสร้างภายในของมัน

แผนที่นวัตกรรม: การผ่าตัดดัดแปลงเฉพาะจุด (Surgical Interventions)



นวัตกรรมใหม่ล่าสุดมุ่งเป้าไปที่การผ่าตัดดัดแปลงเฉพาะจุดภายใน Transformer Block เพื่อลดขนาดของประสิทธิภาพ


Gemma 4: แชร์ KV ข้ามเลเยอร์ (Cross-Layer KV Sharing)



Data Point	Takeaway
ลดขนาด KV Cache ลงได้ถึง 2.7 GB (สำหรับรุ่น E2B) และ 6 GB (สำหรับรุ่น E4B) ที่ความยาวคอนเท็กซ์ '128K'	แทนที่จะแชร์แค่ภายในเลเยอร์ Gemma 4 นำ KV tensors มาแชร์ข้ามเลเยอร์ ช่วยฟื้นการใช้หน่วยความจำลงเกือบครึ่ง

Gemma 4: เพิ่มความจุโดยไม่เพิ่มขนาด (Per-Layer Embeddings / PLE)

Parameter Efficiency Hack




PLE เพิ่มความจุของโมเดลผ่าน Lookup Table ที่ใช้ดัชนีค้นหา ทำให้โมเดลขนาดเล็กมี "พลังแฝง" เท่าโมเดลใหญ่ โดยไม่เพิ่มภาระการคำนวณ (Compute Cost) ในเลเยอร์หลัก

Laguna XS.2: จัดสรรงบประมาณ Attention (Layer-Wise Budgeting)



ไม่ใช่ทุกเลเยอร์ที่ต้องการทรัพยากรเท่ากัน Laguna XS.2 จัดสรรงบประมาณความจุของ 'Query-head' ตามหน้าที่ เลเยอร์ Global ที่กินพลังงานสูงจะถูกจำกัดงบ ส่วนเลเยอร์ Local จะได้รับงบเต็มที่เพื่อบรรลุประสิทธิภาพสูงสุด


ZAYA1-8B: ประมวลผลใน Latent Space (Compressed Convolutional Attention)



ZAYA1-8B ฉีกกฎเดิมด้วยการคำนวณ Attention ภายในสภาวะบีบอัด (Latent Space) โดยตรง ซึ่งช่วยลดทั้งขนาดของ KV Cache และจำนวนการคำนวณ (FLOPs) อย่างมหาศาล

The CCA Secret: ชดเชยข้อมูลด้วย Convolution (Sequence Mixing)

Sequence Mixing Intervention




การบีบอัดทำให้ข้อมูลสูญหาย
CCA แก้เกมด้วยการใช้ '1D Convolution'
ปาดกวาดข้อมูลเฉพาะบนเวกเตอร์ 'Q' และ 'K'
เพื่อชดเชยบริบทแวดล้อม (Local Context)
กลับคืนมาก่อนที่จะนำไปคำนวณคะแนน Attention


DeepSeek V4: ยกระดับทั้งสองเส้นทาง (The Dual Upgrade)

Note: DeepSeek V4-Pro has the lowest active-parameter share (extreme sparsity) among recent MoE models.


The Residual Flow → 'mHC' (Manifold-Constrained Hyper-Connections)



The Attention Mechanism → 'CSA / HCA' (Compressed Attention)




DeepSeek V4-Pro ยกระดับสถาปัตยกรรมแบบหน้ามือเป็นหลังมือ โดยไม่ได้ปรับปรุงแค่กลไก Attention แต่ยังรีไทร์โครงสร้างเส้นทางส่งข้อมูล (Residual Stream) ภายใน Transformer Block ใหม่ทั้งหมด



DeepSeek V4: ขยายถนนข้อมูล (Manifold-Constrained Hyper-Connections)

Standard Residual Stream



`mHC` (Manifold-Constrained Hyper-Connections)



Training Overhead:
Only +6.7%
for massive capacity gain.


mHC ขยายถนนส่งข้อมูลจาก 1 เลนเป็น 4 เลนคู่ขนาน โดยใช้สมการคณิตศาสตร์ (Doubly Stochastic) ควบคุมให้สัญญาณผสมกันได้อย่างเสถียร ไม่หักล้างกันเอง รองรับโมเดลที่ลึกขึ้นโดยแทบไม่เพิ่มภาระการคำนวณ

DeepSeek V4: บีบอัดมิติเวลา (CSA & HCA)

MLA (Baseline)



CSA (Sparse Attention)



HCA (Heavily Compressed)



ที่บริบท '1M tokens',
DeepSeek V4-Flash
ลดการใช้ FLOPs
เหลือเพียง 10%
และลด KV Cache
เหลือเพียง 7%
เมื่อเทียบกับ V3.2

สลับเลเยอร์การทำงานระหว่าง CSA (คัดเลือกเฉพาะบล็อกสำคัญ) และ HCA (บีบอัดมิติเวลา 128 บล็อกเหลือ 1 บล็อก)
ช่วยรีดประสิทธิภาพ Long-Context ขึ้นสุด


The Compression Wars:

ตารางเปรียบเทียบสถาปัตยกรรม

	MODEL	CORE BOTTLENECK ADDRESSED	KEY ARCHITECTURAL HACK	CORE TRADE-OFF
	Gemma 4	Memory Size	`Cross-Layer KV Sharing` + `PLE`	Approximation / Reduced capacity in core layers
	Laguna XS.2	Compute FLOPs	`Layer-Wise Budgeting` (6 vs 8 Q-Heads)	Implementation complexity
	ZAYA1-8B	Latency & FLOPs	`CCA` (Latent Attention + Convolution)	Potential compression data loss
	DeepSeek V4	Extreme Long-Context	`mHC` + `CSA/HCA`	Extreme engineering complexity


ทุกนวัตกรรมคือการแลกเปลี่ยน (Trade-off) ไม่มีสถาปัตยกรรมใดสมบูรณ์แบบ
มีเพียงการเลือกเงื่อนไขทรัพยากรส่วนที่ไม่จำเป็นทิ้งอย่างชาญฉลาด

กายวิภาค Transformer ยุคใหม่ (The Anatomy of a 2026 LLM)



กายวิภาคของ LLM ยุคใหม่ไม่ใช่ Block ทรงสี่เหลี่ยมเรียงง่ายแบบ GPT-2 อีกต่อไป แต่มันคือเครื่องยนต์ที่ถูกปรับแต่งแบบเฉพาะเจาะจง (Heterogeneous Engine) ที่ผสานทุกเทคนิคเพื่อโอบกอดจำกัดทางสถาปัตยกรรม

ความซับซ้อนที่แลกมาด้วยประสิทธิภาพ (Complexity vs. Efficiency)



รูปแบบสถาปัตยกรรมหลักยังคงเป็น Decoder-only แบบเดิม แต่ "ส่วนขยาย" (Tweaks) เหล่านี้เพิ่มความซับซ้อนของโค้ดขึ้นนับสิบเท่า เพื่อบีบให้ต้นทุนการประมวลผลถูกลงที่สุด

บทสรุป (Key Takeaways)



Context is King

ทิศทางการพัฒนาพุ่งเป้าไปที่
ความจุระดับ Long-context
อย่างสมบูรณ์ เพื่อปูทางสู่ระบบ
Agentic AI



Smart Degradation

เรากำลังเรียนรู้วิธี "ทิ้งข้อมูล
อย่างชาญฉลาด" (เช่น แชนจ์ KV,
ทอนเลเยอร์, บัฟเฟอร์มิติเวลา)
โดยไม่กระทบความฉลาดของโมเดล



Architecture Matters Again

แม้ข้อมูล (Data) จะสำคัญที่สุด
แต่โครงสร้างระดับสถาปัตยกรรม
(Architectural Hacks)
คือกุญแจเดียวที่ทำให้ AI เหล่านี้
สามารถนำมาใช้งานจริงได้ในเชิง
เศรษฐศาสตร์