





Numina-Lean-Agent: สถาปัตยกรรมปัญญาประดิษฐ์แบบเปิด สำหรับการใช้เหตุผลทางคณิตศาสตร์เชิงรูปนัย

การเปลี่ยนผ่านจากโมเดลเฉพาะทาง สู่ระบบตัวแทนอัจฉริยะ (Agentic System) ที่ประสานงานเครื่องมือขั้นสูงแบบอัตโนมัติ


ประสิทธิภาพระดับ State-of-the-Art บน Putnam 2025 โดยใช้การทำงานร่วมกันระหว่าง Claude Code และ MCP Ecosystem



คณิตศาสตร์แบบไม่เป็นทางการ



คณิตศาสตร์เชิงรูปนัย - Lean / Isabelle



ข้อจำกัดของระบบในปัจจุบัน



ยึดติดกับ Pipeline เฉพาะกิจ (Task-specific)

ไม่ยืดหยุ่น, ออกแบบมาเพื่อโจทย์เฉพาะด้าน



พึ่งพาโมเดลที่ต้องฝึกฝนอย่างหนัก (Extensively trained formal provers)

ต้องใช้ทรัพยากรการคำนวณและข้อมูลมหาศาล



เป็นระบบปิด (Closed-source) ขยายผลและทำซ้ำได้ยาก

เข้าถึงยาก, จำกัดการพัฒนาและตรวจสอบร่วมกัน




จุดเปลี่ยนผ่านสำคัญ (The Paradigm Shift)

ทำไม General Coding Agent + MCP จึงเหนือกว่า Specialized Math Model?




สถาปัตยกรรมของระบบ: ผู้ควบคุมการก่อสร้าง (The Master Builder)



โมเดลตัวกลางทำหน้าที่ประเมินสถานการณ์และเรียกใช้ 4 เครื่องมืออย่างอิสระเพื่อแก้ปัญหาย่อยแต่ละจุด

เครื่องมือที่ 1: Lean-LSP-MCP (สะพานเชื่อมสู่ระบบ การจัดเตรียมพิสูจน์)



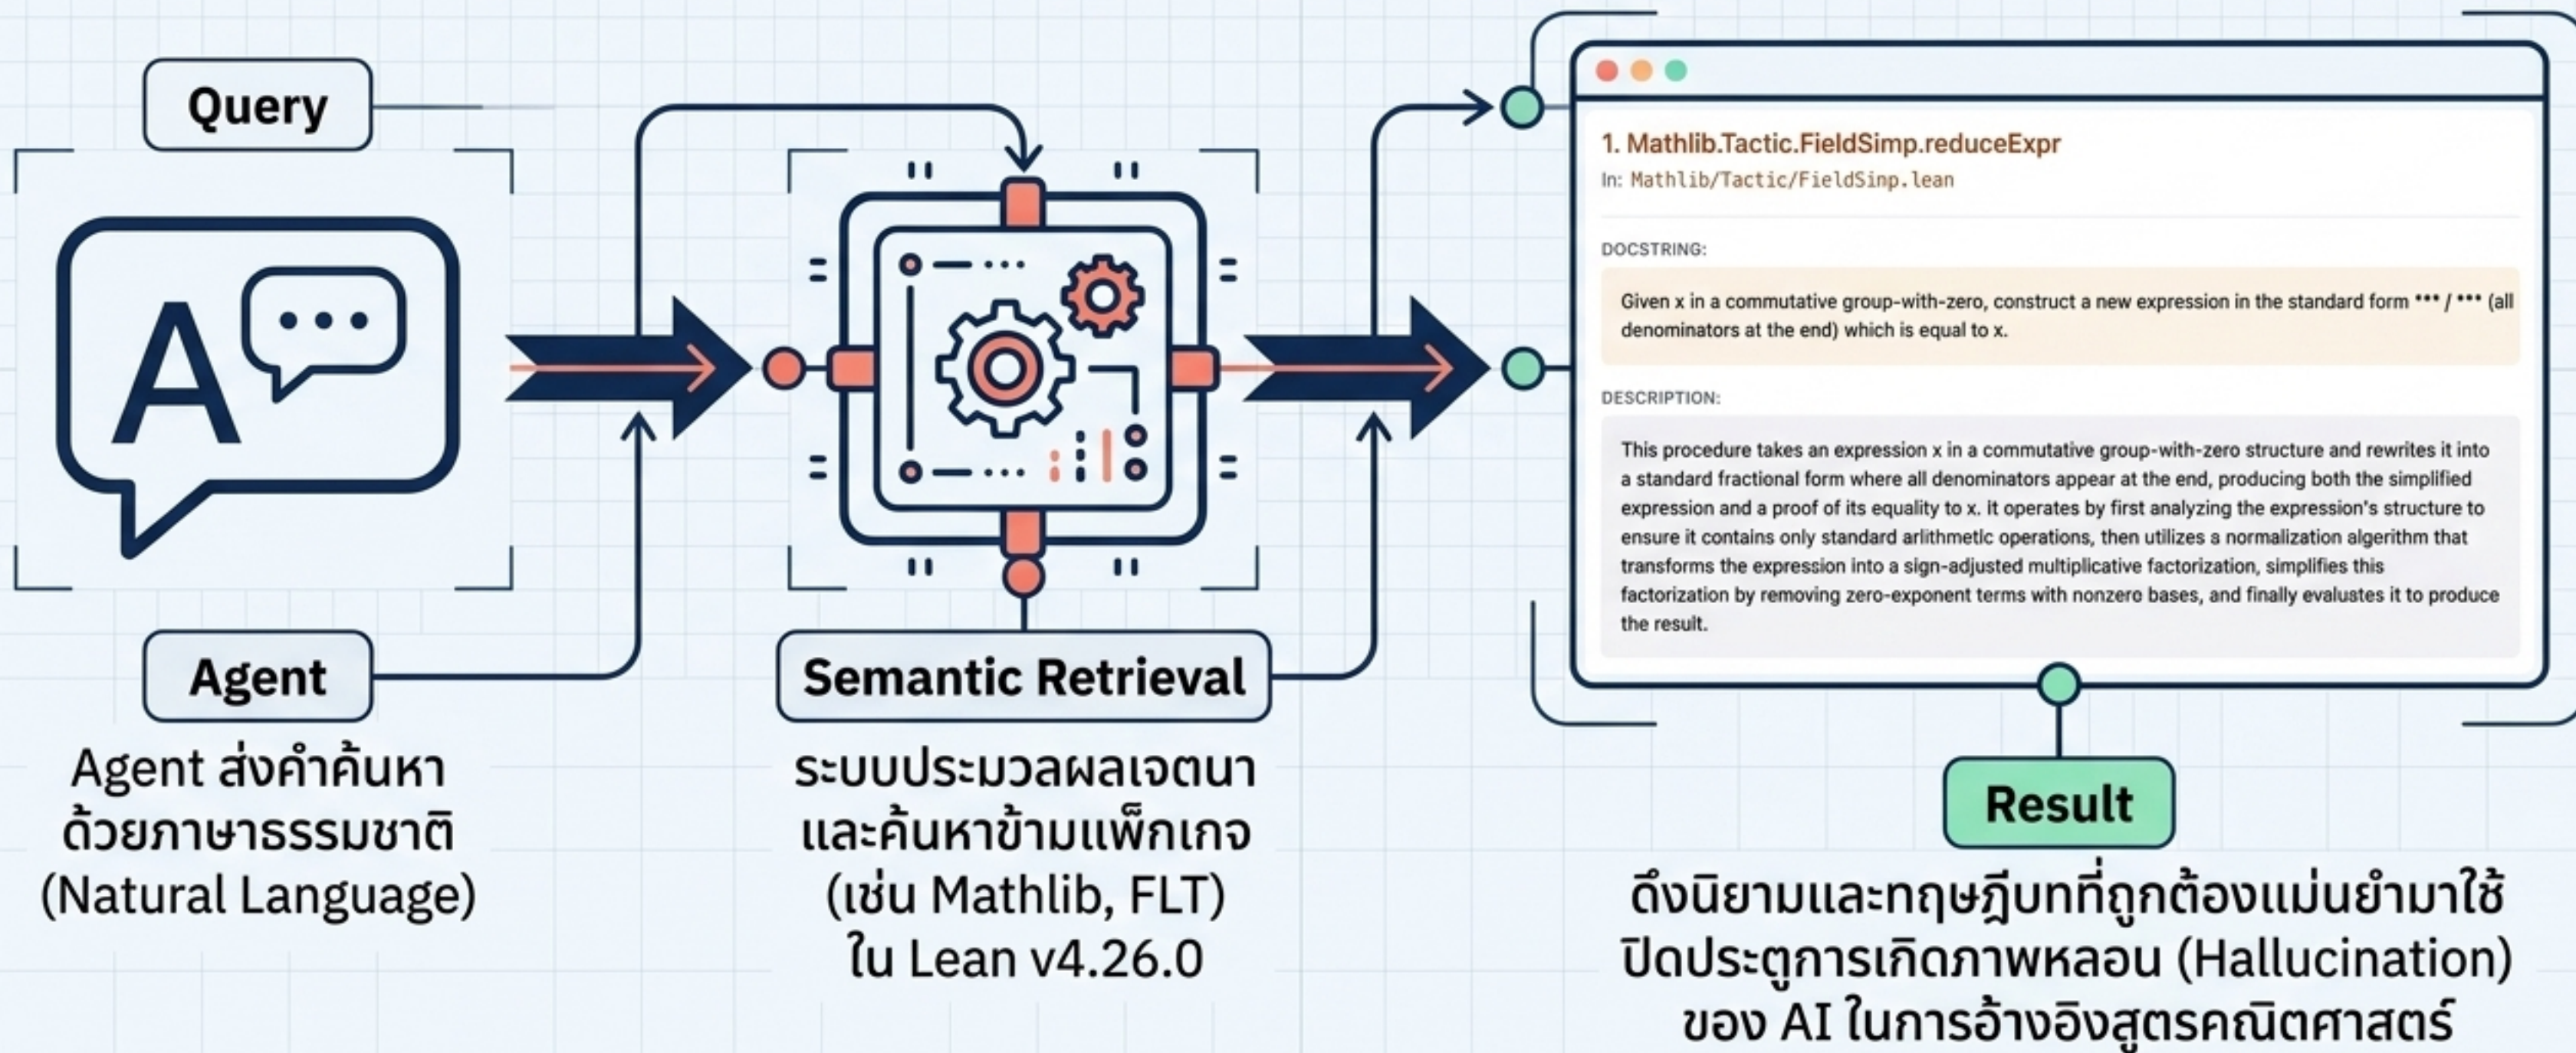
**Step 1: การรับรู้และโต้ตอบ
(Semantic Awareness)**
- ตั้งโครงสร้างไฟล์และเช็คเป้าหมาย
การพิสูจน์ (Proof State)
ป้องกันความผิดพลาด

**Step 2: การทำงานคู่ขนาน
(Strategy Exploration)**
- คอมไพล์โค้ดทดสอบแบบแยกส่วน
ผ่าน `lean_run_code` และใช้
`lean_multi_attempt` ประเมิน
กลยุทธ์หลายทางพร้อมกัน

**Step 3: การแก้ไข
(Closed-Loop
Optimization)**
- นำ Diagnostic Messages
(ข้อผิดพลาด) จาก Lean มา
ปรับแต่งและวนลูปพิสูจน์ใหม่
ทันที


เครื่องมือที่ 2: LeanDex (ระบบฐานข้อมูลความหมายเชิงรุก)

Key Concept: ก้าวข้ามข้อจำกัดของการค้นหาแบบเดิม (เช่น Google หรือ Local Search) ที่บังคับรูปแบบไวยากรณ์ตายตัว




เครื่องมือที่ 3 & 4: การร่างโครงสร้างและการระดมสมอง (Informal Prover & Discussion Partner)

Informal Prover (Gemini IMO Agent)



- ระบบ Generator ร่างบทพิสูจน์ และส่งให้ Verifier ตรวจสอบ
- แก้ไขซ้ำ (Iterative Refinement) ตามคำติชม ทำซ้ำสูงสุด 20 รอบ
- ต้องผ่านการตรวจสอบอิสระ 3 ครั้งจึงจะได้รับการยอมรับ

Discussion Partner



- เมื่อเจอ 'ทางตัน' หรือความคลุมเครือใน Lemma ย่อย
- Claude Code สามารถเรียก AI ตัวอื่นมา 'ปรึกษาหารือ' (Multi-model collaboration)
- เพื่อหาทิศทางในการแก้ปัญหาลใหม่ ช่วยหลุดพ้นจากมุมมองเดิมๆ

การทดสอบ Putnam 2025: ผลลัพธ์ระดับ State-of-the-Art (12/12)

Benchmark Dashboard

Numina-Lean-Agent	✓	(เทียบเท่าโมเดลระบบปิดที่ดีที่สุด)
AxiomProver		(Closed-source ensemble)
Seed-Prover 1.5		
Aristotle (Harmonic)		

ความเข้มงวดในการทดสอบ

ไม่มีสิทธิ์เข้าถึงอินเทอร์เน็ต (Zero online search)
และทำงานแบบลำดับขั้น (Strictly sequential)
ไม่มีการประมวลผลแบบขนาน (No parallelization)

Insight

ชนะกลยุทธ์ Independent Sampling → ✓
แบบขาดลอยด้วยกลยุทธ์ Iterative Refinement


ประสิทธิภาพและความสวยงาม (Efficiency & Elegance)

Time Efficiency (เวลา)




แม้ไม่มีการประมวลผลแบบขนาน (Parallelization) แต่ Numina ทำเวลาได้ดีกว่าคู่แข่งในหลายโจทย์

Code Elegance (ความยาวของโค้ด)



- Numina สร้างสรรค์โค้ดที่ 'สั้นและกระชับกว่า' อย่างมีนัยสำคัญเมื่อเทียบกับ Axiom และ Seed-Prover 1.5 (เห็นได้ชัดในโจทย์ A3, B1 และ B5)
- โค้ดที่สั้นกว่าหมายถึงบทพิสูจน์ที่ตรงประเด็นและลดความซับซ้อนที่ไม่จำเป็น (Compact and efficient formalizations)

การจัดการความซับซ้อนขั้นสุด: กรณีศึกษา Problem A5 (Subagents)




เมื่อเนื้อหาเยอะเกินไป โมเดลจะหลุดโฟกัสและละเลยคำสั่งสำคัญ
ส่งผลให้ติดแหง็กใน Lemma หลัก

The Breakthrough: ระบบ Subagent Mechanism

- แยก Lemma สำคัญออกมาจากเป้าหมายหลัก
- เรียกใช้ GPT-5.2 เพื่อสร้างคำใบ้ (Informal Hint) เฉพาะเจาะจง
- ให้ Subagent ดำเนินการพิสูจน์ย่อยแบบแยกขาดอิสระ จนกว่าจะสำเร็จ
- นำผลลัพธ์กลับมารวบรวมกัน ป้องกันอาการหลงทางในบริบทที่ลึกเกินไป


กลยุทธ์พิมพ์เขียว (The Blueprint Strategy: Plan-Formalize-Refine)

The Concept: การพิสูจน์ระยะยาวไม่สามารถทำแบบรวดเดียวจบ (One-shot) ต้องใช้แผนผัง (DAG) ที่กำหนดลำดับชั้นของ Lemma



การวิจัยร่วมระหว่างมนุษย์และ AI (Human-AI Vibe Proving)

Case Study: The Brascamp-Lieb Theorem (ทำงานร่วมกับนักคณิตศาสตร์ตัวจริง)



ข้อจำกัดในปัจจุบัน และรุ่งอรุณแห่งคณิตศาสตร์แบบเปิด



ข้อจำกัดที่ต้องพัฒนาต่อ (Limitations)

- **Verbosity:** โค้ดที่สร้างในระดับโครงสร้างใหญ่บางครั้งยังเย็นเยื่อ ขาดความเป็น Idiomatic Mathlib (ความสวยงามเชิงโครงสร้างแบบมนุษย์)
- **Type-Level Constraints:** ความท้าทายในการแปลง Type (เช่น Real vs NNReal) ซึ่ง AI มักมองข้ามเนื่องจากความคุ้นเคยในคณิตศาสตร์แบบไม่เป็นทางการ



อนาคต (The Future)

Numina-Lean-Agent พิสูจน์แล้วว่าการเชื่อมต่อโมเดลทั่วไปเข้ากับเครื่องมือเฉพาะทาง (General Agent + MCP) คือก้าวต่อไปที่ทรงพลัง และที่สำคัญที่สุดคือ เป็นระบบเปิด (Open-source) ที่พร้อมให้คอมมูนิตี้นำไปต่อยอดได้อย่างไร้ขีดจำกัด