




ทรัพยากรที่ถูกมองข้ามในการฝึกฝน AI



- โมเดล AI ในปัจจุบันทิ้งข้อมูลที่มีค่าที่สุดไปทันทีหลังจากการโต้ตอบ
- สัญญาณ Next-State Signal คือกุญแจสำคัญสู่การเรียนรู้อย่างต่อเนื่อง (Continuous Online Learning)

การรื้อไหลของข้อมูลสองรูปแบบในระบบปัจจุบัน



Waste 1: สัญญาณประเมินผล (Evaluative)

ปฏิกิริยาตอบรับที่บ่งบอกว่าผลลัพธ์นั้น ดี หรือ แย่
(เช่น การที่ผู้ใช้ถามคำถามเดิมซ้ำ หรือไต่ดรนผ่าน)
ซึ่งมักถูกมองข้ามในการฝึกฝนแบบดั้งเดิม

Waste 2: สัญญาณบอกทิศทาง (Directive)

คำวิจารณ์ที่ระบุชัดเจนว่าควรแก้ไข Token ไหนและอย่างไร
ซึ่งไม่สามารถจับได้ด้วยระบบ Scalar Reward ทั่วไป

OpenClaw-RL: เปลี่ยนผ่านสู่การเรียนรู้แบบต่อเนื่อง




OpenClaw-RL

Offline Batch Training



Continuous Live Learning




โครงสร้างพื้นฐานที่เปลี่ยนปรัชญา
การทำงานของ Agent

ดักจับ Next-State Signals
แบบเรียลไทม์

อัปเดตโมเดลโดยไม่รบกวนการให้บริการ
(Zero Serving Interruption)

สัญญาณ Next-State คือภาษาสากลของทุก Agent



Terminal

Signal:
Stdout/stderr,
Exit code
(Long Horizon)



GUI

Signal:
Screen state diff,
Accessibility tree
(Long Horizon)



SWE

Signal:
Test verdicts,
Lint output
(Long Horizon)




Tool-call

Signal:
Return values,
Error traces
(Medium Horizon)

ไม่ว่าจะเป็น Personal Agent หรือ General Agent ทุกการกระทำล้วนสร้างปฏิกิริยาตอบสนอง
OpenClaw-RL มองทุกสภาพแวดล้อมเป็นแหล่งข้อมูลสำหรับฝึกฝน Policy เดียวกัน

กลไกทำงานแบบ Asynchronous ไร้รอยต่อ



Decoupled Architecture

- ทั้ง 4 ส่วนทำงานแยกอิสระจากกัน

Zero Wait Time

- โมเดลให้บริการคำขอใหม่ ในขณะที่ PRM ประเมินคำตอบเก่า และระบบ Trainer อัปเดตน้ำหนัก (Weights) ไปพร้อมกัน

สองกลไกสกัดข้อมูลจากปฏิกิริยาตอบกลับ

Binary RL

Signal Type:
Evaluative

Advantage:
Scalar

Feedback:
Implicit/Explicit

ให้ความครอบคลุม (Coverage) ประเมินผลแบบ Turn-by-turn

Hindsight-Guided OPD

Signal Type:
Directional

Advantage:
Token-level

Feedback:
Explicit Corrections only


ให้ความละเอียดระดับ Token แนะนำทิศทางที่ถูกต้องอย่างแม่นยำ

Combined Method

ผสมผสาน w_{binary} และ w_{opd}

ระบบออกแบบมาให้ใช้งานร่วมกันเพื่อประสิทธิภาพสูงสุด โดยดึงจุดเด่นของทั้งสองฝั่งมาทำงานผสมกัน


Binary RL: เปลี่ยนผลลัพธ์เป็นคะแนนประเมินผลแบบเรียลไทม์




สร้าง Process Reward
จากสัญญาณ Next-State
โดยไม่ต้องใช้มนุษย์กำกับข้อมูล

ใช้เสียงข้างมาก (Majority Vote) จาก PRM
เพื่อประเมินความพึงพอใจของผู้ใช้หรือ
ความสำเร็จของโค้ด

Hindsight-Guided OPD: เปลี่ยนคำวิจารณ์เป็นทิศทาง



การปรับแต่งระดับ Token (Token-Level Advantage)



Scalar Advantage

ให้ค่าคะแนนเดียวกับทุก Token
ในประโยคอย่างเท่าเทียมกัน

Directional Advantage

แนะนำโมเดลได้อย่างแม่นยำว่าควรลดน้ำหนัก Token ไດ
และเพิ่มน้ำหนัก Token ไດในบริบทเดียวกัน


Process Reward: จุดตรวจสำหรับงานที่ซับซ้อน



- งานอย่าง GUI หรือ SWE ต้องการการให้คะแนนและการตรวจสอบในทุกๆ ขั้นตอน
- ผสาน Outcome Reward เข้ากับ Process Reward จาก PRM เพื่อนำทาง Agent ไม่ให้หลงทางใน Task ที่ยาวนาน




แดชบอร์ดแสดงผลสัมฤทธิ์: Personal Agents

	Base Model	Updated (8 steps)
Student	0.17	0.76
Teacher	0.22	0.90




- การทดสอบ: ทักษะการตอบคำถามของนักเรียน และ ทักษะการตรวจการบ้านของครู
- ผลลัพธ์: การใช้แบบผสม (Combined Method) ใช้เวลาเพียงไม่กี่รอบการสนทนาเพื่อปรับสไตล์ให้เป็นธรรมชาติและตรงใจผู้ใช้มากที่สุด
- โมเดลเรียนรู้ที่จะละทิ้งแพทเทิร์นแบบ "หุ่นยนต์" โดยอัตโนมัติ

แดชบอร์ดแสดงผลสัมฤทธิ์: General Agents



- Scalability: รองรับสภาพแวดล้อมแบบคู่ขนานสูงกว่า 128 Environments บนระบบ Cloud
- ประสิทธิภาพเพิ่มขึ้นอย่างต่อเนื่องในทุกรูปแบบการทำงาน ตั้งแต่การจัดการ Terminal ไปจนถึงการใช้งาน GUI

วิสัยทัศน์ของ Agent ที่เก่งขึ้นทุกครั้งที่ถูกใช้งาน



- จากข้อมูลที่เคยถูกทิ้ง
สู่ระบบวิเคราะห์ข้อมูล
(Live Telemetry Refinery)
ที่ทรงพลัง

- ก้าวข้ามข้อจำกัดของ Dataset ที่ตายตัว
สู่ยุคของโมเดลที่พัฒนาตัวเองแบบ
Real-time ผ่านการโต้ตอบในโลก
ความเป็นจริง

- OpenClaw-RL:
โครงสร้างพื้นฐานแห่งอนาคต
สำหรับ AI Agent ทุกรูปแบบ