



Qwen3 & Qwen3.5: ยุคใหม่แห่งโมเดลภาษา

จาก 'Thinking Mode' สู่ 'Hybrid Architecture' - การก้าวกระโดดสู่ AGI

TECHNICAL REPORT OVERVIEW | 2025-2026 ROADMAP

Qwen3: การปฏิวัติทางความคิด (Cognitive Revolution)

- Thinking Mode
- รองรับ 119 ภาษา
- สถาปัตยกรรม MoE

2025


Qwen3.5: วิวัฒนาการสถาปัตยกรรม (Architectural Evolution)

- Hybrid Attention (Gated DeltaNet)
- รองรับ 201 ภาษา
- Native Multimodal

2026

**Qwen ไม่ได้แค่สร้างโมเดลที่ใหญ่ขึ้น
แต่สร้างโมเดลที่ ‘คิด’ ได้ลึกซึ้งและ ‘ทำงาน’ ได้รวดเร็วยิ่งขึ้น**


การรวมสองระบบไว้ในหนึ่งเดียว: Thinking & Non-Thinking Mode



สถาปัตยกรรม MoE: ประสิทธิภาพสูงสุดที่ต้นทุนต่ำกว่า

Active Params:
22 Billion

Total Params:
235 Billion



Model:	Qwen3-235B-A22B
Total Experts:	128
Activated Experts:	8

ประสิทธิภาพระดับโมเดลยักษ์ใหญ่ (235B) แต่ใช้ทรัพยากรประมวลผลเพียงส่วนน้อย (22B)

รากฐานที่แข็งแกร่ง: ข้อมูล 36 ล้านล้านโทเคน

36T 119

คลังข้อมูลขนาดมหึมา (Massive Dataset)

ภาษา (Languages)

กระบวนการ Pre-training 3 ขั้นตอน:


สร้างพื้นฐานความรู้ → เพิ่มทักษะ STEM/Code → ขยาย Context Length (32k)

กระบวนการ Post-Training 4 ขั้นตอนเพื่อสร้าง “Thinking Mode”




เปลี่ยนจากโมเดลภาษาทั่วไป สู่โมเดลที่มีกระบวนการคิด

Strong-to-Weak Distillation: ประสิทธิภาพ ระดับเรือธงในขนาดพกพา




- ลดเวลาการฝึก GPU ลง 90%
- สร้างโมเดลขนาดเล็ก (0.6B - 32B) ที่มีความสามารถในการ 'คิด' เกินตัว

ความเป็นเลิศด้านการให้เหตุผล (STEM & Coding)




ประสิทธิภาพที่เหนือกว่าในด้านคณิตศาสตร์และการเขียนโปรแกรมด้วยพลังของ Thinking Mode

พลังแห่ง 'Thinking Budget': ควบคุมความลึกซึ้งของการคิด




ความท้าทายใหม่: คอขวดของ Attention ในบริบทระยะยาว



เมื่อโมเดล 'คิด' มากขึ้น ความยาวของบริบท (Context) ก็เพิ่มขึ้นทวีคูณ สถาปัตยกรรมแบบเดิมจึงทำงานได้ช้า


ถึงเวลาของ Qwen3.5

สถาปัตยกรรม Hybrid Attention: ความแม่นยำพบกับความเร็ว



- Ratio 3:1 - ประมวลผลบริบทระยะยาวได้เร็วกว่าโดยไม่สูญเสียความแม่นยำ

Qwen3.5: ออกแบบมาเพื่อยุคแห่ง AI Agent




Model:	Qwen3.5-397B-A17B
Context Window:	1,000,000 Tokens
Training:	RL on Million-agent environments
Specialty:	Asynchronous RL for Long-horizon tasks

มาตรฐานใหม่: ผู้นำด้าน Instruction Following และ Vision



ระบบนิเวศที่ไร้พรมแดน: Multilingual และ Multimodal



ไม่ต้องใช้ฮาร์ดแวร์แยก โมเดลเข้าใจภาพและข้อความในระดับโครงสร้าง

บทสรุป: เปลี่ยนสนาามรบจาก ‘ขนาด’ สู่ ‘ประสิทธิภาพ’

- **Qwen3:** ปลดล็อกศักยภาพการให้เหตุผล
- **Qwen3.5:** ปลดล็อกขีดจำกัดทางสถาปัตยกรรม

Qwen3 (Thinking Mode)

Qwen3.5 (Hybrid Efficiency)

AGI

**“Qwen กำลังสร้างอนาคตที่ AI สามารถคิดได้ลึกซึ้ง
และทำงานได้รวดเร็วไปพร้อมกัน”**

