


RELGT: สถาปัตยกรรม

TABLE PROJECTS


ก้าวข้ามข้อจำกัดของ GNN ด้วยเทคโนโลยี
ที่ออกแบบมาเพื่อข้อมูล Enterprise

RELGT: สถาปัตยกรรม Graph Transformer แห่งอนาคตสำหรับฐานข้อมูลเชิงสัมพันธ์

ก้าวข้ามข้อจำกัดของ GNN ด้วยเทคโนโลยี Relational Deep Learning ที่ออกแบบมาเพื่อข้อมูล Enterprise ระดับสเกลโดยเฉพาะ




ชุดทรัพยากรข้อมูลที่ถูกซ่อนอยู่ในโครงสร้างตาราง



แต่เครื่องมือหลักในปัจจุบันอย่าง **Graph Neural Networks (GNNs)** กำลังเผชิญกับ 'กำแพง' สำคัญ...


ปัญหาของ GNN: คอขวดข้อมูล (The Information Bottleneck)

Standard 2-Layer GNN



Node T1 และ T2 ถูกค้นด้วย C เสมอ (ห่างกัน 2 hop)
ในขณะที่ P1 และ P2 แทบจะไม่มีโอกาสแลกเปลี่ยนข้อมูลกันโดยตรง
เพราะติดข้อจำกัดเชิงโครงสร้าง (Structural Constraints)
การส่งผ่านข้อมูลต้องผ่านหลายชั้นและสูญหาย

Full-Attention GT




เส้นนำแสงสีนีออนพุ่งตรงเชื่อม P1 กับ P2 ได้ทันที
มองเห็นบริบททั้งหมดข้ามข้อจำกัดของ Hop

Key Stat Box

ในสถาปัตยกรรม GNN แบบ 2 ชั้น Product 2 ตัวจะไม่มีทางปฏิสัมพันธ์กันได้โดยตรง (Robinson et al., 2024)

ทำไม Graph Transformer ทั่วไปจึงล้มเหลวในระดับสากล?

Heterogeneity (ความหลากหลายของโหนด)



GT ทั่วไปมองทุกโหนดเหมือนกัน
ไม่เข้าใจความแตกต่างระหว่างตาราง
(เช่น User vs Product)

Temporal Leakage (ข้อมูลรั่วไหลข้ามเวลา)



ขาดกลไกควบคุมเวลา
ทำให้โมเดลแอบดู 'ข้อมูลในอนาคต'
มาทำนายอดีต

The Precomputation Penalty (ข้อจำกัดด้านการคำนวณ)




Positional Encodings (PEs) แบบเดิม
(เช่น Laplacian) ต้องคำนวณล่วงหน้า
ทั้งกราฟ ซึ่งเป็นไปไม่ได้กับฐาน
ข้อมูลขนาดหลายล้านเรคคอร์ด

ฐานข้อมูลเชิงสัมพันธ์ต้องการสถาปัตยกรรมที่สร้างขึ้นมาโดยเฉพาะ...

แนะนำ RELGT: สถาปัตยกรรมที่ออกแบบมาเพื่อข้อมูลเชิงสัมพันธ์โดยเฉพาะ

นวัตกรรมที่ประสาน Tokenization แบบแยกส่วน เข้ากับเครือข่าย Local-Global Attention



1. Relational Entity Graph

ข้อมูลดิบที่มีทั้งเวลาและประเภทโหนด

2. Tokenization

แปลงโหนดเป้าหมาย (Seed Node) และโหนดรอบข้างให้เป็น Multi-element Tokens


3. Transformer Network

ประมวลผลคู่ขนานผ่าน Local Context และ Global Centroids

4. Prediction Heads

ทำนายผลลัพธ์ระดับองค์กร (เช่น User Churn, Item Sales)

กายวิภาคของ RELGT Token: ถอดรหัส 5 องค์ประกอบ



นำองค์ประกอบทั้ง 5 มารวมกันเป็น 'Super Token' 1 ตัว
โดยไม่ต้องคำนวณกราฟล่วงหน้าทั้งระบบ (No global precomputation)


Positional Encoding Showdown: ทลายคอขวดด้านการคำนวณ

ทำไม Subgraph GNN PE จึงมีประสิทธิภาพเหนือกว่า Laplacian PE สำหรับฐานข้อมูลเชิงสัมพันธ์

	Traditional Laplacian PE	RELGT Subgraph PE
Runtime Overhead (ภาระการประมวลผล)	สูงมาก ($O(N^3)$) ต้องคำนวณล่วงหน้า 	ต่ำมาก (คำนวณเฉพาะใน Subgraph K โหนด) 
Breaking Symmetry (การแยกแยะโหนด ที่หน้าตาเหมือนกัน)	ล้มเหลวในกราฟขนาดใหญ่และหลากหลาย 	ใช้ Random Node Features Initialization สุ่มค่าเริ่มใหม่ทุกรอบการเทรน เพื่อสร้างความแตกต่างให้ Parent-Child relationships 


การใช้ Random Features ทำให้ความแม่นยำสูงขึ้น
โดยไม่ต้องรับ Laplacian ให้เปลืองทรัพยากร

กลไก Local-Global Attention: โฟกัสจุดเล็ก พร้อมมองเห็นภาพใหญ่



Local Attention (โฟกัสเฉพาะที่)

All-Pair Self-Attention ภายในกลุ่มโหนดรอบข้าง ($K=300$)
แลกเปลี่ยนข้อมูลเชิงลึกตาม Schema ของฐานข้อมูล
ข้ามข้อจำกัดของ GNN



Global Attention (มองเห็นภาพใหญ่)

เข้ารหัสโหนดทั้งหมดผ่าน Learnable Centroids ($B=4096$)
อัปเดตแบบไดนามิก (EMA K-Means)
ดึงบริบทภาพรวมของทั้งองค์กรโดยไม่ต้องคำนวณกราฟที่แสดง


รวม Local + Global ผ่าน Transformer Layers ($L=4$)
สร้าง Representation ที่สมบูรณ์แบบ

RDL Landscape: ข้อได้เปรียบทางสถาปัตยกรรม

	Flat Tabular Models (XGBoost)	Standard GNNs (HeteroGNN)	Heterogeneous GTs (HGT+PE)	RELGT (Ours)
รองรับข้อมูลต่างประเภท (Heterogeneity)	✗	✓	✓	✓
ป้องกันการรั่วไหลของเวลา (Temporal-Aware)	—	✓	✗	✓
จับความสัมพันธ์ระยะไกล (Long-Range)	✗	✗	✓	✓
สเกลได้โดยไม่ต้อง Precompute กราฟ	✓	✓	✗	✓

พิสูจน์ด้วยข้อมูล: ทูบสถิติ RelBench Benchmark


RELGT เอาชนะหรือเทียบเท่า RDL Baseline ใน 19 จาก 21 งานทดสอบ



Conclusion Text:

การใช้ Multi-element Tokenization ทำให้โมเดลเข้าใจ
โครงสร้างลึกซึ้งกว่าเดิม ส่งผลต่อความแม่นยำอย่างมีนัยสำคัญ

ความเร็วที่ใช้งานได้จริง: หลีกเลียง “The Precomputation Penalty”



Takeaway Box

Graph Transformer แบบเดิม (HGT+PE) เสียเวลาคำนวณ Laplacian PE นานขึ้นสูงสุดถึง 8.62 เท่า

RELGT ขจัดปัญหานี้สิ้นเชิงด้วย Subgraph GNN PE ทำให้ได้ทั้งความเร็วของ GNN และความฉลาดของ Transformer

RELGT: นิยามใหม่ของ Relational Deep Learning



1. Natively Relational

สถาปัตยกรรมแรกๆที่เข้าใจ โครงสร้างตาราง, เวลา, และความหลากหลายของข้อมูลอย่างแท้จริงผ่านระบบ 5-Part Tokenization

2. Unbounded Context

ทำลายขอบเขต 2-hop ของ GNN เชื่อมโยงข้อมูลทั้งองค์กรผ่าน Local-Global Attention

3. Enterprise Scalability

ตัดวงจร Precomputation ที่กินทรัพยากร พร้อมใช้งานกับฐานข้อมูลขนาดมหาศาล

หมดยุคของการทำ Manual Feature Engineering.
RELGT คือรากฐานใหม่สำหรับการสร้าง Foundation Models บนฐานข้อมูลเชิงสัมพันธ์ขององค์กร.