



The Paradigm Shift: คู่มือสเกล RL Compute ในยุคของ Reasoning Models

ถอดรหัส Scaling Laws จาก Pretraining

สู่ Group Relative Policy Optimization (GRPO)

สำหรับ AI Researchers และ Tech Leaders




$$C = 6ND$$

Compute / FLOPs

Model Parameters

Tokens Observed

ในการทำ Pretraining เราสามารถทำนายประสิทธิภาพล่วงหน้าได้อย่างแม่นยำ ประสิทธิภาพจะเพิ่มขึ้นแบบ Power Law เมื่อเราเพิ่ม Data และ Compute



Inverse Power Law: ข้อความฉลาดได้ด้วยการเพิ่ม FLOPs เป็นเส้นตรงแบบคาดเดาได้

DeepSeek-R1-Zero ใช้เวลาถึง **100,000 H800 GPU hours**
สำหรับ RL (**3.75%** ของ Pretraining Compute)
จากโมเดล o1 ถึง o3 การใช้ RL Compute **พุ่งสูงขึ้นกว่า 10 เท่า**

Pretraining

RL Training Compute

30%


Reasoning Models เปลี่ยนคอบวดของการเทรน จากการพึ่งพาข้อมูลดิบ
กลายเป็นการใช้ RL เพื่อค้นหาตรรกะที่ถูกต้อง การเทรนไม่ได้เป็นเส้นตรงอีกต่อไป!

The Optimizer Matrix

	PPO	GRPO
Architecture	Requires Heavy Value Model (Critic)	No Value Model required
Advantage Baseline	Generalized Advantage Estimation (GAE)	Group Mean & Standard Deviation (Relative scores)
Compute Overhead	Heavy (Memory bottleneck)	Lightweight (Highly scalable)


GRPO คือขุมพลังเบื้องหลัง DeepSeek-R1 ตัด Value Model ทิ้งเพื่อปลดล็อกหน่วยความจำ ให้โมเดลสเกล Rollouts ได้มหาศาล

The GRPO Process: A Circular Flow




GRPO ใช้กระบวนการแบบวนซ้ำ (Iterative Loop) ที่ไม่พึ่งพา Critic Model ทำให้การเทรนมีประสิทธิภาพและขยายสเกลได้ง่าย

Advanced GRPO Optimizations: Patches & Fixes




การปรับปรุงเหล่านี้ช่วยแก้ปัญหาเฉพาะในการเทรน GRPO เพื่อประสิทธิภาพสูงสุดและความเสถียรในการใช้งานจริง

$$\text{Reward} = \frac{A}{[1 + (C_{\text{mid}} / C)^B]}$$



ใน RL การเปลี่ยน
Algorithm มักจะช่วย
เพิ่มความชัน (B)
มากกว่าเพิ่มเพดาน (A)
การจะทะลุเพดานต้อง
ใช้สเกลที่ใหญ่ขึ้น!

Compute Efficiency & Model Size



Low Compute Budget:

โมเดล 32B ชนะ!


ภายใต้ FLOPs จำกัด โมเดลเล็กทำ
Update Steps (M) ได้มากกว่า

High Compute Budget:

โมเดล 72B ชนะชนะ!


Learning Efficiency
ของโมเดลเล็กเริ่มอิ่มตัว

Rule of Thumb: หากมีงบ Compute จำกัด
การใช้โมเดลขนาดกลางแล้วเทรนหลาย Steps ค่อนข้างดีกว่าโมเดลยักษ์



Scaling RL to Breakthrough Performance

Easy Problems



Hard Problems



การสเกล RL ให้เก่งทะลุขีดจำกัด ไม่ใช่แค่การเทรนยาวขึ้น (M) แต่คือการลงทุนใน Sampling Compute (n)!

Easy: การเพิ่ม n ช่วยเรื่อง Policy Robustness ลดโอกาสตอบผิด

Hard: การเพิ่ม n เป็นกุญแจสำคัญ! ช่วยให้เห็น Rare reasoning paths ทำให้ S-Curve ทะลุเพดาน (พิจารณาถอด Regularization เพื่อไม่ให้ขัดขวาง Exploration)

The ScaleRL Playbook



Split Generator-Trainer Engine

แยก vLLM และ FSDP ออกจากกันแบบ Asynchronous เพื่อลด GPU Idle



Float32 LM Head

ใช้ Precision เต็มที่ Layer สุดท้ายเพื่อลด Mismatch ของ Token Probabilities



Smart Batching

กรอง Prompts ที่มี Zero-Variance ทั้งหมดที่ เพราะไม่เกิด Gradient



Bounded Context

บังคับจบการคิดด้วย Token พิเศษหากาก 12K tokens เพื่อประหยัด Compute

Comparing Pretraining & RL Scaling Laws

	Pretraining Laws	RL Scaling Laws
Primary Metric	Cross-entropy loss (นึ่ง, มาตรฐาน)	Reward / Pass@K (แกว่ง, ขึ้นอยู่กับโดเมน)
Compute Definition	Clean FLOPs ($C=6ND$)	Messy (GPU hours + Sampling Compute $B_p \times n$)
Extrapolation Scope	Inter-model	Inter-model & Intra-model
Standardization	Highly Standardized	Bespoke (อัลกอริทึมเปลี่ยน รูปทรงกราฟเปลี่ยน)

01

Extrapolate Early

ทดสอบและทำนาย:
ใช้ Intra-model
extrapolation
พัฒนาการจากช่วงต้น
เพื่อใช้ความคุ้มค่า

02

Match Model to Compute

เลือกไซส์ให้ตรงงบ:
งบน้อยเลือก 32B เน้น
Steps, งบเยอะเลือก
72B+ เน้น Efficiency

03

Push Resources to n

ทุ่มงบไปที่ Rollouts:
สำหรับโจทย์ยาก การเพิ่ม
Sampling n คือเคล็ดลับ
ลับสู่ Aha Moment

**Scale is no longer just about data.
In the reasoning era, Scale is about Exploration.**