

SIAMGPT-32B: วิศวกรรมความ มั่นยำ เพื่อภาษาไทย

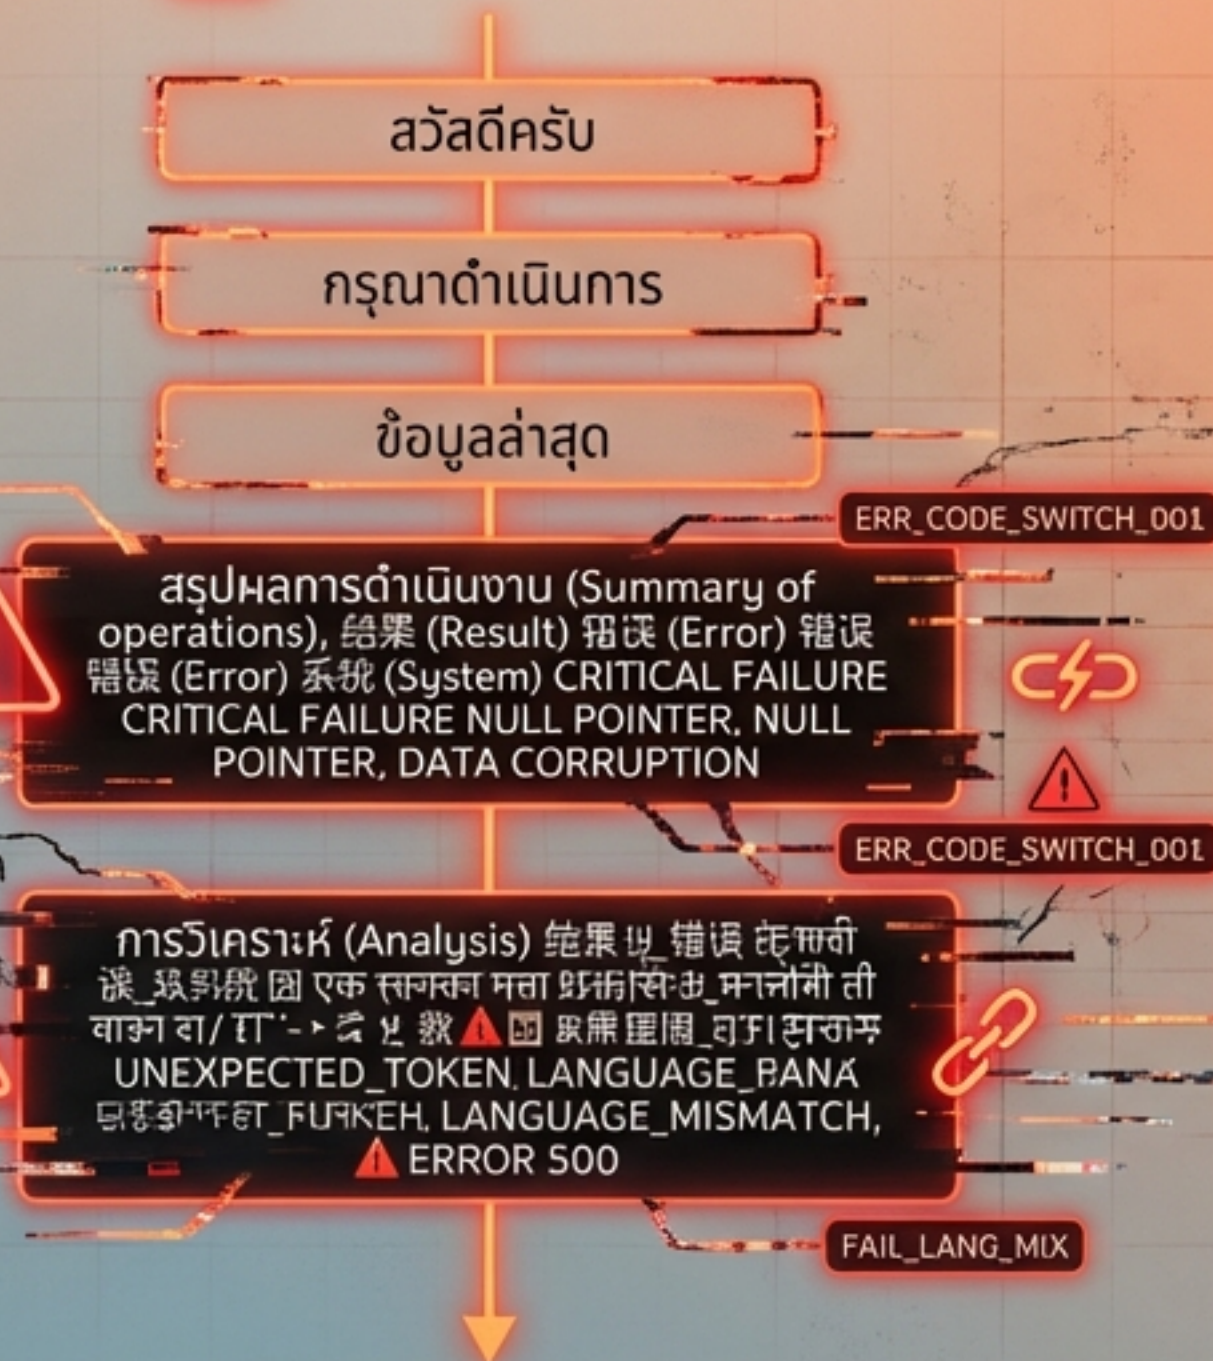
- โมเดลแบบ Open-Weights ขนาด 32B ที่ออกแบบมาเพื่อความเสถียรขั้นสุด

- สร้างขึ้นจากฐาน Qwen3-32B ด้วยกลยุทธ์ Quality-First



ปัญหาข้อขัดข้องของการใช้งานจริง: อาการ Code-Switching

The Problem




LLMs ระดับโลกมักประสบปัญหาความไม่เสถียรเมื่อเออคำสั่งภาษาไทยที่ซับซ้อน
เกิดการแทรกคำภาษาอื่น (จีน, ฮินดี, อังกฤษ) ในผลลัพธ์ภาษาไทย

✔ The Solution (The Impact)




ทำให้ระบบพึ่งและขาดความน่าเชื่อถือเมื่อนำไปใช้งานจริง (Production)

บทบาทเป้าหมาย: ตัวสร้างคำตอบสุดท้ายในระบบ Agentic



- โมเดลไม่ได้ถูกออกแบบมาเพื่อจินตนาการเปิดกว้าง แต่เพื่อเป็น โหนดสุดท้ายที่ไว้ใจได้ (Final Response Generator)
- ต้องการการปฏิบัติตามข้อกำหนดทางรูปแบบที่เข้มงวด (Strict Formatting)
- มุ่งเน้นความสอดคล้องของบริบท (Contextual Consistency) ขั้นสูงสุด

แนวคิดหลัก: ปริมาณข้อมูลมหาศาลบ่อนทำลายความเสถียร




ไม่ใช่ Continual Pre-training
หรือฐานข้อมูลมหาศาลอย่างไร้ทิศทาง



ใช้เพียง SFT (Supervised Fine-Tuning)
บนชุดข้อมูลความละเอียดสูงที่ผ่านการคัดกรอง
อย่างเข้มงวด (Quality-First)

งดเว้นการใช้ DPO หรือ RLHF ที่อาจทำให้เกิดความไม่เสถียรในเชิงโครงสร้างภาษา

สถาปัตยกรรมข้อมูลแบบสายคู่ (Dual-Stream Pipeline)



ระบบตรวจสอบด้วย AutoIF: บังคับใช้กฎอย่างเด็ดขาด



บทสรุปเชิงโครงสร้าง: ข้อจำกัดสร้างความแม่นยำ



สกัดกั้นข้อมูลขยะด้วยกฎเกณฑ์ AutoIF
ทำให้โมเดลไม่ต้องเดาหรืออนุมานรูปแบบเอง

ยกระดับการปฏิบัติตามคำสั่ง (Instruction Following) อย่างเหนือชั้น และลดอาการ Code-Switching จนเกือบเป็นศูนย์


การยกระดับประสิทธิภาพจากโมเดลฐาน (Qwen3-32B)

IF-Eval




ปฏิบัติตามคำสั่ง
(IF-Eval)
+7.53

MT-Bench



การสนทนาต่อเนื่อง
(MT-Bench)
พุ่งทะยาน +17.87

Code-Switching



ความเสถียรทางภาษา
(Code-Switching)
ไร้ร่องรอยภาษาอื่น


ตารางเปรียบเทียบโมเดล Open-Weights

กลุ่ม 30B-32B (SEA-HELM)


ความสามารถ (Dimensions)	SiamGPT-32B	Typhoon 2.5 30B	OTG-R1 32B
Instruction Following	👑 83.00 (ชนะเลิศ)	79.00	54.00
Multi-Turn Dialogue	75.81	76.61	59.69
Natural Language Understanding	👑 67.95 (ชนะเลิศ)	65.56	59.89



**SiamGPT ครองแชมป์คะแนน
เฉลี่ยรวมสูงสุดที่ 63.60**



ชนะเลิศในด้านความเข้าใจ, ตรรกะ, และความปลอดภัย



NLU: เข้าใจบริบทเชิงลึกได้ดีที่สุด



**NLR: นำห่างคู่แข่งกว่า 5-13 จุด
แสดงถึงตรรกะที่แข็งแกร่ง**



**Safety: ตรวจจับข้อความ
ที่เป็นพิษได้แม่นยำที่สุด**

ความเป็นจริงของข้อแลกเปลี่ยน: ความเสถียร แลกกับ ความลื่นไหลอิสระ

**ความเสถียร &
การรักษาฟอร์แมต**
(Stability & Format Control)

บังคับใช้กฎอย่างเข้มงวด
ลดอาการหลอนร้อยเปอร์เซ็นต์



ความเป็นธรรมชาติ
(Generative Naturalness / NLG)

สาเหตุ: เป็นผลจากการออกแบบที่องอาจ
โมเดลลดความลื่นไหลในการสร้างสรรค์ข้อความแบบ
เปิดกว้างลง เพื่อแลกกับความสามารถในการเป็น Final
Response Generator ที่ทำงานไม่ผิดพลาด

ข้อควรระวังในการใช้งาน และ อนาคต (Future Work)

ข้อกำหนดการใช้งานปัจจุบัน (Current Guardrails)



- ควรใช้ร่วมกับระบบ RAG (Retrieval) เพื่อให้มีข้อมูลอ้างอิงและลดการสร้างข้อมูลเท็จ



- แนะนำให้ตั้งค่า Decoding Controls อย่างรัดกุมเพื่อป้องกันอาการพิมพ์วนซ้ำ (Looping) เมื่อใช้งานแบบเปิดกว้าง

แผนงาน V2 (Roadmap)


1. ฝังความรู้เชิงลึกเกี่ยวกับวัฒนธรรมและภูมิศาสตร์ไทย (Thai Native Expert)

2. ปิดช่องว่างด้านความลื่นไหลของภาษา (NLG) โดยไม่เสียความเสถียร

3. เพิ่มความเชี่ยวชาญในข้อมูลเฉพาะทาง เช่น การท่องเที่ยวและกฎหมายไทย

พร้อมใช้งานสำหรับโครงสร้างพื้นฐานระดับองค์กร

SIAMGPT-32B
คือเครื่องมือที่ถูกนำมาเพื่อเป็น
Final Response Generator
ที่เสถียรที่สุดสำหรับภาษาไทย



ออกแบบมาเพื่อชนะเลิศในด้าน
Multi-turn Dialogue และ
Instruction Following



**โมเดลแบบ Open-Weights พร้อมให้ดาวน์โหลดแล้วบน
HuggingFace: [siammaids/SiamGPT-32B](#)**