


ภาพลวงตาของ การใช้เหตุผลทาง ทางคณิตศาสตร์ใน AI

เจาะลึกกระบวนการคิดของ
Large Language Models
ผ่านชุดทดสอบ GSM-Symbolic
เพื่อพิสูจน์ว่าพวกมัน 'คิด'
หรือแค่ 'จำแพทเทิร์น' ...



ตัวเลขที่ซ่อนความจริงเบื้องหลังความฉลาดของ LLMs



สิ่งที่อุตสาหกรรมบอกเรา:
โมเดลทำคะแนนแบบทดสอบ
GSM8K ได้เกือบสมบูรณ์แบบ
(90%+)

คำถามที่ต้องจุกคิด:
นี่คือ ‘การคิดเชิงตรรกะ’
(True Reasoning) ที่แท้จริง
หรือเป็นเพียง ‘ภาพลวงตา
ของการจำลองแพทเทิร์น’
(Pattern Mirage)?

จุดบอดของมาตรฐานการวัดผลแบบดั้งเดิม

GSM8K (มาตรฐานเก่า)



GSM8K

When Sophie watches her nephew, she gets out a variety of toys for him. The bag of building blocks has 12 blocks in it. The bin of stuffed animals has 8 stuffed animals inside. The tower of stacking rings has 9 multi-colored rings on it. Sophie recently bought a tube of bouncy balls, bringing her total number of toys for her nephew up to 62. How many bouncy balls came in the tube?

STATIC

- คำถามตายตัว 1,319 ข้อ (เสี่ยงต่อ Data Contamination)
- ให้ผลลัพธ์เป็นตัวเลขค่าเดียว (Single Metric)
- ไม่สามารถควบคุมปัจจัยทดสอบได้

What We Need (สิ่งที่จำเป็นในการวัดผล)



- ชุดทดสอบที่ปรับเปลี่ยนได้แบบพลวัต (Dynamic)
- ให้ผลลัพธ์เป็นเส้นโค้งการกระจายตัว (Distribution Metrics)
- สามารถเจาะจงปรับเปลี่ยนตัวแปรความยากได้อิสระ



ถอดรหัสโครงสร้างด้วยเทมเพลต GSM-Symbolic

Diagnostic Blueprint




Step 1: Original

ข้อความโจทย์คณิตศาสตร์
ต้นฉบับ 1 ข้อ



Step 2: Abstract Template


เปลี่ยนชื่อและตัวเลขเป็นตัวแปร



Step 3: 50 Unique Variations


แตกสายออกเป็นโจทย์ปัญหา 50 ข้อ
ที่มีความต่างกันเฉพาะข้อมูลพื้นผิว
แต่สมการคณิตศาสตร์เหมือนเดิม 100%

ความแม่นยำไม่ใช่ค่าคงที่ แต่เป็นเส้นโค้งการกระจายตัว



**เมื่อตรรกะการคำนวณเหมือนเดิมทุกประการ
ทำไมคะแนนถึงตกลงเพียงแค่ว่าสุ่มเปลี่ยนตัวเลขและชื่อ?**

บททดสอบที่ 1: ความเปราะบางของตัวแปร




The Fragility of Variables

- โมเดลอ่อนไหวต่อ 'พื้นผิว' ของคำถาม (Surface-level elements) ไม่ใช่แก่นตรรกะ
- การเปลี่ยนชื่อบุคคลทำให้กราฟขยับลงมาเล็กน้อย
- การเปลี่ยนตัวเลขทำให้กลไกการคิดสะดุด และกราฟตกลงอย่างเห็นได้ชัด
- ความแปรปรวน (Variance) สูงขึ้นอย่างน่าตกใจ

บททดสอบที่ 2: เมื่อความซับซ้อนทำลายสายโซ่ตรรกะ

ประสิทธิภาพที่ลดลงตามความซับซ้อน




To make a call from a hotel room phone, you must pay \$0.6 for each minute of your call. After 10 minutes, that price drops to \$0.5 per minute.

After 25 minutes from the start of the call, the price drops even more to \$0.3 per minute.

เงื่อนไขที่เพิ่มขึ้น
(Added Condition)


ประสิทธิภาพลดลงและ Variance ระเบิดขึ้นทันที โมเดลไม่สามารถรักษา 'สายโซ่ความคิด' (Chain of Thought) ที่ยาวขึ้นได้เมื่อถูกเพิ่มความซับซ้อนแบบเส้นตรง

บททดสอบที่ 3: กับดักข้อมูลลวงตา



ผลลัพธ์ร่วงหล่น สูงสุดถึง 65%

การพังทลายของระบบเมื่อพบข้อมูลที่ไม่เกี่ยวข้อง




LLMs ถูกฝึกให้แปลงตัวเลขในประโยคเป็น 'ตัวดำเนินการ' (Operations)
พวกมันจึงหยิบทุกตัวเลขไปคำนวณอย่างมึนงงโดยปราศจากความเข้าใจในบริบทของโจทย์อย่างแท้จริง

{ Prompting ไม่สามารถซ่อมแซมกระบวนการคิดที่ว่างเปล่าได้ }

การทดลอง NoOp-Symb


ให้ตัวอย่างการแก้โจทย์ที่ถูกต้อง 8 ข้อใน Prompt



ผลลัพธ์ยังคงร่วงหล่นเหมือนเดิม

การทดลอง NoOp-NoOp

ให้ตัวอย่างโจทย์ที่มีข้อมูลหลอกรูปแบบเดียวกัน 8 ข้อ



ผลลัพธ์แทบไม่ดีขึ้น


{ In-Context Learning ช่วยให้จับ Pattern ได้ดีขึ้น แต่เมื่อปัญหาอยู่ที่ระดับกระบวนการให้เหตุผลทางคณิตศาสตร์ (Formal Reasoning) การป้อนตัวอย่างเพิ่มเติมจึงไร้ผล }

{ เมตริกการวินิจฉัยข้อบกพร่องทางปัญญาของ AI }

ปัจจัยการทดสอบ (Factor)	ปฏิกิริยาของโมเดล (Model Reaction)	ข้อบกพร่องที่ซ่อนอยู่ (Underlying Flaw)
เปลี่ยนตัวแปรความไว (Variables Sensitivity)	แข็งแกร่งต่อชื่อ แต่เปราะบางต่อตัวเลข	ยึดติดกับข้อมูลอ้างอิง (Training Data Dependency)
เพิ่มเงื่อนไขความซับซ้อน (Complexity Decay)	สายโซ่ตรรกะขาดสะบั้น เมื่อต้องคิดหลายชั้น	ไร้ความสามารถในการ เชื่อมโยงประโยคต่อเนื่อง (Lack of Formal Logic Chain)
ใส่ข้อมูลกวนใจ (Distraction / NoOp)	เปลี่ยนข้อมูลหลอกเป็น สมการคำนวณแบบมั่วบอด	ขาดความเข้าใจในบริบท ของเหตุและผล (Absence of Causality)

ความเป็นจริง: การจับคู่แพทเทิร์น vs การคิดเชิงตรรกะที่แท้จริง

Probabilistic Pattern-Matching



หากเปลี่ยนตัวแปรเพียงเล็กน้อย ระบบจะสับสนเพราะ
ฟังก์ชันความน่าจะเป็นในการหาแพทเทิร์นที่เคยเจอ

True Formal Reasoning



ไม่ว่าพื้นผิวของตัวแปรจะเปลี่ยนไปอย่างไร
กลไกของตรรกะเหตุและผลจะไม่มีวันถูกทำลาย


LLMs ไม่ใช่เครื่องยนต์แห่งตรรกะประมวลผล
พวกมันเป็นเพียงระบบสืบค้นแพทเทิร์นทางความน่าจะเป็นที่มีความสลับซับซ้อนสูงเท่านั้น

อนาคตของการประเมินและปรับใช้ AI ในองค์กร




เลิกเชื่อมั่นตัวชี้วัดตายตัว

เลิกใช้ GSM8K หรือเกณฑ์ชี้วัดแบบ Single-point เป็นตัวตัดสินประสิทธิภาพของโมเดล AI ในองค์กร



ทดสอบด้วยการกระจายตัว

สร้างชุดประเมินผลที่เปลี่ยนตัวแปรแบบสุ่ม (Dynamic templates) เพื่อวัด Variance และความเสถียรที่แท้จริงของโมเดล



ระมัดระวังความซับซ้อน

การใช้ LLMs กับงานที่มีตัวแปรเชิงซ้อนหรือมีข้อมูลรบกวนในโลกความเป็นจริง ต้องมีการตรวจสอบโดยมนุษย์เสมอ ไม่สามารถพึ่งพาตรรกะของ AI ได้ 100%

