



LeWorldModel: จุดสิ้นสุดของความโกลาหลใน World Models

สถาปัตยกรรม Joint-Embedding
Predictive Architecture (JEPA)
ที่เรียนรู้จากฟิสิกเซลล์แบบ End-to-End
ผ่านความเรียบง่ายของสมการ 2 ตัวแปร

ตัดความซับซ้อน ทลายข้อจำกัด
คืนความเสถียรให้ Latent Space




ปัญหาคอขวดของ JEPA คือความ "ขี้เกียจ"



ความหวังของ JEPA

กะทัดรัด ประมวลผลไว ไม่ต้องจำลองทุกพิกเซล



ปัญหาข้อเท็จจริง

Representation Collapse: โมเดลมักจะโง่งการเรียนรู้โดยการทำแผนที่ทุกภาพให้กลายเป็นจุดเดียว เพื่อให้ทายอนาคตได้ง่ายที่สุด


The Band-Aid: การแก้ปัญหามันดีแต่ต้องพึ่งพาเทคนิคที่ซับซ้อน เช่น Stop-Gradient, EMA หรือการพึ่งพา Pre-trained Encoder ซึ่งลดทอนศักยภาพการเรียนรู้แบบ End-to-End

วิวัฒนาการและข้อจำกัดของ Latent World Models

โมเดล	End-to-End Learning	Pixels Based	Reconstruction/ Reward Free	Provable Anti-collapse
PLDM	✓	✓	✓	✗ (ต้องใช้ 7 Hyperparameters)
DINO-WM	✗ (ฟังก์ชัน Frozen Encoder)	✓	✓	✓
Dreamer / TD-MPC	✓	✗ (Task specific)	✗ (Reward-based)	✓
LeWM	✓	✓	✓	✓ (มีเพียง 1 Hyperparameter)


LeWM เป็นโมเดลเดียวที่รวมข้อดีทั้งหมด: เรียนรู้จากพิกเซลโดยตรง
ไม่ต้องใช้ Reward และมีกลไกป้องกัน Collapse ที่พิสูจน์ได้ทางคณิตศาสตร์

สถาปัตยกรรมที่ไร้รอยต่อ (End-to-End Pipeline)



The Difference: ไร้ทริกซับซ้อน ไม่มี Stop-Gradient ไม่มี Target Network
มีเพียงการอัปเดตน้ำหนักโดยตรงจาก 2 Loss Functions

สมดุลของ 2 พลัง: แม่นยำแต่ไม่กระจุกตัว



The Insight


ตรงข้ามกับโมเดลเดิมที่มีถึง 7 Loss terms, สถาปัตยกรรม LeWM ต้องการเพียง 2 ตัวแปรหลักในการทำงาน

The Result

การปรับจูนง่ายดาย ใช้ Hyperparameter (λ) เพียงตัวเดียว ทำให้การทรมนเสถียร โค้งของ Loss ลดลงอย่างรวดเร็วและคาดเดาได้

เจาะลึก SIGReg: สร้างระเบียบผ่านเลนส์กาส์เซียน


High-dimensional Space.



Step 1

The Challenge: การวัดการกระจายตัวในมิติที่สูงมากเป็นเรื่องยากและกินทรัพยากร

Target Distribution (Isotropic Gaussian)



Step 3

The Outcome: บังคับให้เกิดการกระจายตัวแบบ Gaussian ป้องกัน Collapse สมบูรณ์แบบ

Random Univariate Projections

Step 2

The Solution: SIGReg
ฉายภาพ Latent Vector ลงบนเส้นตรง 1 มิติแบบสุ่มหลายๆ เส้น


Latent Planning: การวางแผนผ่านจินตนาการ

กระบวนการ (Process)


เมื่อฝึกฝนสำเร็จ LeWM
ไม่ต้องดูภาพจริงอีกต่อไป
มันสามารถจำลองอนาคต
ล่วงหน้าหลายสเตปใน
Latent Space

การหาจุดตัดที่ดีที่สุด (Action Optimization)

คำนวณหาลำดับการกระทำ
ที่จะพาโมเดลไปยังเป้าหมาย
โดยไม่ต้องสร้างภาพจริงขึ้นมา




ประสิทธิภาพสูง บนทรัพยากรที่เข้าถึงได้ (The "Single GPU" Advantage)



Foundation Models (เช่น DINOv2)

100M+ Parameters

ต้องใช้ข้อมูลมหาศาลและคลัสเตอร์คอมพิวเตอร์




LeWorldModel (LeWM)

15M Parameters (Vision Transformer ระดับ Tiny)

เทรนสำเร็จในไม่กี่ชั่วโมงบน GPU เพียงใบเดียว

Impact: ทำลายกำแพงต้นทุนและทรัพยากรสำหรับการทำวิจัยและพัฒนาวิศวกรรม
โดยยังคงประสิทธิภาพระดับท็อป

ความเร็วระดับ Real-time: วางแผนเร็วกว่าถึง 48 เท่า



The Data:



การใช้งาน DINO-WM ต้องประมวลผล Token จำนวนมหาศาล ทำให้การวางแผนเต็มรูปแบบใช้เวลาถึง 47 วินาที

The Advantage:



LeWM ประมวลผล Token น้อยกว่าถึง 200 เท่า ทำให้สร้างแผนเสร็จภายในเวลาไม่ถึง 1 วินาที เปิดประตูสู่การควบคุมหุ่นยนต์ในโลกจริงแบบ Real-time

ผ่านการทดสอบทั้งสภาพแวดล้อม 2D และ 3D



PushT (2D Manipulation)




Reacher (2D Locomotion)



OGBench-Cube (3D Manipulation)




TwoRoom (2D Navigation)



Key Insight: ภายใต้ข้อจำกัดด้านการคำนวณที่เท่ากับ LeWM ที่เรียนรู้จากพิกเซลล้วนๆ สามารถเอาชนะ PLDM และทำงานเทียบชั้นโมเดลที่ใช้ข้อมูล Pre-train มหาศาลได้อย่างน่าทึ่ง

SYNTHESIS: มากกว่าการเดาภาพ แต่มันคือ "สัญชาตญาณฟิสิกส์"



The Insight: โมเดลไม่ได้ถูกสั่งให้เรียนรู้กฎฟิสิกส์ แต่มันเกิดขึ้นเองตามธรรมชาติ (Emergent property)


How it Works: การบังคับให้ Latent Space จัดเรียงตัวเป็นระเบียบตามขอบเขตของ Gaussian บังคับให้โมเดลต้องละทิ้งข้อมูลภาพที่ผิว (Pixels) และบีบอัดเฉพาะ "โครงสร้างที่เป็นแก่นแท้" (ตำแหน่ง, มุม, ทิศทาง) เพื่อให้สูญเสียข้อมูลน้อยที่สุด

สกัดตัวเลข ฟิสิกส์ในใจโมเดล (Probing Latent Physics)

คุณสมบัติทางฟิสิกส์	โมเดลเปรียบเทียบ	ค่าสหสัมพันธ์ (r Correlation)
พิกัดของแขนกล (Agent Location)	PLDM vs LeWM	0.955 vs 0.998
พิกัดของวัตถุ (Block Location)	PLDM vs LeWM	0.938 vs 0.999
องศาของวัตถุ (Block Angle)	PLDM vs LeWM	0.745 vs 0.990

- **The Proof:** เมื่อใช้สมการเส้นตรงธรรมดา (Linear Probe) ดึงข้อมูลออกจาก Latent Vector พบว่าตัวเลขมีความเชื่อมโยงกับพิกัด X, Y และองศาการหมุนของวัตถุในโลกจริงแทบจะ 100%
- **Significance:** พิสูจน์ว่า Latent ไม่ใช่แค่ชุดตัวเลขสุ่ม แต่เป็นระบบพิกัดที่โมเดลสร้างขึ้นเอง


มองทะลุ ‘ตาในจินตนาการ’ (Decoding the Mind’s Eye)



Experiment: นำ Decoder (ที่ไม่ได้ใช้ตอนเทรน) มาถอดรหัสภาพจาก Latent Space


Observation: แม้กระบวนการเทรนทั้งหมดจะไม่เคยบังคับให้โมเดลวาดภาพ (Reconstruction-Free) แต่มันสามารถเรนเดอร์จาก แชนกส และคาดเดาอนาคตได้อย่างแม่นยำ

การจับผิดสิ่งเหนือธรรมชาติ (Violation-of-Expectation)



- **The Test:** ประเมินความเข้าใจแบบจิตวิทยาเด็กทารก โดยการสร้างวิดีโอที่วัตถุ "วาร์ป"ข้ามจากแบบผิดกฎฟิสิกส์
- **The Result:** ค่าความประหลาดใจ (Surprise) พุ่งทะยานขีดสุดเมื่อเห็นวัตถุเทเลพอร์ต แต่แทบไม่สนใจเมื่อแค่สีเปลี่ยน
- **Conclusion:** โมเดลรู้ว่ากฎฟิสิกส์คือโครงสร้างหลักที่ละเมิดไม่ได้ ส่วนสีสันเป็นเพียงเปลือกนอก

มาตรฐานใหม่ของ World Models




ความเรียบง่ายที่เสถียรสุดขีด

เรียนรู้แบบ End-to-End
จากพิกเซล ใช้ Loss เพียง
2 Terms และปรับแต่ง
Hyperparameter เพียงตัวเดียว



เร็วกว่า เบากว่า เข้าถึงได้

ประมวลผลเร็วกว่าโมเดลยักษ์
48 เท่า
รันจบและเทรนได้บน GPU
ระดับผู้บริโภคเพียงใบเดียว



สัญชาตญาณเชิงโครงสร้าง

พื้นที่ Latent ที่เป็นระเบียบ
นำไปสู่ความเข้าใจเรื่องพิกัด
มิติ และกฎฟิสิกส์อย่างลึกซึ้ง
โดยไม่ต้องป้อนข้อมูลเสริม

LeWM — เปลี่ยนความโกลาหลของภาพให้เป็นตัวเลขที่เข้าใจโลก