




LeWorldModel: The Elegant Future of Latent World Models

สู่การเรียนรู้แบบ End-to-End จาก
พิกเซลด้วยสมการ Loss เพียงสองพจน์


15M Parameters

1 GPU

Zero Heuristics

ทำไมเราจึงต้องการ World Models?

การสร้างตัวแทน
(Agents)
ที่สามารถเรียนรู้และ
วางแผนล่วงหน้าได้ใน
'จินตนาการ'
(Imagination Space)
โดยไม่ต้องลองผิด
ลองถูกในโลกจริง




หัวใจสำคัญคือการเรียนรู้ Offline Dynamics จากภาพพิกเซลดิบ
โดยไม่ต้องใช้ Reward Signals หรือทำ Feature Engineering

ข้อจำกัดสำคัญของ JEPA: Representation Collapse

แม้สถาปัตยกรรม Joint-Embedding Predictive Architecture (JEPA) จะทรงพลัง แต่มีจุดอ่อนร้ายแรงคือ Representation Collapse

Real World Observations




Input: หลากหลายท่าทางในโลกจริง

Neural Network Process (JEPA)



The Latent Space



Representation Collapse Occurs

โมเดล ‘โกง’
‘โกง’ การเรียนรู้โดยการ
แปลงทุก Input ให้กลายเป็น
จุดๆ เดียวใน Latent Space
เพื่อให้ Loss เป็นศูนย์
ทำให้สูญเสียข้อมูลทั้งหมด

Result: การสูญเสียข้อมูลทั้งหมดใน Latent Space ทำให้โมเดลใช้งานไม่ได้จริง

Current Fixes

ปัจจุบันแก้ปัญหาดังกล่าวด้วยวิธีที่ซับซ้อน: 6+ Hyperparameters,  Exponential Moving Averages (EMA), หรือพึ่งพา Pre-trained Encoders




วิวัฒนาการและข้อจำกัดของ Latent World Models

LeWM ทลายข้อจำกัดของทุกกระบวนทัศน์ โดยดึงจุดแข็งของการฝึกแบบ End-to-End มารวมกับการการันตี Anti-collapse ทางคณิตศาสตร์

Models	End-to-End Learning	Pixels Based	Anti-Collapse Mechanism	Reward-Free
Task-Specific (Dreamer/TD-MPC)	✗ No	✗ No	N/A	✗ No
Foundation-Based (DINO-WM)	✗ No	✓ Yes	Frozen Pre-trained Encoder	✓ Yes
End-to-End (PLDM)	✓ Yes	✓ Yes	6 Hyperparameters	✓ Yes
LeWM (Ours)	✓ Yes	✓ Yes	1 Hyperparameter (Provable Guarantee)	✓ Yes


การถ่ายโอนขีดจำกัดด้วย LeWorldModel (LeWM)

LeWM คือ JEPA ตัวแรกที่สามารถฝึกแบบ End-to-End จากภาพพิกเซลได้อย่างเสถียร โดยไม่ต้องใช้ Heuristics ใดๆ (ไม่มี Stop-gradient, ไม่มี EMA)



ใช้งานง่าย ทรงพลัง และสามารถเทรนได้บน GPU เพียงใบเดียวภายในไม่กี่ชั่วโมง

สถาปัตยกรรมของ LeWM: เรียบง่ายแต่แม่นยำ




Encoder (ViT):
แปลงภาพเป็น Latent
Embeddings ขนาดเล็ก

Predictor (Transformer):
ทำนายอนาคตใน Latent Space
ด้วย Adaptive Layer
Normalization (AdaLN)

เคล็ดลับการป้องกัน Collapse: SIGReg

แทนที่จะใช้ Loss ซับซ้อน LeWM บังคับให้ Latent Embeddings มีการกระจายตัวแบบ Isotropic Gaussian



อาศัยทฤษฎี Cramér–Wold Project ข้อมูลลงบนแกน 1D แบบสุ่ม
แล้วใช้สมการ Epps–Pulley Normality Test เพื่อรับประกัน Feature Diversity

ความสวยงามที่แสดงออกผ่าน Code เพียงไม่กี่บรรทัด


```
def LeWorldModel(obs,actions,lambd=0.1):  
    """  
    obs: (B, T, C, H, W) raw pixels sequence  
    actions: (B, T, A) action sequence  
    lambd: (float) SIGReg loss weight  
    """  
  
    emb = encoder(obs) # (B, T, D)  
    next_emb = predictor(emb,actions) #(B, T, D)  
  
    # - LeWorldModel training loss  
  
    # next-embedding prediction loss  
    pred_loss = F.mse_loss(emb[:, 1:] - next_emb[:, :-1])  
  
    # step-wise sigreg (anti-collapse)  
    sigreg_loss = mean(SIGReg(emb.transpose(0, 1)))  
  
    return pred_loss + lambd * sigreg_loss
```

Next-embedding MSE

Step-wise Anti-Collapse

ลด Hyperparameter จาก 6 ตัวเหลือเพียง 1 ตัว ($\lambda = 0.1$)
ทำให้สามารถทำ Bisection Search ด้วยเวลาแบบ Logarithmic ได้อย่างง่ายดาย

ความเร็วในการวางแผน (Planning) ที่เหนือกว่า 48 เท่า






0.98 วินาที (LeWM) vs 47 วินาที (DINO-WM)

การเข้ารหัส (Encoding) ข้อมูลด้วยจำนวน Token ที่น้อยกว่า DINO-WM ถึง ~200 เท่า ทำให้ LeWM วางแผนได้เร็วกว่ามหาศาล โดยที่ยังรักษาประสิทธิภาพในระดับสูง

ประสิทธิภาพระดับ State-of-the-Art (Control Tasks)

ภายใต้ข้อจำกัดการประมวลผลที่เท่ากัน (Fixed FLOPs) LeWM เอาชนะ DINO-WM อย่างขาดลอยในงานที่ซับซ้อนอย่าง PushT และ OGBench-Cube


Performance Dashboard



ทรงพลังทั้งในสภาพแวดล้อมแบบ 2D และ 3D

การถอดรหัส Latent Space (Visual Proof)


แม้ LeWM จะไม่มีการใช้ Reconstruction Loss เลยในระหว่างการเทรน...



แต่ Decoder ที่นำมาทดสอบภายหลังสามารถสร้างภาพจากกลับมาได้อย่างสมบูรณ์จากเวกเตอร์ขนาดเพียง 192-dim
พิสูจน์ให้เห็นว่าโครงสร้างทางพื้นที่ (Spatial Structure) ถูกบันทึกไว้ใน Latent Space อย่างครบถ้วน


ความเข้าใจฟิสิกส์ที่เกิดขึ้นเอง (Emergent Physics)

The Physical Action



Central Frame

The AI's Mind: Surprise / Prediction Error (MSE)



The Test: การทดสอบ Violation-of-Expectation (VoE) โดยทำให้วัตถุ ‘วาร์ป’ ผิดกฎฟิสิกส์

The Result: โมเดลเกิดค่า ‘ความประหลาดใจ’ (Surprise/Error Spike) พุ่งสูงขึ้นทันทีที่เกิดการวาร์ป แต่ไม่แสดงอาการเมื่อเปลี่ยนแค่สีวัตถุ

Insight: โมเดลไม่ได้ถูกสอนเรื่องความคงอยู่ของวัตถุ (Object Permanence) แต่มันเรียนรู้กฎฟิสิกส์ด้วยตัวเอง

อนาคตที่เรียบง่ายและเสถียร (Signal from Noise)

Stable & Simple (เสถียรภาพ)

ยุติปัญหา Representation
Collapse
ด้วยสมการคณิตศาสตร์ 2 พจน์
ลด Hyperparameter เหลือ 1 ตัว
เทรนจบได้ใน GPU ใบเดียว

48x Speed (ความเร็วสูงสุด)

ความเร็วในการวางแผนที่เหนือกว่า
Foundation Models ขนาดใหญ่
เปิดประตูสู่ระบบ Real-time
Control

Emergent AI (ปัญญาประดิษฐ์เชิงลึก)

Latent Space ที่เข้าใจโครงสร้าง
ของโลกและกฎฟิสิกส์ได้เองโดยไม่
ต้องพึ่งพา Reward Signals