


Beyond Prompt Engineering: The Era of Context Engineering

เจาะลึกสถาปัตยกรรมโลจิสติกส์ข้อมูล
เพื่อปลดล็อกศักยภาพสูงสุดของ
Large Language Models

อ้างอิงและสังเคราะห์เนื้อหาจากเอกสารวิจัย
A Survey of Context Engineering for
Large Language Models
(การประเมินเปเปอร์วิจัยกว่า 1,400 ฉบับ)




ทำไม Prompt Engineering ถึงไม่พออีกต่อไป?

อดีต: Prompt Engineering		อนาคต: Context Engineering	
โมเดล (Model)	ข้อความแบบคงที่ (C = prompt)	ระบบประกอบข้อมูลแบบไดนามิก (C = A(c_1, c_2, ..., c_n))	
การปรับแต่ง (Optimization)	ปรับแก้คำสั่งด้วยมือ (Manual)	การปรับแต่งทั้งระบบนิเวศการทำงาน (System-level F*)	
สถานะ (State)	ไร้สถานะ ลืมทุกอย่างเมื่อจบเซสชัน (Stateless)	มีความจำและสถานะของตัวเอง (Stateful: c_mem, c_state)	
การขยายขนาด (Scalability)	ยิ่งยาวยิ่งเปราะบาง	จัดการความซับซ้อนด้วย Modular Composition	

บริบท (Context) ไม่ใช่แค่คำสั่ง แต่เป็น 'Payload ข้อมูล' ที่ต้องอาศัยสถาปัตยกรรมโลจิสติกส์ในการบริหารจัดการ

ถอดรหัสสมการแห่งบริบท (The Assembly Function)


$$C = A(c_{instr}, c_{know}, c_{tools}, c_{mem}, c_{state})$$




ภูมิทัศน์ของ Context Engineering (Unified Framework)

⚡ Navigational Blueprint

2. System Implementations (ระบบประยุกต์)




1. Foundational Components (ฐานราก)




เปเปอร์นี้คือความพยายามแรกในการเชื่อมโยง 'จิ๊กซอว์' เทคนิคต่างๆ ให้เป็นกรอบการทำงานเดียว (Unified Framework)

เสาหลักที่ 1: การค้นหาและสร้างบริบท (Retrieval & Generation)



Tier 3: Dynamic Assembly

ใช้ AI ปรับแต่งรูปแบบอัตโนมัติ (Automated Prompt Optimization) เช่น Promptbreeder เพื่อหาโครงสร้างที่ดีที่สุด ไม่ใช่แค่จับข้อความมาต่อกัน




Tier 2: External Knowledge

ปลดล็อกขีดจำกัดด้วยข้อมูลภายนอกแบบไดนามิก ลดอาการหลอน (Hallucination) ด้วยโครงสร้าง RAG และ Knowledge Graphs (KG)


Tier 1: Cognitive Prompting

ยกระดับคำสั่งทางเดียว สู่การจำลองกราฟความคิดมนุษย์ (Chain-of-Thought, Tree-of-Thoughts, Graph-of-Thoughts)

เสาหลักที่ 2: ทลายคอขวดของการประมวลผล




The Complexity Curve




Architectural Fixes (แก้ที่สถาปัตยกรรม)

State Space Models (SSM) เช่น Mamba หรือ LongNet ปรับสมการให้เป็น Linear Scaling ประมวลผลระดับพันล้าน Token ได้




Memory Hacks (แก้ที่หน่วยความจำ)

- FlashAttention จัดการ GPU Memory ให้มีประสิทธิภาพสูงสุด
- StreamingLLM ใช้ Attention Sink รักษาความต่อเนื่องโดยไม่ต้องจำข้อมูลทั้งหมด




เราไม่ต้องขยาย Context Window เสมอไป การจัดการ Attention และ Cache แบบ 'ฉลาดเลือก' คือทางออกที่ยั่งยืนกว่า

เสาหลักที่ 2 (ต่อ): การขัดเกลาตัวเองและข้อมูลเชิงโครงสร้าง




Self-Refinement (วงจรขัดเกลาตัวเอง)



กลไกที่ LLM สวมบทบาทครบวงจรแบบอัตโนมัติ (เช่น Reflexion) ข้ามขีดจำกัดด้วยการปล่อยให้ AI ตรวจสอบและแก้ไขตัวเอง


Structured Data (ข้อมูลเชิงโครงสร้าง)




- **ปัญหา:** LLM เก่งเรื่องข้อความ แต่ไม่ถนัดข้อมูลฐานข้อมูลเชิงสัมพันธ์ (Relational Data)
- **ทางออก:** แปลงโครงสร้างเป็นโค้ด (Python/SQL) หรือใช้ Graph Neural Networks (GNNs) ช่วยเพิ่มความแม่นยำทางตรรกะได้มหาศาล

เสาหลักที่ 3: การจัดการบริบทของระบบปฏิบัติการ (Context Management)


Technical Taxonomy



The Phenomenon: Lost-in-the-Middle



LLM มักจำได้แค่ต้นเรื่องและท้ายเรื่อง
แต่ลืมเนื้อหาตรงกลางเมื่อ Context ยาวเกินไป



Main Memory (ความจำหลัก)

หน้าต่างบริบทหลัก (Context Window)
ทำงานเร็วสุด แต่พื้นที่มีจำกัด

Compression (การบีบอัด)


บีบอัด Context ยาวๆ ให้สั้นลง
เช่น In-context Autoencoder (ICAE)
บีบข้อมูลลง 4 เท่า หรือลบ Token ที่ไร้ค่า (H2O)

External Storage (ความจำถาวร)


ข้อมูลเก็บถาวรปริมาณมหาศาล
ที่ดึงผ่าน Function Calling
(เช่น ระบบ MemGPT)

ระบบประยุกต์ 1: วิวัฒนาการของระบบ RAG

Technical Taxonomy




Era 1: Naive RAG (Linear)




การค้นหากทางเดินตรงเดียว ค้นหา ถึงข้อมูล แล้วตอบ

Era 2: Modular RAG (Reconfigurable)



ระบบยืดหยุ่นปรับเปลี่ยนได้ (RAGFusion, FlashRAG)
เพิ่มโมดูลตรวจสอบคุณภาพข้อมูลก่อนตอบ และเปลี่ยนเส้นทางตามสถานการณ์

Era 3: Graph-Enhanced RAG (Networked)




ก้าวข้ามการหาแค่ 'เอกสาร' สู่การดึง 'ความสัมพันธ์เชิงโครงสร้าง' (Entity relationships)
ผ่าน GraphRAG ทำให้สามารถให้เหตุผลข้ามเอกสาร (Multi-hop reasoning) ได้แม่นยำ

ระบบประยุกต์ 1 (ต่อ): RAG ขับเคลื่อนด้วย Agent (Agentic RAG)

จากหุ่นยนต์หยิบของ สุนัขสืบอิสระ เมื่อระบบ RAG ไม่ต้องรอคำสั่งดึงข้อมูลแบบ Static

Technical Taxonomy



1. Task Decomposition

วางแผนและแตกเป้าหมายใหญ่เป็นงานย่อย เพื่อการค้นหาที่แม่นยำ

2. Adaptive Retrieval

ประเมินสถานการณ์ว่าต้องหาข้อมูลอะไรเพิ่มเติมบ้าง (Self-RAG)

Perception (การรับรู้)

Action (การกระทำ)

Memory (ความจำ)

Planning (การวางแผน)


3. Self-reflection

ตรวจสอบข้อมูลที่เจอว่าตอบคำถามได้จริงหรือไม่ ถ้าไม่ จะออกไปค้นหาใหม่โดยอัตโนมัติ


Use Case: ตอบโจทย์ Real-time RAG สำหรับระบบที่มีข้อมูลเปลี่ยนแปลงทุกวินาที เช่น ระบบเทรด หรือความปลอดภัย

ระบบประยุกต์ 2: สถาปัตยกรรมระบบความจำ (Memory-Enhanced Agents)

เปลี่ยน AI จาก 'เครื่องจักรที่จำอดีตไม่ได้' เป็น 'บุคลิกภาพที่มีความจำระยะยาว' (Stateless -> Stateful)



Architectural Taxonomy



System Implementations:
Memory Systems

Cognitive Principles (แรงบันดาลใจจากมนุษย์)

- MemoryBank:** ใช้ทฤษฎี Ebbinghaus Forgetting Curve ให้ AI ค่อยๆ 'ลืม' ข้อมูลที่ไม่สำคัญตามกาลเวลา ประหยัดพื้นที่ประมวลผล
- REMEMBERER:** ให้ AI เรียนรู้จากความสำเร็จและข้อผิดพลาดในอดีต (Success/Failure) นำมาปรับปรุงตัวโดยไม่ต้อง Fine-tune โมเดล

Impact: สร้าง Personalized AI Assistant ที่รู้ใจ เต็มโตไปพร้อมผู้ใช้ และทำงานโปรเจกต์ระยะยาวได้ไม่หลุดโฟกัส

ระบบประยุกต์ 3 & 4: เครื่องมือภายนอกและทีมเวิร์ก (Tools & Orchestration)

Architectural Taxonomy




Tool Integration (มือและตาของ AI):

เปลี่ยน LLM ให้สามารถกระทำกับโลกภายนอก (Action) ผ่าน Function Calling (เช่น ReAct, Toolformer) และนำผลลัพธ์ป้อนกลับมาเป็น Context

Multi-Agent Orchestration (การประสานงาน):

ใช้กลไกจัดสรรงานตามสถานะบริบท (c_state)


ผลลัพธ์: การทำงานเป็นทีมเพิ่มอัตราความถูกต้องตั้งแต่รันครั้งแรก (Pass@1) สูงขึ้นถึง **47%** เมื่อเทียบกับการใช้ AI ตัวเดียว



เส้นทางวิวัฒนาการระดับเอกซโพเนนเชียล (Timeline 2020-2025+)

2020-2022: រាក្ស៊ាន


ยุคเริ่มต้นของการวางโครงสร้าง RAG และให้ AI เริ่มจับเครื่องมือเบื้องต้น (เช่น WebGPT)



ยุคเริ่มต้นของการวางโครงสร้าง RAG และให้ AI เริ่มจับเครื่องมือเบื้องต้น (เช่น WebGPT)

2023-2024: การระเบิดของเอเจนต์


การกำเนิดของ Agentic RAG (Self-RAG), ระบบจัดการความจำอิสระ (MemGPT), และเฟรมเวิร์ก Multi-Agent ที่ทำงานร่วมกัน (AutoGen, MetaGPT)



การกำเนิดของ Agentic RAG (Self-RAG), ระบบจัดการความจำอิสระ (MemGPT), และเฟรมเวิร์ก Multi-Agent ที่ทำงานร่วมกัน (AutoGen, MetaGPT)

2025+: อนาคตที่กำลังเกิดขึ้น


มุ่งหน้าสู่ระบบบริหารเครือข่ายเอเจนต์ขนาดใหญ่,
GraphRAG สเกลระดับประเทศ, และหุ่นยนต์ผู้ช่วยที่มีความ
จำระยะยาวพร้อมจริยธรรม (Ethical LTM Assistants)



มุ่งหน้าสู่ระบบบริหารเครือข่ายเอเจนต์ขนาดใหญ่,
GraphRAG สเกลระดับประเทศ, และหุ่นยนต์ผู้ช่วยที่มีความ
จำระยะยาวพร้อมจริยธรรม (Ethical LTM Assistants) 🚀

ความเร็วในการพัฒนานวัตกรรมพุ่งสูงขึ้นแบบก้าวกระโดดในช่วง 2 ปีที่ผ่านมา

พรมแดนใหม่: บริบทแบบ Multimodal และ Structural Scaling



1 The Next Challenge

ขนาดความยาวของบริบท (Context Length) จะไม่สำคัญเท่า โครงสร้างของบริบท (Context Structure)

2 Modality Bias (อคติของ AI)

ความท้าทายสำคัญคือ AI ในปัจจุบันมักเชื่อข้อมูลที่เป็นข้อความ (Text) มากกว่าการตีความจากรูปภาพ (Vision) แม้ว่าจะป้อนข้อมูลให้พร้อมกันก็ตาม

3 The Future System

ระบบแห่งอนาคตต้องผสานบริบทด้าน 'กาลเวลา', 'พื้นที่', และ 'จุดมุ่งหมาย (Intent)' เข้าด้วยกันอย่างสมบูรณ์แบบ เพื่อก้าวไปสู่การรับรู้เทียบเท่ามนุษย์

