





Graph-of-Agents (GoA): สถาปัตยกรรมแห่งอนาคต สำหรับการทำงานร่วมกันของ AI

ปลดล็อกศักยภาพ Multi-Agent ด้วยโครงข่าย
ที่แม่นยำ ทรงพลัง และประหยัดทรัพยากร



ปัญหาของยุค LLM Zoo

จำนวนโมเดลที่เพิ่มขึ้น ไม่ได้แปรผันตรงกับประสิทธิภาพ
เสมอไป หากขาดการประสานงานที่ดี



ตัวเลือกมหาศาล: มี LLM เชี่ยวชาญเฉพาะทาง
จำนวนมาก แต่การดึงมาใช้งานร่วมกันทำได้ยาก




ต้นทุนที่ควบคุมไม่ได้: การเรียกใช้งานทุกโมเดล
พร้อมกัน ทำให้สิ้นเปลือง Token และเวลาประมวลผล



ความท้าทายหลัก: เราจะสร้างพื้นที่การทำงาน
(Playground) ที่ AI สามารถดึงดูดเชิง ชดเชยจุดอ่อน
และทำงานร่วมกันอย่างมีประสิทธิภาพได้อย่างไร?

ข้อจำกัดของ Mixture-of-Agents (MoA)



1 ไม่มีการคัดกรอง (No Selection)

โยนคำถามให้ทุกโมเดลที่มีอยู่ ทำให้เกิด Agent Explosion ที่ไม่จำเป็น

2 สัญญาณรบกวน (Noise)

โมเดลที่ไม่เกี่ยวข้องกับคำถาม สร้างคำตอบที่ทำให้ผลลัพธ์สุดท้ายผิดเพี้ยนและสับสน

3 ต้นทุนมหาศาล (Costly Integration)


นำทุกคำตอบมาต่อกันแบบ Concatenation ทำให้ใช้ Token เปลืองและระบบประมวลผลล่าช้า

3 เสาหลักของการทำงานร่วมกันใน Multi-Agent




Which
agents?

เราจะเลือกเฉพาะผู้เชี่ยวชาญ
ที่ตรงกับงานที่สุดได้อย่างไร?



How do they
communicate?

เราจะให้ AI แลกเปลี่ยนข้อมูล
และปรับปรุงคำตอบกันอย่างไร
โดยไม่เกิดความสับสน?




How to
integrate?

เราจะรวบรวมคำตอบจาก AI
หลายตัวให้กลายเป็นข้อสรุปเดียว
ที่แม่นยำที่สุดได้อย่างไร?


การยกระดับสถาปัตยกรรม: แนะนำ Graph-of-Agents (GoA)

GoA เปลี่ยนกระบวนการทัศน์จากการ รวมทุกอย่าง เป็นการสร้าง โครงข่ายความสัมพันธ์ ที่มีทิศทาง


แบบเดิม: เส้นทางแบบเส้นตรง (Linear Stack)



แบบใหม่: โครงข่ายทิศทาง (Directed Graph)



ขั้นตอนที่ 1: Node Sampling (การคัดกรองผู้เชี่ยวชาญ)




Key Takeaway: ระบบจะตรวจสอบ นามบัตร (Model Card) ของ AI แต่ละตัว และอนุญาตให้เฉพาะ AI ที่เกี่ยวข้องเข้าสู่โครงข่าย
ตัดปัญหาการสับสนเปลี่ยนทรัพยากรตั้งแต่เริ่มต้น

ขั้นตอนที่ 2: Edge Sampling (การสร้างเส้นทางแห่งความน่าเชื่อถือ)

กระบวนการ (Process Steps)


1. Peer Review

AI ที่ถูกคัดเลือก จะให้คะแนนคำตอบเริ่มต้น
ของกันและกัน เพื่อสร้าง Score Matrix



2. Ranking

จัดอันดับ AI เป็น Source (มีอิทธิพลสูง)
และ Target (มีอิทธิพลรอง)




3. Pruning

ตัดเส้นทางของ AI ที่ได้คะแนน
ความเกี่ยวข้องกันต่ำกว่าเกณฑ์ที่ตั้ง
(Threshold $\tau = 0.05$)



หลักฐานภาพ (Visual Evidence)


	Agent A	Agent B	Agent C	Agent D
Agent A	-	0.92	0.03	0.78
Agent B	0.85	-	0.12	0.65
Agent C	0.04	0.11	-	0.02
Agent D	0.76	0.60	0.01	-



ผลลัพธ์: เกิดเป็นเส้นทาง (Edges) ที่กำหนดอย่างชัดเจนว่าใครควรเป็นผู้ให้คำแนะนำ และใครควรเป็นผู้รับคำแนะนำ


ขั้นตอนที่ 3: Message Passing (การขัดเกลาคำตอบแบบสองทิศทาง)

Cycle 1: Source -> Target



AI ระดับท็อป (Source) ส่งข้อมูลชี้แนะไปยัง AI ระดับรอง (Target) เพื่อปรับปรุงคำตอบเบื้องต้นให้แม่นยำขึ้น

Cycle 2: Target -> Source




AI ระดับรอง ส่งคำตอบที่ถูกขัดเกลาแล้วกลับไปสะท้อนให้ AI ระดับท็อป ยืนยันและสร้างข้อสรุปที่สมบูรณ์ที่สุด

Insight: โครงสร้างทิศทางคู่ (Bidirectional) รับประกันว่าข้อมูลที่แข็งแกร่งจะไม่ถูกรบกวนโดยข้อมูลที่อ่อนกว่า แต่ในขณะเดียวกันระบบก็ยังเปิดรับมุมมองที่หลากหลายเพื่อปรับปรุงคำตอบ


ขั้นตอนที่ 4: Graph Pooling (การรวบรวมข้อสรุป)

Option A: Max Pooling (เส้นทางที่มั่นคงที่สุด)




ดึงคำตอบสุดท้ายจาก AI ที่มีอิทธิพลและได้รับการยอมรับจากเพื่อนร่วมทีมมากที่สุดในโครงข่าย (มีจำนวน Edge เข้ามากที่สุด)

Option B: Mean Pooling (การถ่วงน้ำหนักร่วมกัน)









ให้ Meta-LLM ประมวลผลภาพรวมและหาค่าเฉลี่ยแบบถ่วงน้ำหนัก (Weighted Average) จากคำตอบสุดท้ายของ AI ทุกตัว




ภาพรวมสถาปัตยกรรม GoA แบบสมบูรณ์



วิเคราะห์เปรียบเทียบ: สถาปัตยกรรม MoA vs. GoA

มิติการเปรียบเทียบ	MoA (สถาปัตยกรรมเดิม)	GoA (สถาปัตยกรรมใหม่)
มิติที่ 1: การเลือก Agent	 ใช้ทุกตัวที่มี (Brute-force)	 คัดเลือกเฉพาะผู้เกี่ยวข้อง (Node Sampling)
มิติที่ 2: รูปแบบการสื่อสาร	 นำมารวมกันเป็นก้อนเดียว (Many-to-one)	 สื่อสารแบบ 1-ต่อ-1 ผ่านโครงข่าย (Message Passing)
มิติที่ 3: การรวบรวมคำตอบ	 นำ Token มาต่อกัน (Concatenation)	 กว่งน้ำหนักตามความน่าเชื่อถือ (Graph Pooling)
มิติที่ 4: ความซับซ้อน (Cost)	 สูงมาก ระดับ $O(LNd)$ 	 ต่ำและปรับขยายได้ (Scalable Subgraph) 

ประสิทธิภาพที่เหนือกว่า: น้อยแต่่มาก ด้วยโครงสร้างที่ฉลาดกว่า



Key Insight: GoA ใช้ AI เพียง 3 ตัว แต่สามารถทำคะแนนชนะสถาปัตยกรรมที่ใช้ AI ถึง 6 ตัวพร้อมกันในทุกเกณฑ์การวัด (Benchmarks) พิสูจน์ให้เห็นว่าโครงสร้างที่ดีสำคัญกว่าปริมาณ

การลดต้นทุนและเพิ่มความเร็ว (Efficiency Dashboard)

ผลการทดสอบประสิทธิภาพจาก MMLU-Pro (GoA vs MoA)

การใช้ Token ลดลงอย่างมหาศาล

-65% ↓

จาก 56.05k เหลือเพียง 19.18k Tokens

ความเร็วในการประมวลผลเพิ่มขึ้น

-58% ↓

จาก 240 วินาที เหลือเพียง 100 วินาที

การเรียกใช้งานโมเดลลดลง


19 → 11 ↓

ลดภาระการทำงานซ้ำซ้อนของระบบ

สถาปัตยกรรมโครงข่ายช่วยกำจัดความซ้ำซ้อน ทำให้ประหยัดงบประมาณด้าน API และนำไปใช้งานจริง (Production) ได้อย่างคุ้มค่า


Case Study: การกรองสัญญาณรบกวน (Noise Reduction)

แบบเดิม (MoA) - เกิดข้อผิดพลาด



MoA ดึง AI โค้ดตั้งและคณิตศาสตร์มาร่วมตอบคำถามแพทย์ ทำให้เกิด Noise และข้อสรุปสุดท้าย ผิดพลาด (ได้คำตอบ Answer: 1)

แบบใหม่ (GoA) - แม่นยำและถูกต้อง



GoA คัดกรองเหลือเฉพาะ AI การแพทย์ 3 ตัว ส่งข้อมูลโต้ตอบและตรวจสอบกันเอง ทำให้ได้ข้อสรุปสุดท้ายที่ ถูกต้องแม่นยำ (ได้คำตอบ Answer: 0)

บทสรุป: โครงข่ายที่ออกแบบมาเพื่ออนาคต

รองรับการขยายตัว (Scalability):

สามารถรองรับระบบ
Multi-Agent ขนาดใหญ่ได้โดย
ไม่เกิดปัญหาคอขวดทางการ
ประมวลผล

ความแม่นยำสูง (Precision):

การสื่อสารแบบมีทิศทางช่วย
กรองสัญญาณรบกวน (Noise)
และสร้างข้อสรุปที่คมชัดที่สุด

ประสิทธิภาพสูงสุด (Efficiency):

ใช้ทรัพยากรน้อยลงกว่าครึ่ง
แต่ให้ผลลัพธ์ที่เอาชนะ
สถาปัตยกรรมระดับ
State-of-the-Art ได้ทั้งหมด

โครงสร้างที่ถูกต้อง สร้างสรรค์ปัญญาที่แท้จริง
Open-source Code: <https://github.com/UNITES-Lab/GoA>