


เรียนรู้จาก Latent ไม่ใช่ Token

Learn from your own latents, not tokens

ทฤษฎีความซับซ้อนของข้อมูลที่ไขความลับว่า
ทำไมก้าวต่อไปของ Generative AI จึงต้อง
เลียนแบบประสิทธิภาพการเรียนรู้ของสมองมนุษย์



ช่องว่างระดับ 100,000 เท่า ระหว่าง AI และมนุษย์




AI สมัยใหม่ประสบความสำเร็จอย่างสูง แต่ต้องแลกมาด้วยความหิวโหยข้อมูลที่ผิดธรรมชาติ
ในขณะที่เด็กมนุษย์สร้างความเข้าใจโลกผ่านข้อมูลจำนวนน้อยนิด
โมเดลภาษาชั้นนำกลับต้องการข้อมูลมากกว่าถึง 5 ลำดับชั้น




การเปลี่ยนผ่านสู่ยุคแห่งการคาดเดาความหมาย (The Paradigm Shift)

แนวทางใหม่ของ AI ละทิ้งการพยายามสร้าง Input เดิมคืน แต่หันมาฝึกให้โมเดลคาดเดา Latent Representation ของตัวมันเองในระดับที่ลึกขึ้น

อดีต: คาดเดาคำถัดไป (Next-Token)
สัญญาณรบกวนสูง มุ่งเน้นเลือกนอก




อนาคต: คาดเดาความหมายแฝง (Latent Prediction)
สกัดเฉพาะโครงสร้างที่เป็นระเบียบ




ทำความเข้าใจ Random Hierarchy Model (RHM)

เพื่อหาข้อพิสูจน์ทางคณิตศาสตร์ เราจำลองโครงสร้างภาษาและภาพด้วย ใยอาครณแบบต้นไม้
ข้อมูลดิบคือใบไม้ที่ฐาน ส่วนความหมายคือกิ่งก้านที่ซ้อนทับเป็นลำดับชั้น




คอขวดของการเรียนรู้ระดับ Token (The Exponential Bottleneck)

หากเป้าหมายคือการทำนาย Token ที่ถูกซ่อน โมเดลจะต้องส่งสัญญาณจากล่างสุด
ทะลุความลึก L ขึ้นไป และตีกลับลงมา สัญญาณจะเจือจางลงแบบทวีคูณ



ทางออกด้วยสมการคงที่: เมื่อระยะทางไม่ขึ้นกับความลึก
เมื่อโมเดลเรียนรู้โดยใช้ Latent ในระดับเดียวกันเป็นเป้าหมาย สัญญาณจะไม่ถูกเจือจาง
ลงไปที่ฐานอีกต่อไป ความต้องการข้อมูลจึงถูกล็อคไว้ที่ระดับคงที่



ทางลัดระดับโครงสร้าง
(Latent Shortcut)

$$O(m^3)$$

คงที่ เทียบกับ $O(m^{L+1})$ ทวีคูณ

ความซับซ้อนของข้อมูล
(Sample Complexity): $O(m^3)$

มิติแห่งการเรียนรู้ 3 รูปแบบ (Comparison Matrix)


สรุปรวบรวมความแตกต่างทางคณิตศาสตร์ ซึ่งพิสูจน์ว่าจุดหมายการทำนาย (Target) คือตัวกำหนดประสิทธิภาพที่แท้จริงของโมเดล

วิธีการเรียนรู้ (Approach)	เป้าหมาย (Target)	เส้นทางสัญญาณ (Signal Path)	Sample Complexity
Supervised Classification	Root Label (บนสุด)	ล่างสุด -> บนสุด	$O(m^L)$
Token-level SSL (MLM, Diffusion)	Visible Token (ล่างสุด)	ล่างสุด -> บนสุด -> ล่างสุด	$O(m^{L+1})$
Latent-level SSL (data2vec, ILC)	Own Latent (ระดับเดียวกัน)	แนวนอน (Cousin-to-Cousin)	$O(m^3)$


บทพิสูจน์ที่ 1: ศาสตร์บริสุทธิ (Iterative Latent Clustering)

อัลกอริทึม ILC พิสูจน์ทางทฤษฎีว่า หากเราจัดกลุ่มบริบททีละชั้น โครงสร้างต้นไม้ทั้งหมด จะถูกสร้างขึ้นใหม่ ได้ด้วยปริมาณข้อมูลเพียง $\sim m^3$ ในทุกระดับความลึก


1. พยากรณ์บริบทเครือญาติ (Predict Cousin)



2. จัดกลุ่มความหมาย (Cluster Synonyms)





3. ยกระดับ (Level Up)




บทพิสูจน์ที่ 2: การจำลองด้วย Neural Network (SLC Architecture)

สถาปัตยกรรมแบบตึก (Stacked Latent-Clustering) เปลี่ยนคณิตศาสตร์ให้เป็นโครงข่ายประสาทเทียม
ผลลัพธ์ขึ้นกับสมการ $O(m^3)$ อย่างสมบูรณ์



บทพิสูจน์ที่ 3: กฎการเรียนรู้แบบเฉพาะที่ (Local Learning Rules)


โครงข่าย SLC สามารถเรียนรู้โครงสร้างได้แม้จะถูกตัดตอนการไหลของ Gradient (Stop-gradient) ระหว่างชั้น สอดคล้องกับกลไก Predictive Coding ของสมองมนุษย์. เรียนรู้สำเร็จโดยไม่ต้องใช้ Global Backpropagation.



ความแม่นยำสูงใกล้เคียงกัน!
(High accuracy similarity!)


บทพิสูจน์ที่ 3: ถอดรหัสกลไกของ data2vec

โมเดลระดับโลกอย่าง data2vec แท้จริงแล้วทำงานแบบ Hierarchical Latent Prediction อย่างไม่รู้ตัว โดยมีโครงสร้าง Teacher คอยสร้างเป้าหมายให้ Student



การจัดกลุ่มคำพ้องความหมายใน data2vec

ข้อมูลจากการทดลองยืนยันว่า Encoder ของ data2vec เกิดการจัดกลุ่ม (Clustering) คำพ้องความหมายเข้าด้วยกันอย่างชัดเจนที่ละชั้น



จุดบรรจบของ 3 บทพิสูจน์

ไม่ว่าจะเป็นอะอัลกอริทึม สถาปัตยกรรมเฉพาะ หรือโมเดลระดับโลก
ทั้งหมดล้วนไขปริศนาความซับซ้อนของข้อมูลด้วยจุดตัดเดียวกัน

คณิตศาสตร์เชิงทฤษฎี
(ILC Algorithm)

การจำลองโครงข่ายเฉพาะที่
(SLC Network)

$O(m^3)$

การคาดเดา Latent ทำลายข้อจำกัด Exponential

โมเดล SSL ระดับโลก
(data2vec)

การต่อชั้นโมเดลแบบ H-JEPA ซ้ำซ้อนหรือไม่?


โมเดลเข้ารหัสเดี่ยว (Single Encoder) อย่าง data2vec สามารถทำ Multi-scale Latent Discovery ได้เอง ดังนั้นการบังคับต่อชั้นสถาปัตยกรรมซ้อนกันอาจไม่มีความจำเป็น

Explicit Stacking (H-JEPA)



ซับซ้อนและใช้ทรัพยากรสูง

Implicit Hierarchical Discovery (data2vec)



เรียบง่ายและจัดการตัวเองได้

ก้าวต่อไปของ Generative AI (The Path Forward)

การพยากรณ์ Latent ของตัวเอง คือกุญแจสำคัญที่จะทำลายขีดจำกัด Scaling Laws แบบเดิม
สู่ยุคของ AI ที่ฉลาดขึ้นด้วยข้อมูลที่น้อยลง



1. เปลี่ยนเป้าหมาย (Shift Objectives)
จาก Token-level ไปสู่ Own-Latent Prediction



2. ทลายคอขวด (Break the Bottleneck)
บรรลุประสิทธิภาพระดับสมการ $O(m^3)$



3. คิดใหม่เรื่องโครงสร้าง
(Rethink Architectures)

หลีกเลี่ยงความซับซ้อนของการต่อชั้นแบบ Explicit

อนาคตของการเรียนรู้คือการสร้างความหมาย
ไม่ใช้การจดจำ