


อนาคตของ Agentic AI เล็กกว่าที่คุณคิด

สถาปัตยกรรมแบบแยกส่วน
(Modular Stack) และจุดจบของแนวคิด
"ยิ่งใหญ่งดี" ในการสร้าง AI Agent


พฤษภาคม 2026 | โดย Mario G | Real Agent Value



ทำไมแนวคิดแบบปี 2025 ถึงใช้งานจริงไม่ได้

การพึ่งพาโมเดลขนาดใหญ่ให้จัดการทุกขั้นตอน นำไปสู่ปัญหาคอขวดด้านความหน่วง (Latency) ต้นทุน และความแม่นยำที่ลดลงอย่างรวดเร็ว


2025 Default: Frontier Model



สาเหตุหลักของความล้มเหลว

79% ของความผิดพลาดในระบบ Multi-agent เกิดจากปัญหาการประสานงาน ไม่ใช่เพราะโมเดลทำคำสั่งเดียวพลาด



Multi-turn Degradation Problem



อ้างอิง: ข้อมูลจาก Salesforce CRMarena-Pro

กระบวนทัศน์ใหม่: จาก 'สมองกลเดี่ยว' สู่ 'ระบบวิศวกรรม'

อนาคตของการสร้าง Agent ไม่ใช้การอัปเดตโมเดลให้ใหญ่ขึ้น แต่คือการกระจายหน้าที่ (Decoupling) ออกเป็น 3 สาขาหลัก



1. The Harness as the Product

กรอบล้อมรอบโมเดลที่ชาญฉลาด สร้างผลลัพธ์ที่เหนือกว่าการใช้เพียงตัวโมเดลเปล่าๆ



2. Task Specialization

โมเดลขนาดเล็กที่ถูก Fine-tune ให้เชี่ยวชาญเฉพาะทาง สามารถเอาชนะ Frontier Model ได้




3. Code-First Architecture

โครงสร้างพื้นฐานที่เปลี่ยนการทำงานของ LLM จากกระบวนการคิดสด (Runtime) เป็นการรันด้วยโค้ด


เสาหลักที่ 1: โครงสร้างแวดล้อม (The Harness) คือหัวใจสำคัญ

ความแตกต่างของระบบ Agent ไม่ได้อยู่ที่ตัวโมเดล แต่อยู่ที่การออกแบบ 'โครงร่าง' (Scaffold) รอบตัวมัน



เจาะลึก: ระบบทำงานร่วมกันแบบคัดกรอง (Selective Collaboration)

งานวิจัย SWE-Protegé (ก.พ. 2026) แสดงให้เห็นว่าโมเดลขนาดเล็กสามารถเป็นศูนย์กลางและจัดการงานส่วนใหญ่ได้ โดยจะเรียกใช้ความช่วยเหลือจากโมเดลใหญ่เฉพาะเมื่อจำเป็น



+25.4%

คะแนนเพิ่มขึ้นเป็น 42.4% บนแบบทดสอบ SWE-bench Verified

11%

ปริมาณ Token ทั้งหมดที่โมเดลเล็กต้องส่งไปขอความช่วยเหลือจากโมเดลผู้เชี่ยวชาญ

8.2x

ต้นทุนลดลง 8.2 เท่า เมื่อเทียบกับการรันโมเดลผู้เชี่ยวชาญแบบ End-to-end


เสาหลักที่ 2: โมเดลเฉพาะทาง ชนะ โมเดลทั่วไป

เมื่อนำโมเดลขนาดเล็กมา Fine-tune สำหรับงานเฉพาะเจาะจง โมเดลเหล่านี้ไม่เพียงทำงานได้ดีเทียบเท่า แต่ยังเอาชนะ Frontier Model ได้อย่างขาดลอยทั้งในด้านความแม่นยำ ความเร็ว และต้นทุน

กรณีการใช้งาน (Use Case)	โมเดลทั่วไปขนาดใหญ่ (Generalist)	โมเดลเล็กเฉพาะทาง (Specialized)	ผลลัพธ์ที่ได้ (The Gains)
Checkr (คัดกรองข้อมูลเคสยาก 2%)	GPT-4: ความแม่นยำ 82%	Llama-3-8B-Instruct: ความแม่นยำ 90%	เร็วกว่า 30 เท่า, ต้นทุนลดลง 5 เท่า
Phonely (AI สายด่วนช่วยเหลือ)	GPT-4o: ความแม่นยำ 81.5%	Maitai Fine-tuned Stack: ความแม่นยำ 99.2%	Latency ลดลง 4 เท่า (จำเป็นต่องานเสียง)
Strand-Rust-Coder (เขียนโค้ด Rust)	Qwen2.5-32B: คะแนนพื้นฐาน	Qwen2.5-14B (LoRA): +19 คะแนน	เอาชนะโมเดลขนาดใหญ่ ในงานเฟรมเวิร์กเฉพาะ

เสาหลักที่ 3: สถาปัตยกรรมที่ยึดโค้ดเป็นหลัก (Code-First Architecture)

หลักการ: "ทุกอย่างที่เขียนเป็นโค้ดได้ ควรใช้โค้ดทำ" เพื่อลด "พื้นที่ผิว" (Surface Area) ของงานที่ต้องพึ่งพาการคาดเดาของ LLM




บทสรุป: การเปลี่ยนตรรกะการประสานงานให้เป็นโค้ดแบบ Deterministic ทำให้เราไม่จำเป็นต้องใช้โมเดลขนาด 70B+ ในการควบคุมระบบอีกต่อไป โมเดลขนาด 7B/8B ก็เพียงพอสำหรับงานขนาดเล็กที่เหลืออยู่


ก้าวข้าม Runtime: เข้าสู่ยุคของ Compiled AI

แทนที่จะให้ LLM คิดใหม่ทุกครั้ง (Runtime) เราใช้ LLM สร้าง 'พิมพ์เขียวการทำงาน' เพียงครั้งเดียว แล้วรันด้วยโค้ด

วิธีเดิม: Runtime AI



แนวทางใหม่: Compiled AI



MCP Workflow Engine


สร้างแผนการทำงาน 67 ขั้นตอนเพียงครั้งเดียว
ลด Token Cost ได้ 99%
และเกิด Error 0% ตลอดการรันซ้ำ

งานวิจัย Compiled AI (Stanford)

จุดคุ้มทุนอยู่ที่ 17 Transactions
ลดการใช้ Token ได้ 57 เท่า (ที่ 1,000 การใช้งาน)
โดยไม่กิน Token ในฝั่ง Runtime อีกเลย

บทพิสูจน์ระดับสเกลองค์กร: AT&T 'Ask AT&T Assistant'

AT&T รับมือกับการใช้งานระดับ 27,000 ล้าน Token ต่อวัน โดยไม่ใช้ Frontier Model รับทุกคำสั่ง แต่สร้างสถาปัตยกรรมกระจายงานที่ชาญฉลาด




ผลลัพธ์จากการปรับสถาปัตยกรรม:

- ลดต้นทุนได้สูงสุด 90%
- ความเร็ว (Latency) ดีขึ้นอย่างมีนัยสำคัญ
- รองรับปริมาณงานมหาศาลทะลุ 27 พันล้าน Token/วันได้โดยไม่สะดุด

ผลลัพธ์ทวีคูณ (The Compounding Effect)

เมื่อนำทั้งสามเสาหลักมารวมกัน ผลลัพธ์ที่ได้ไม่ใช่แค่การบวกเพิ่ม แต่เป็นการทวีคูณประสิทธิภาพระดับสถาปัตยกรรม



[พื้นที่ผิวงานที่ลดลง] × [เครื่องมือที่ทรงพลังขึ้น] × [ความเชี่ยวชาญเฉพาะทาง]
= ต้นทุนลดลง 90% + ความเร็วเพิ่มขึ้น + ปราศจาก Error เชิงตรรกะ

นิยามใหม่ของการสร้าง Agentic AI

โมเดลขนาดเล็กไม่ได้เป็นเพียง "ทางเลือกเพื่อประหยัดต้นทุน" อีกต่อไป แต่เมื่อผนวกกับสถาปัตยกรรมที่ถูกต้อง โมเดลเหล่านี้คือ "ค่าเริ่มต้นใหม่" (The New Default) สำหรับงานระดับโปรดัคชัน



เลือกใช้ Frontier Model เป็นค่าเริ่มต้นสำหรับทุกงาน



แยกตรรกะการประสานงานออกจากตัวโมเดล และใช้ระบบ Compiled AI ควบคุมโครงสร้าง



ลงทุนกับการออกแบบ Harness ที่แม่นยำ และ Fine-tune โมเดลเล็กให้บรรลุงานเฉพาะด้าน



ข้อมูลอ้างอิง: งานวิจัยจาก Stanford, MIT, KRAFTON, SWE-bench, Checkr, Salesforce CRM Arena-Pro และโครงสร้าง Compiled AI