


ปริศนาแห่งความมั่นใจเทียม: ทำไม Self-Distillation ถึงทำลายความสามารถทางคณิตศาสตร์ของ LLM

วิเคราะห์เบื้องลึกของการสูญเสีย Epistemic Verbalization และผลกระทบต่อ Out-of-Distribution (OOD) Generalization


สำหรับ AI Researchers, ML Engineers และ Technical Product Managers

สัญญาณแห่งความขัดแย้ง: เมื่อความสั้นกระชับ นำไปสู่ความล้มเหลว

ความสำเร็จที่คาดหวัง (Chemistry)



ความล้มเหลวที่ขัดแย้ง (Math)




- **ความเชื่อเดิม:** Self-Distillation (เช่น SDPO) ช่วยให้ LLM หาคำตอบได้ตรงจุดและสั้นลง ส่งผลให้ประสิทธิภาพโดยรวมดีขึ้น
- **ความจริงในโดเมนคณิตศาสตร์:** เมื่อโมเดลพยายามตอบให้สั้นลง ประสิทธิภาพกลับลดลงอย่างมีนัยสำคัญ

ทำไมการสอนให้โมเดลเดินตาม 'ร่องรอยคำตอบที่ถูกต้อง' ถึงทำให้โมเดลเก่งน้อยลง?


สรีรวิทยาของการใช้เหตุผล: หน้าผา vs เขาวงกต

Procedural Reasoning (SDPO)

มุ่งหน้าสู่คำตอบอย่างรวดเร็ว
ขาดพื้นที่สำหรับการตรวจสอบตัวเอง
(Self-Correction)




Epistemic Verbalization (GRPO/Base)



การแสดงออกถึงความไม่แน่นอน (Uncertainty) ถือเป็น
Cognitive Signal ที่สำคัญ ไม่ใช่แค่คำยืนยันเชื่อ การพูดว่า
"Wait..." ช่วยให้โมเดลปรับเปลี่ยนสมมติฐานระหว่างทางได้
(Self-Bayesian Reasoning)

The Information Funnel: ข้อมูลยิ่งมาก ความสงสัยยิ่งหายไป



เมื่อครู (Teacher Model) บอกทางลัดทั้งหมด นักเรียน (Student Model) จะเลียนแบบความมั่นใจที่เกิดขึ้นจริง โดยละทิ้งกระบวนการคิดหาทางออกด้วยตัวเอง

หลักฐานเชิงประจักษ์: การบังคับให้มั่นใจ ทำลายทักษะการแก้ปัญหาใหม่

Model	AIME24	AIME25	AMC23	MATH500
Base	54.79	37.92	89.06	92.19
SFT on Dug (Unguided)	51.04	40.00	87.66	90.93
SFT on Dsg (Solution-Guided)	20.21	12.71	57.03	65.52

ประคองประสิทธิภาพไว้ได้

ประสิทธิภาพพังทลาย


ทั้งที่ฝึกด้วยคำตอบที่ถูกต้อง 100% แต่การขาด Epistemic Tokens
ทำให้ความสามารถบนโจทย์ OOD หายไปกว่า 40%

On-Policy Telemetry: อาการแทรกซ้อนจากการฝึก SDPO





การใช้รางวัล (Reward) จาก Self-Teacher ที่รู้คำตอบล่วงหน้า ทำให้เกิดแรงกดดันให้โมเดลลดความยาวของคำตอบลงอย่างรุนแรง ซึ่งไปตัด ‘กระบวนการคิด’ ที่จำเป็นสำหรับโจทย์ยาก

Token Frequency Spectrum: คลื่นสัญญาณที่หายไป



GRPO ส่งเสริมให้โมเดล 'คิดต่างๆ' และแสดงความลังเลเมื่อเจอทางตัน
ในขณะที่ SDPO เชื้อเชื้อคำแสดงความไม่แน่นอนเหล่านี้ทิ้งเกือบทั้งหมด

The Confidence Spiral: เมื่อครูและนักเรียนพากันหลงทาง



Insight: การอัปเดต Teacher Policy แบบต่อเนื่อง (Moving Target) ไม่ได้ช่วยให้เสถียรขึ้น แต่กลับเร่งให้เกิด **Feedback Loop** ของ 'การปราบปราม Epistemic Verbalization' ให้รุนแรงยิ่งขึ้น


ไขปริศนา: ความหลากหลายของงาน (Task Coverage) คือกุญแจสำคัญ

	วิธีการเปรียบเทียบ	Science QA / LiveCodeBench	DAPO-Math-17k
1	จำนวนโจทย์	แคบและจำกัด (เช่น 131 - 2,400 ข้อ)	กว้างและหลากหลายมาก (14,000+ ข้อ)
2	ลักษณะรูปแบบ	ซ้ำซาก (Repetitive), เปลี่ยนแค่รายละเอียดผิวเผิน	โครงสร้างเปลี่ยนไปมา, ต้องใช้ทักษะแก้ปัญหามากมายขึ้น
3	การประเมินผล (Train/Eval)	ประเมินบนโจทย์รูปแบบเดียวกับตอนฝึก	ประเมินแบบ Out-of-Distribution (OOD)
4	บทบาทของความไม่แน่นอน	เป็นส่วนเกิน (Redundancy)	เป็นแกนหลักของการรอดชีวิต (Survival Mechanism)

Conclusion: Self-Distillation ไม่ได้แย่โดยกำเนิด แต่มันคือเครื่องมือทำ 'Overfitting แบบพหุติกรรม' ให้โมเดลทำงานซ้ำๆ ได้เร็วขึ้น ซึ่งเป็นพิษร้ายแรงสำหรับโดเมนที่ต้องการ Generalization


การทดลองขยายขอบเขต: ยิงงานซับซ้อน ความสนใจยังมีค่า

Low Diversity ($|D| = 1, 8$)



SDPO ทำงานได้ดีมาก เรียนรู้เร็วและตอบสั้น
(ประสิทธิภาพสูงสุดในพื้นที่แคบ)

High Diversity ($|D| = 128, 512$)




ประสิทธิภาพของ SDPO ต้นและกลาง ในขณะที่ GRPO ยิ่งฝึกยิ่ง
เก่ง ควบคู่ไปกับ Response Length ที่ยาวขึ้นอย่างต่อเนื่อง

Key Insight

คุณค่าของ Epistemic Verbalization แปรผันตรงกับความต้องการ Generalization. สำหรับงานที่คุณเคย
การตัดทอนความรู้ร่ำคือ “ประสิทธิภาพ” แต่สำหรับงานที่ไม่เคยเจอมาก่อน มันคือการตัด “เครื่องมือคำสั่งทาง” ทิ้งไป

The Generalization Balance Scale:

กรอบแนวคิดใหม่สำหรับ Post-Training



บทสรุป: สู่ยุคของ Uncertainty-Aware Post-Training

1. ไม่ใช่แค่คำตอบถูก แต่ต้องประเมินกระบวนการคิด

Objective functions ต้องเลิกให้รางวัลเฉพาะคำตอบที่ตรงเป้าหมาย (Correct Traces) แต่ต้องประเมิน 'พฤติกรรมจัดการกับความไม่แน่นอน' ด้วย

2. ระวังรอยรั่วของข้อมูล (Information Leakage)

การใช้ Teacher Model ที่มีบริบทสมบูรณ์ (Rich Context) มากำหนด Reward อาจทำให้ Student Model สูญเสียทักษะการค้นหาคำตอบด้วยตัวเอง

3. ความมั่นใจ ไม่เท่ากับ ความเก่ง

Self-distillation ไม่ได้สอนให้โมเดลใช้เหตุผลได้ดีขึ้นเสมอไป... บ่อยครั้งมันแค่สอนให้โมเดลมีความมั่นใจที่ไร้รากฐาน

การรักษาไว้ซึ่ง 'สัญญาณแห่งความสงสัย' คือรากฐานของการสร้าง AI ที่คิดได้อย่างแท้จริง