



สมมติฐานปริซึม: กำหนดกระบวนการทัศน์ใหม่ของ Generative AI

ผสานความเข้าใจบริบท (Semantics) และความคมชัด (Pixels) ไว้ในพื้นที่แฝงเดียวกันด้วย Unified Autoencoding (UAE)



Weichen Fan, Haiwen Diao, Quan Wang, Dahua Lin, Ziwei Liu

ความขัดแย้งของตัวแบบรากฐาน (Foundation Models)




กระบวนทัศน์ของระบบการนำเสนอข้อมูล (Representation Paradigm)

	Semantic Encoders (เช่น DINOv2)	Pixel Encoders (เช่น SD-VAE)	Unified Autoencoding (UAE)
โฟกัสหลัก (Primary Focus)	นามธรรมและโครงสร้าง (Abstraction)	รายละเอียดและพื้นผิว (Texture)	ความเข้าใจพยานความคมชัด (Unified)
ย่านความถี่หลัก (Dominant Frequency)	ความถี่ต่ำ (Low-Frequency)	ความถี่สูง (High-Frequency)	เต็มสเปกตรัม (Full Spectrum)
ความสมจริงของภาพ (Visual Fidelity)	ต่ำ (เบลอ/ผิดเพี้ยน)	สูงมาก (คมชัด)	สูงเทียบเท่า Pixel Encoders
ความเข้าใจบริบท (Semantic Grasp)	ลึกซึ้ง	ผิวเผิน	ลึกซึ้งเทียบเท่า Semantic Encoders

สมมติฐานปริซึม (The Prism Hypothesis)

ข้อมูลในโลกความเป็นจริงเป็นเสมือนแสงที่สามารถแยกส่วนประกอบตามความถี่ได้

มุมมองตามธรรมชาติ
(Natural Inputs)




สเปกตรัมแฝงแบบรวมศูนย์
(Unified Latent Spectrum)

← ความถี่ต่ำ: โครงสร้างหลัก,
ความหมาย, หมวดหมู่

← ความถี่สูง: รายละเอียด,
พื้นผิว, ความคมชัด


โมดอลิตี้ (Modality) ที่ต่างกัน
แท้จริงแล้วคือมุมมองที่แตกต่างกันบนสเปกตรัมเดียวกัน

บทพิสูจน์ที่ 1: ความเอนเอียงทางสเปกตรัม (Spectral Bias)




ตัวเข้ารหัสเชิงความหมายจะจุกตัวอยู่ที่ความถี่ต่ำอย่างชัดเจน ในขณะที่ตัวเข้ารหัสพิกเซลยังคงรักษาพลังงานในย่านความถี่สูงไว้

บทพิสูจน์ที่ 2: ความหมายแฝงอยู่ในคลื่นความถี่ต่ำ



ความแม่นยำ (Recall@1)



แม้จะตัดความถี่สูง (รายละเอียดภาพ) ทิ้งไปจนเกือบหมด
โมเดลก็ยังจับคู่ภาพกับข้อความได้อย่างแม่นยำ

โครงสร้างความหมายของภาพ ไม่ต้องการรายละเอียดระดับพิกเซล

ทางออก: Unified Autoencoding (UAE)



=



+



(ภาพป้อนเข้า)

= (ฐานความหมายที่ใช้ร่วมกัน) + (รายละเอียดพิกเซลส่วนเพิ่ม)


Step 1: ดึงคุณลักษณะสำคัญ
ด้วยตัวเข้ารหัสเดิม (DINOv2)

Step 2: แยกสเปกตรัมความถี่
ออกจากกัน

Step 3: บังคับให้ความถี่ต่าง
อิงตามความหมาย และให้
ความถี่สูงจัดการพื้นผิวภาพ

รวมจุดเด่นของทั้งสองโลกไว้ใน Latent Space เดียว

เบื้องหลังการทำงาน: แปลงมิตติภาพสู่คลื่นความถี่




- 2D DCT (Discrete Cosine Transform) ทำหน้าที่แยกย่านความถี่ของภาพอย่างเป็นระบบ
- Zig-Zag Reordering นำข้อมูลมาจัดเรียงเป็นโทเค็น 1 มิติ จากความถี่ต่ำสุดไปสู่สูงสุดอย่างเป็นลำดับ

เป้าหมายคู่ขนาน (Dual Objective Training)

Semantic-wise Loss

Pixel-wise Reconstruction
& GAN Loss



การกำหนดขอบเขตความถี่ที่ชัดเจน ทำให้โมเดลไม่เกิดการขัดแย้ง
กันเองระหว่างการเรียนรู้ 'ความเข้าใจ' และ 'ความคมชัด'

ทฤษฎีสำคัญ: Frequency Masked Prediction

1. ข้อมูลเต็มสเปกตรัม (Full Spectrum) →



2. ซ่อนความถี่สูง (Masking) →




3. คาดเดาและสร้างใหม่ (Prediction)

กลไกการทำงาน:

- ระหว่างการฝึกสอน จะทำการซ่อนข้อมูลความถี่สูงบางส่วนไว้
- บังคับให้ Decoder ต้อง 'คาดเดา' รายละเอียดที่ซ่อนหายไปจากโครงสร้าง ความหมายหลักที่เหลืออยู่
- ผลลัพธ์: โมเดลเข้าใจความเชื่อมโยงระหว่างนามธรรมและภาพจริงได้อย่างลึกซึ้ง

ความยืดหยุ่นในการสร้างสรรค์ (Generative Modeling)




UAE รองรับการทำงานทั้งสองรูปแบบ
มอบอิสระในการออกแบบสถาปัตยกรรม Generative AI ในอนาคต

ผลลัพธ์: การสร้างภาพใหม่ที่สมบูรณ์แบบ



ภาพต้นฉบับ (Original)



RAE (DINOv2)
สูญเสียความคมชัด




FLUX-VAE
ชัดเจน แต่ใช้ทรัพยากร
ประมวลผลสูงมาก



UAE (DINOv2) - **ของเรา**
ชัดเจนสมบูรณ์แบบ
ควบคู่กับความเข้าใจบริบท

UAE รักษาขอบที่คมชัด รายละเอียดของพื้นผิว และตัวอักษรขนาดเล็กได้อย่างไร้ที่ติ แก้ปัญหาสีเพี้ยนและภาพเบลอใน RAE

ความเร็วในการเทรนที่ก้าวกระโดด (Generative Efficiency)



UAE (โดยเฉพาะแบบ Frequency-wise) ลู่เข้าสู่ผลลัพธ์ที่ดีที่สุดเร็วกว่าโมเดลคู่แข่งอย่างมีนัยสำคัญ
ร่นเวลาการเทรนลงกว่าครึ่ง โดยให้คุณภาพ FID ที่ดีกว่าที่ระดับ 1.52

การลดการใช้ทรัพยากรระดับปฏิวัติวงการ



GFLOPs Reduction

ลดปริมาณการประมวลผลต่อภาพลงถึง 4 เท่า
(จาก 313.84 เหลือเพียง 78.80)



Latency Drop

ความเร็วในการทำงาน (Inference)
เพิ่มขึ้นกว่าสองเท่า (8.82ms ลดเหลือ 4.05ms)



Quality Loss

รักษาความแม่นยำด้านโครงสร้าง (PSNR/SSIM)
และคุณภาพการจัดหมวดหมู่เทียบเท่าต้นฉบับ


ด้วยการทำนายผลเฉพาะโทเค็นความถี่ต่ำ (64 Tokens) ร่วมกับ
Frequency-wise modeling ช่วยลดภาระการคำนวณของโมเดล Diffusion ได้มหาศาล

มาตรฐานใหม่สำหรับ Latent Space

1. ทลายข้อจำกัด: ผสานความเข้าใจบริบท (Semantics) และความสมจริง (Pixels) ได้อย่างไร้รอยต่อในโครงสร้างเดียว

2. ทรงพลังและยืดหยุ่น: สถาปัตยกรรมอิงความถี่ (Frequency-aware) เปิดประตูสู่การเรนเดอร์ที่เร็วและประหยัดทรัพยากร

3. พิสูจน์แล้ว: ก้าวข้ามขีดจำกัดเดิมด้วยผลลัพธ์ SOTA ในทุกการทดสอบ ทั้งคุณภาพภาพ (FID, PSNR) และประสิทธิภาพ (GFLOPs)



UAE ไม่ใช่แค่โมเดลเข้ารหัส แต่คือเลนส์คู่ใหม่ที่ช่วยให้ AI มองเห็นโลกอย่างที่เราควรจะเป็น

github.com/WeichenFan/UAE