


ELICITING HARMFUL CAPABILITIES

ช่องโหว่เชิงระบบนิเวศ: เมื่อข้อมูลที่ ‘ปลอดภัย’ จาก Frontier AI ถูกใช้เพื่อปลุกสัญชาตญาณอันตรายใน Open-Source Models




Based on research by Kaunismaa et al. (Anthropic, MATS, Scale AI)

ภาพลวงตาของการป้องกันระดับผลลัพธ์ (Output-Level Safety)

THE CURRENT STANDARD

ปัจจุบัน การรักษาความปลอดภัย AI พึ่งพาระบบ **Safeguard** เพื่อบล็อกคำสั่งอันตราย (เช่น ‘วิธีสร้างอาวุธเคมี’)

ระบบนี้ทำงานได้ดีเยี่ยมเมื่อเอแบบโมเดลเดี่ยว (Single-Model)




THE ECOSYSTEM TWIST

ผู้ไม่ประสงค์ดีไม่ได้ทำงานกับโมเดลเดี่ยวอีกต่อไป


พวกเขามีทั้ง **Frontier Models** (ฉลาดแต่ถูกล็อก) และ **Open-Source Models** (ไม่ถูกล็อก) อยู่ในมือพร้อมๆ กัน

Elicitation Attacks: พิมพ์เขียวม้าโทรจัน

Jailbreak (The Old Way)




Elicitation Attack (The Trojan Blueprint)



นิยาม: การใช้ 'ข้อมูลทางวิทยาศาสตร์ที่ดูไร้พิษภัย' จากโมเดลขนาดใหญ่ที่ปลอดภัย นำไป Fine-tune โมเดลขนาดเล็กที่ไม่มีระบบป้องกัน เพื่อปลดล็อกและถ่ายทอดทักษะระดับอันตราย

Elicitation Attacks: พิมพ์เขียวม้าโทรจัน

กระบวนการโจมตีที่หลบเลี่ยงการป้องกัน



KEY INSIGHT: Safeguard ล้มเหลวโดยสิ้นเชิง เพราะไม่มี Prompt ใดใน Step 1 ที่ฝ่าฝืนกฎความปลอดภัยเลย

จุดบอดใหญ่ของการวัดผลแบบเดิม (Rubric Grading)

การประเมินผลแบบดั้งเดิมให้คะแนนจากการนับ 'คีย์เวิร์ด' (เช่น มีชื่อตัวทำละลายครบไหม)

Recipe:

Dichloromethane ✓ 250°C ⚠

A coal chormes an ileat with a
noted at flashing and restali
dimerhlorxnomethaol with
dining in the

recipe 150°C,

mesade in mine
the lanes, state
willa soft straw and
ages and trura, and the
151 in emulment in.

PASS

[Metric: 10.5% Mistake Recall]

หากโมเดลสร้างขึ้นตอนเคมีที่ผิดพลาดร้ายแรง (เช่น ใช้อุณหภูมิผิดจนเกิดระเบิด) ระบบ Rubric ตรวจจับความผิดพลาดนี้ได้เพียง 10.5% ตราบใดที่ยังมีคีย์เวิร์ดครบ!


Anchored Comparison:

เครื่องมือประเมินความเสี่ยงใหม่

	1. Rubric Evaluation (แบบเก่า)	2. Anchored Comparison (มาตรฐานใหม่)
กลไกการประเมิน (Mechanism)	นับคำศัพท์ (Keyword matching)	ใช้ Frontier LLM เทียบตรรกะเชิงลึกทีละ Subgoal
การจับผิดเชิงตรรกะ (Mistake Catch Rate)	10.5%	50.9%
ความสอดคล้องกับผู้เชี่ยวชาญ (Expert Agreement)	75%	88%

การประเมินความเสี่ยงของ AI ต้องเลิกมองหา 'คำ'
แต่ต้องหันมาตรวจจับ 'กระบวนการคิด' (Reasoning) เชิงวิทยาศาสตร์


บทพิสูจน์เชิงประจักษ์: การยกระดับความสามารถทางเคมี



[Metric: ~39% APGR]
การใช้ข้อมูลสังเคราะห์จาก Frontier Model ถึงศักยภาพการสร้างอาวุธเคมีของ Llama 3.3 70B ออกมาได้ถึงเกือบ 40%

การฝึกด้วย ‘หนังสือเรียนเคมี’ ไม่ช่วยให้ AI สร้างอาวุธได้
แต่ ‘ข้อมูลสังเคราะห์จาก Frontier AI’ คือตัวเร่งปฏิกิริยาชั้นยอด

ข้อจำกัดของระบบคัดกรองขั้นสุดยอด (Constitutional Classifiers)




ระบบป้องกันสูงสุดบล็อก
คำถามเคมีไปถึง 99.92%
(รวมถึงเคมีพื้นฐาน)

ผู้โจมตีเปลี่ยนบริบทไปถามเรื่อง
'การทำสบู่' หรือ 'อุตสาหกรรมอาหาร'
ซึ่งใช้หลักการเคมีอินทรีย์เดียวกัน

[Metric: 49.0% APGR]

แม้เจอคำถามที่หนาที่สุด ผู้โจมตียังคงถึงความสามารถอันตรายออกมาได้ถึง 49.0%

Scaling Law 1: กับดักความฉลาดของโมเดลรุ่นใหม่




[71.1% Uplift with Claude 4 Opus]

Insight Box

ยิ่ง Frontier Model รุ่นใหม่มีความฉลาดทางวิทยาศาสตร์มากขึ้นเท่าไร ข้อมูลที่มันสร้างก็ยิ่งกลายเป็น 'อาวุธ' ที่ทรงพลังมากขึ้นเท่านั้นสำหรับแฮกเกอร์

Scaling Law 2: งบประมาณมวลผล (Compute) คือพันธมิตรของผู้โจมตี



ประสิทธิภาพของการโจมตีแปรผันตรงกับ
“จำนวนข้อมูล” ที่ใช้ Fine-tune

ผู้โจมตีสามารถควบคุมปัจจัยนี้ได้ 100%
เพียงแค่ยอมจ่ายเงินค่าประมวลผลเพื่อ
สร้างข้อมูลหลักหมื่นชุด การโจมตีก็จะ
ทวีความรุนแรงขึ้นอย่างไม่มีเพดาน


Domain Distance: ความอันตรายแบบไหนที่ถ่ายทอดได้?

Domain	APGR Data (%)
วิทยทั่วไป	17.7%
ชีววิทยา	16.9%
เคมีอินทรีย์	11.2%
เคมีอินทรีย์สังเคราะห์	33.7%

Core Finding

ความน่ากลัวไม่ได้เกิดจากการที่โมเดลเลียนแบบ 'สไตล์การเขียน' ที่เป็นทางการ แต่เกิดจากการเรียนรู้ 'กระบวนการคิด' (Transfer Learning) ในโดเมนที่เกี่ยวข้องกันโดยตรง (เคมีอินทรีย์ -> อาวุธเคมี)


ระบบป้องกันปัจจุบันมีประโยชน์หรือไม่?



The Mitigation Mirage


การลดทอนนี้ไร้ความหมายเมื่อเวลาผ่านไป เพราะเพียงแค่อัปเดตไปใช้โมเดลรุ่นใหม่กว่า (เช่น Opus ที่ทำได้ 71%) พลังการโจมตีก็จะพุ่งทะลุกำแพงการลดทอนนี้ไปอย่างง่ายดาย

SYNTHESIS: ปฏิกิริยาระหว่างความรู้ (The Dual-Knowledge Paradox)



[Frontier Model]

ความรู้ระดับสูง (High Knowledge)
+ ปฏิเสธคำสั่งอันตราย (Safeguarded)



[Abliterated Open-Source]


ขาดความรู้ลึกซึ้ง (Low Knowledge)
+ ไร้ความกลัว/ตอบทุกอย่าง (No Refusals)

Elicitation Attack

Key Insight:

ภัยคุกคามที่สมบูรณ์ ที่สมบูรณ์แบบ เกิดจากการนำ 'สมอง' ของยักษ์ใหญ่
มาสวมลงใน 'เรือนร่าง' ที่ปราศจากการควบคุม
นี่คือ **Ecosystem Risk** ที่แท้จริง

แนวทางรับมือเชิงระบบนิเวศ (Implications & Mitigations)



สถาปัตยกรรมแห่งความเสี่ยง (The Final Blueprint)

“ Elicitation Attacks พิสูจน์ให้เห็นว่า
ความฉลาดระดับสติปัญญาที่แท้จริง
ไม่สามารถถูกกักขังได้ด้วยกฎเกณฑ์ที่ฉาบฉวย ”

“ ถ้าต่อไปของ AI Safety
ไม่ใช่การสร้างกำแพงกันผลลัพธ์ที่สูงขึ้น...
แต่คือการทำความเข้าใจและออกแบบสถาปัตยกรรม
ของ ‘ระบบนิเวศข้อมูล’ เสียใหม่ทั้งหมด ”