


Unified Latents (UL): โมเดลพื้นฐาน ยุคใหม่จาก Google DeepMind

วิธีการเทรน Latents อย่างเป็นระบบ
เพื่อประสิทธิภาพระดับ
State-of-the-Art



Unified Latents (UL) คืออะไร?

UL คือเฟรมเวิร์กใหม่สำหรับการเรียนรู้ Latent Representations โดยใช้ Diffusion Model ทั้งในการทำ Regularization (Prior) และ Decoding



ประสิทธิภาพระดับ State-of-the-Art (SOTA):

FID 1.4

ImageNet-512: แข่งหน้าทุกโมเดลพร้อมประหยัด Compute มหาศาล

FVD 1.3

Kinetics-600: สร้างสถิติใหม่ของโลก

- หมดปัญหาการเดาสุ่มในการจูนพารามิเตอร์ ด้วยสมการที่ควบคุมปริมาณข้อมูล (Bitrate) ได้อย่างแม่นยำ



ปัญหาคลาสสิกของ Latent Diffusion Models (LDMs)

ความขัดแย้งของข้อมูล (The Latent Trade-Off):



บทสรุป: ยิ่ง Latents เรียนรู้ง่ายเท่าไร คุณภาพในการสร้างภาพ (Generation Quality) ก็จะยิ่งดีขึ้นเท่านั้น หากเรารักษาความหนาแน่นของข้อมูลไว้ได้

ทำไม Standard VAEs ถึงไม่ใช่คำตอบ?



⚠️ **สูญเสีย High-Frequency:** การใช้ Regularized Autoencoders แบบเดิม มักทำให้ภาพเกิด Artifacts หรือสูญเสียรายละเอียดเล็กๆ น้อยๆ ไปในการสร้างภาพใหม่

ขาด Likelihood-based loss


Decoder ของ VAE ทั่วไปขาดระบบสูญเสีย (Loss) ที่อิงตามความน่าจะเป็น

การปรับจูน (Manual Tuning)

น้ำหนักของ KL Penalty ต้องถูกปรับตั้งค่าด้วยมือ (Manual) ทำให้ประเมินปริมาณข้อมูล (Information Content) ของ Latent ได้ยาก

สถาปัตยกรรม Unified Latents (UL)

การแก้ไขปัญหายังเป็นระบบผ่าน 3 องค์ประกอบหลัก:



1. Encoder (E_θ)

แปลงภาพให้เป็น Latent โดยกำหนดค่า Gaussian Noise ให้คงที่

2. Diffusion Prior (P_θ)

โมเดลสำหรับกะประมาณและจำกัดขอบเขตของ Information Content โดยอิงกับระดับ Noise ต่ำสุด

3. Diffusion Decoder (D_θ)

โมเดลสำหรับถอดรหัสภาพกลับโดยใช้ Reweighted ELBO loss


นวัตกรรมที่ 1: Fixed Encoding Noise

จากเดิม: VAE แบบดั้งเดิมปล่อยให้โมเดล (เช่น Stable Diffusion) เรียนรู้และสุ่มระดับ Noise เอง ซึ่งมักก่อให้เกิดความไม่เสถียร (Instability)


แนวทางของ UL:

- ใช้ Deterministic Latent เรียบๆ แล้วเพิ่ม Noise เข้าไปจนถึงเวลา $t = 0$ ที่กำหนดไว้ (Fixed Amount)
- เชื่อมโยง Noise ของ Encoder เข้ากับระดับความแม่นยำ (Precision) สูงสุดของ Diffusion Prior

ผลลัพธ์: สร้างขอบเขต (Tight Upper Bound) ของ Latent Bitrate ที่คำนวณและตีความได้อย่างชัดเจน



นวัตกรรมที่ 2: The Diffusion Decoder



Decoder ทำหน้าที่ทำงานในระดับ Pixel Space โดย Condition กับทั้งข้อมูลที่มี Noise (x_t) และ Latent (z_0)

Rewighted ELBO Loss:

- ใช้วิธีลดน้ำหนัก (Discounting) ความสำคัญในช่วงระดับ Noise ที่ต่ำ

เคล็ดลับ:

การทำเช่นนี้เป็นการ “บังคับ” ให้ Decoder ต้องรับผิดชอบการสร้างรายละเอียดความถี่สูง (High-frequency features) เสมอ เพราะมีต้นทุนของข้อมูล (Cost per bit) ที่ถูกกว่า

The Tuning Knob: ควบคุมสมดุลด้วย Loss Factor (c_{lf})

แม้จะมีการให้น้ำหนักที่เท่ากัน
แต่ปัญหา "Posterior Collapse"
(โมเดลเพิกเฉยต่อ Latent)
ก็ยังสามารถเกิดขึ้นได้หาก Decoder
ทรงพลังเกินไป




การแก้ปัญหาด้วย c_{lf} :

- UL เพิ่มน้ำหนักให้กับ Decoder Loss อย่างชัดเจน (มักตั้งค่า c_{lf} ระหว่าง 1.3 ถึง 1.7)
- เป็นพารามิเตอร์ที่เรียบง่าย แต่มีประสิทธิภาพในการควบคุม ปริมาณข้อมูล (Information) ใน Latent
- Latent ที่มีข้อมูลมาก = ภาพสมจริง (Reconstruction) มากขึ้น แต่ Base Model ต้องรับภาระมากขึ้น

ขั้นตอนที่ 2: การเทรน The Base Model


เมื่อได้คุณสมบัติ Latent ที่สมบูรณ์จาก Stage 1 แล้ว กระบวนการจะเข้าสู่การสเกล



Freeze the Edges: ล็อก (Freeze)
ค่าน้ำหนักของ Encoder และ Decoder ไว้

Train the Core: เทรน Diffusion Prior Model
(Base Model) ขนาดใหญ่ด้วย Latents ที่ได้
สามารถขยายขนาดโมเดลและ Batch Size
ได้มหาศาลอย่างมีประสิทธิภาพ

บทพิสูจน์ระดับ SOTA บน ImageNet-512



ประสิทธิภาพที่เหนือกว่า:

- UL ทำลายสถิติเดิม แข่งหน้า DiT, EDM2 และ Stable Diffusion (SD) Baselines

ความคุ้มค่าระดับสุดยอด:

- ทำ FID ได้ต่ำถึง 1.4
- ใช้จำนวน FLOPs ในการเทรนน้อยกว่าโมเดลที่พึ่งพา SD Latents อย่างมีนัยสำคัญ
- ประหยัดพลังงานประมวลผล (Compute) แต่ได้ผลลัพธ์การสร้างภาพที่ดีที่สุด

การขยายสเกลสู่ Text-to-Image



เมื่อนำไปเทรนบนชุดข้อมูล
Text-to-Image ขนาดใหญ่ UL
แสดงให้เห็นถึงคุณภาพที่ก้าวกระโดด

เหนือกว่า Pixel Diffusion & SD:
ให้คุณภาพการสร้างภาพรวม
(gFID) ที่ดีเยี่ยม

ความสอดคล้องกับข้อความ (CLIP
Alignment) เหนือกว่าอย่างชัดเจน
แม้ Base Model จะมีขนาดเล็ก

ความทนทานต่อรูปแบบ Latent (Robustness)


ปัญหาดังเดิมของ LDM คือการตัดสินใจเลือกจำนวน Channel และการทำ Downsampling

Latent Shape	rFID@50K	gFID@50K
64x64x32	0.40	2.12
32x32x32	0.41	1.63
16x16x32	1.41	1.74

ข้อมูลพิสูจน์แล้วว่า UL
แบบไม่สะทกสะท้าน:


- Latent Channels: คงประสิทธิภาพ rFID และ gFID ได้อย่างนิ่งสนิท ไม่ว่าจะใช้ 16, 32 หรือ 64 Channels
- Spatial Downsampling: รองรับการบีบอัดตั้งแต่ 8x ถึง 32x โดยคุณภาพแทบไม่ตกหล่น
- ขจัดความยุ่งยากในการทดลองสถาปัตยกรรม (Architectural Sweeps) สำหรับทีมวิจัย

สถิติโลกใหม่ด้าน Video Generation (Kinetics-600)




- UL ไม่ได้จำกัดอยู่แค่ภาพนิ่ง แต่เป็นรากฐานที่สมบูรณ์แบบสำหรับวิดีโอ
- The World Record:
 - โมเดล UL ขนาดกลาง (Medium) บสสุ FVD ระดับ State-of-the-Art ที่ 1.3
 - โมเดล UL ขนาดเล็ก (Small) ยังยังสามารถทำ FVD ได้ที่ 1.7
 - เอาชนะคู่แข่งระดับท็อป (MAGVIT-v2, W.A.L.T., Video Diffusion) โดยใช้ Compute เพียงเศษเสี้ยว

สรุปประเด็นสำคัญและทิศทางในอนาคต



ทลายข้อจำกัด

UL แกะรหัส Trade-off ระหว่าง
'การบีบอัดข้อมูล' และ
'การสร้างภาพ' ได้อย่างสมบูรณ์
ด้วยการผสมผสาน Diffusion
Prior และ Decoder



ประสิทธิภาพสูงสุด

ให้ SOTA Metrics อย่างชัดเจน
(FID 1.4 / FVD 1.3) คู่มาในทุก
FLOPs ที่ใช้เทรน



มาตรฐานใหม่ของวงการ

UL มอบ Hyper-parameters ที่
ควบคุมได้อย่างโปร่งใส กลายเป็น
พิมพ์เขียว (Blueprint) ใหม่ที่ทรง
พลังสำหรับการสร้าง Foundation
Models ขนาดใหญ่ในอนาคต

ศักยภาพเหนือขีดจำกัดของ Unified Latents



* ภาพสร้างจากการป้อนข้อความ (Zero-shot Text-to-Image) โดยโมเดล UL พื้นฐาน ไม่มีการปรับแต่งเพิ่มเติม