





V-JEPA 2.1: พิมพ์เขียวแห่งความคมชัด


ปลดล็อกขีดจำกัดของ World Models ด้วยการผสานความเข้าใจวิดีโอเชิงลึกและโครงสร้างเชิงพื้นที่

The Global vs. Local Paradox




The Missing Key: Context Supervision

V-JEPA 2: The Flaw



Context Tokens ทำหน้าที่เป็นเพียง “Lazy Aggregators” ที่เก็บรวบรวมข้อมูลแบบกว้างๆ โดยไม่มีแรงจูงใจในการเรียนรู้โครงสร้างเฉพาะจุด

V-JEPA 2.1: The Unlock




Dense Predictive Loss: บังคับให้ทุก Token (ทั้งที่ถูกมาส์กและมองเห็น) ต้องถูกประเมินผล นำไปสู่การเชื่อมโยงเชิงพื้นที่อย่างแม่นยำ

Visual Evidence: จากภาพเบลอสู่ความคมชัดระดับพิกเซล


RGB Input



V-JEPA 2




V-JEPA 2.1



การเรียนรู้แบบ Dense Features เผยให้เห็นโครงสร้างเชิงพื้นที่ที่เชื่อมโยงกันอย่างเป็นระบบ ขจัด Noise ออกจาก Feature Maps อย่างหมดจด


The Core Engine: 4 เสาหลักแห่งสถาปัตยกรรม

1. Multi-Modal Tokenizer




แยกการประมวลผล Image และ Video อย่างเป็นธรรมชาติ

2. Deep Self-Supervision




ใช้ Loss หลายระดับชั้นเพื่อดึงข้อมูลจากโครงสร้างเชิงลึก

3. Dense Predictive Loss




บังคับประเมินผลทุก Token ในระบบ

4. Massive Scale



รองรับข้อมูลและการคำนวณขนาดใหญ่

Ablation: เส้นทางสู่สถิติใหม่ (Semantic Segmentation ADE20k)



The Master Proof Dashboard

Dense Tasks (Spatial)

+96%

Depth Estimation NYUv2: 0.307 RMSE
ADE20K: 47.9 mIoU

Global Tasks (Video)

SOTA

Action Recognition SSv2: 77.7% Accuracy

Forecasting (Anticipation)

+35%

Ego4D STA: 7.71 mAP
EPIC-KITCHENS: 40.8 Recall@5

Robotics

+20%

Grasping Success Rate


V-JEPA 2.1 คือโมเดลระดับ ViT-G ที่พิสูจน์แล้วว่าไร้คู่แข่งในการประเมินแบบ Frozen-Backbone

Real-World Application I: Dense Vision

Raw Input



DINOv3




V-JEPA 2.1




0.307 RMSE

อันดับ 1 ในโมเดลขนาดต่ำกว่า 2B

Real-World Application II: Future Anticipation

Frame T  Frame T+ δ
(Time to contact)




Where? (แม่นยำระดับ 2D)

What? (Semantic Noun+Verb:
'Take Paintbrush')


When?
(Anticipation Time δ : 'in 0.68s')

7.71 mAP on Ego4D
(ทิ้งห่างโมเดลก่อนหน้านี้อย่างขาดลอย)


Real-World Application III: Physical Robotics



Physical Execution



Z-Axis Depth Topography (V-JEPA 2.1)




ฟีเจอร์ที่หนาแน่น (Dense Features) ช่วยให้หุ่นยนต์เข้าใจมิติเชิงลึกได้อย่างสมบูรณ์แบบ
ส่งผลให้การวางแผนและหยิบจับวัตถุแม่นยำยิ่งขึ้น

Real-World Application IV: Navigation Planning

Latent Space Trajectory Planning

Start Frame

Goal Frame



Previous SOTA (SD-VAE) - 128 Denoising Steps

103.2 seconds

V-JEPA 2.1 - 8 Denoising Steps

10.6 seconds

ความเร็วในการวางแผนเพิ่มขึ้น 10 เท่า โดยไม่ต้องแลกกับความแม่นยำ

The Future: Distillation & Accessibility

ViT-G (2 Billion)

The Massive Teacher. SOTA Performance.


ViT-L (300 Million)

The Efficient Student. 46.7 mIoU on ADE20K.

ViT-B (80 Million)

Lightweight & Deployable.

ประสิทธิภาพระดับโลกที่ถูกบีบอัด:
เทคโนโลยี Distillation ถ่ายทอดความ
รู้จากโมเดล 2B สู่โมเดลขนาดเล็ก
เพื่อการใช้งานจริงที่รวดเร็วและใช้
ทรัพยากรน้อยลง



V-JEPA 2.1 ไม่ใช่เพียง
แค่การอัปเดต แต่คือการ
กำหนดมาตรฐานใหม่
เป็นโมเดลแรกที่หลอมรวม
ความเข้าใจโครงสร้างภาพ
เชิงลึก (Dense Layouts)
เข้ากับพลวัตของวิดีโอ
(Temporal Dynamics)
อย่างไร้รอยต่อ