



ถอดรหัสสุดยอด MoE ขนาด 700M
Active Parameters และเทคโนโลยี
Markovian RSA จาก Zephyra




พลังระดับยักษ์ ในขนาดกะทัดรัด

ZAYA1-8B (0.7B/8B)



โมเดลขับเคลื่อนด้วยพารามิเตอร์ที่ทำงานจริงเพียง 700 ล้านตัว (0.7B Active Parameters) ต่อหนึ่ง Token


DeepSeek-R1 (37B/671B)



สัดส่วน 'Active vs Total Parameters' ที่ฉีกกฎเดิม

การคิดวิเคราะห์ทางคณิตศาสตร์ขั้นสูงไม่จำเป็นต้องใช้โมเดลขนาดใหญ่เสมอไป หากมีการออกแบบสถาปัตยกรรม (MoE) และการคำนวณขณะใช้งาน (Test-Time Compute) ที่ทำงานสอดคล้องกันอย่างสมบูรณ์แบบ

ทะลุขีดจำกัดด้วย Markovian RSA




AIME'25:
ก้าวกระโดดสู่ 91.9%


HMMT'25 Feb:
พุ่งทะยานสู่ 89.6%

เมื่อผสาน ZAYA1-8B เข้ากับ
Markovian RSA
ช่องว่างระหว่างโมเดลขนาดเล็กและ
โมเดลยักษ์ระดับ Frontier
(Gemini-2.5 Pro, GPT-5-High)
จะถูกกลายลงอย่างรวดเร็ว

5 เสาหลักแห่งเครื่องยนต์ ZAYA1-8B



สถาปัตยกรรม I: บีบอัดเพื่อประสิทธิภาพสูงสุด



Compressed Convolutional Attention (CCA)




ผสมผสานลำดับข้อมูลใน Latent Space ที่ถูกบีบอัด ช่วยลดทั้งภาระการคำนวณ (FLOPs) และขนาดของ KV-cache ได้อย่างมหาศาล

Residual Scaling

ทำงานเสมือนวาล์วควบคุมแรงดัน ช่วยจำกัดการขยายตัวของ Norm ในเลเยอร์ที่ลึกขึ้น แทนของ Norm ในเลเยอร์ที่ลึกขึ้น โดยแทบไม่ต้องพึ่งพารามิเตอร์เพิ่มเติม

สถาปัตยกรรม II: เราเตอร์ที่เรียบง่ายและแม่นยำ


The Editorial Engineering Blueprint. Split-screen schematic comparison.



Linear Router แบบดั้งเดิมทำให้การเลือก Expert คลุมเครือ ZAYA1 ยกระดับด้วย MLP Router ผสานกับ Exponential Depth Averaging (EDA) การตัดสินใจที่เรียบง่าย (Top-1 Routing) ช่วยให้ Expert แต่ละตัวมีความเชี่ยวชาญเฉพาะทางอย่างแท้จริง ลดความซ้ำซ้อน และประหยัดทรัพยากร


นวัตกรรมข้อมูล: ตัดส่วนหาง คงคำตอบสุดท้าย

Answer-Preserving (AP) Trimming




ปัญหาหลักของการฝึกสอนแบบใช้เหตุผลคือ Context Window เริ่มต้นที่แคบ (4K) วิธีแก้ปัญหามันคือการ "ตัดเฉือน" (Truncate) ส่วนหางของกระบวนการคิดออก แต่รักษาล็อก "คำตอบสุดท้าย" ไว้รอคอย เพื่อบังคับให้โมเดลเรียนรู้วิธีการไปสู่เป้าหมายที่ถูกต้องตั้งแต่วัยแรกของการ Pretraining

4 ลำดับขั้นของน้ำตกแห่งการเรียนรู้เสริม (RL Cascade)




The Spine: โครงสร้างหลักขับเคลื่อนด้วยอัลกอริทึม PipelineRL แบบ Asynchronous, DPPO Binary-TV และ Muon Optimizer

ผลลัพธ์จากการเรียนรู้เสริมแบบตรวจสอบได้ (Verifiable RL Impact)



Verifiable RL ทำหน้าที่ดึงขีดความสามารถแฝง (Latent Capabilities) ที่ถูกสร้างไว้ในขั้นตอน Midtraining ออกมาให้เห็นผลได้อย่างสมบูรณ์แบบ โดยใช้จำนวนก้าวการอัปเดต (Optimizer steps) ที่น้อยมาก


อาวุธลับแห่งการอนุมาน: Markovian RSA



- **Test-Time Compute (TTC):** การขยายขีดความสามารถของโมเดล ด้วยการเพิ่มพลังประมวลผลขณะใช้งาน
- **สูตรลับ:** Recursive Self-Aggregation (การประเมินและรวมคำตอบซ้ำ) + Bounded Workspace (พื้นที่การทำงานที่มีการจำกัดขอบเขต)

Key Insight: โมเดลที่ถูกฝึกมาการทำ Aggregation จะสามารถไตร่ตรองคำตอบได้ลึกซึ้งยิ่งขึ้นโดยไม่ต้องพึ่งพาสายพานข้อมูลที่ยาวเกินจำเป็น

เจาะลึกกระบวนการ Markovian RSA Anatomy



Step 1: Parallel Generation

สร้างสมมติฐานคู่ขนาน
16 เส้นทาง (N=16)

Step 2: Tail Extraction

แทนที่จะส่งข้อมูลทั้งหมด ระบบจะตัดเอา
เฉพาะ 'ส่วนหาง' (Tail τ) จำนวน 4K
Token ที่เป็นแก่นของกระบวนการคิด

Step 3: Bounded Aggregation



ถึง 4 ทาง (C=4) มารวมกันเพื่อ
สร้าง Prompt ในรอบถัดไป

Why it matters: แก้ปัญหาคอขวดของ Context อย่างเด็ดขาด
ปลดล็อกการคิดเชิงลึกโดยไม่ทำให้เปลืองทรัพยากรหน่วยความจำ

เมทริกซ์เปรียบเทียบกลยุทธ์ TTC (The Test-Time Compute Matrix)

กลยุทธ์	รูปแบบการถอดรหัส (Decode Profile)	ข้อมูลที่ส่งต่อ (State Passed)	การขยายตัวของ Context
Single Long-CoT	เติบโตตามความยาวรวม	ทั้งก้อน	ไร้ขอบเขต (Unbounded)
Full-chain RSA	แตกแขนงรอบด้าน	ทุกเส้นทางแบบเต็ม	ขยายตัวระดับทวีคูณ (Massive)
Delethink	แตกแขนงแบ่งส่วน	หางเดียว	ควบคุมได้ แต่ไม่มีการเปรียบเทียบ
Markovian RSA	วนซ้ำและคัดกรอง	C หาง (จำกัดที่ 4K)	มีขอบเขตชัดเจนและฉลาดที่สุด (Bounded & Aggregated)

บทพิสูจน์การสเกลระดับ Test-Time (Test-Time Scaling in Action)



Data Insight

เมื่อเพิ่มงบประมาณต่อรอบ (β) จาก 8K สู่ 40K
อัตราความสำเร็จบน HMMT'25 พุ่งทะยานจาก
80.8% เป็น 89.6%

Core Takeaway

มาตรวัดความคุ้มค่าที่แท้จริงในยุคต่อไป
ไม่ใช่ปริมาณพารามิเตอร์รวม แต่เป็น
'Active Params × Generated Tokens'
ซึ่ง ZAYA1-8B ทำได้อย่างมีประสิทธิภาพสูงสุด

ชุมพลังเบื้องหลัง: สถาปัตยกรรมสแต็ก AMD

ตอกย้ำความเสถียรระดับอุตสาหกรรม

1. ขับเคลื่อนการฝึกสอนทั้งหมด 100% ผ่าน AMD MI300X GPUs
2. เชื่อมต่อแบบไร้คอขวดด้วย Pensando Pollara 400 Networking

เป็นการพิสูจน์ศักยภาพระดับ Production-ready

เป็นการพิสูจน์ศักยภาพระดับ Production-ready ของสแต็ก AMD ในการรองรับโมเดลขนาด 8B ตลอดกระบวนการตั้งแต่งาน Pretraining ขึ้นพื้นฐาน ไปจนถึง SFT Context ยาวระดับ 131K

กระบวนทัศน์ใหม่แห่งอนาคตการสเกลโมเดล AI

Parallel Test-Time Compute (Markovian RSA)



โมเดลขนาดมหึมาแบบดั้งเดิมไม่ใช่ทางออกเดียวอีกต่อไป อนาคตคือการผสาน
'แกนประมวลผลที่กะทัดรัดแต่แม่นยำ' (MoE++) เข้ากับ 'พื้นที่การคิดแบบคู่ขนาน' (Markovian RSA)

การจัดการเส้นทางข้อมูลอย่างฉลาด (Smart Routing) และการสรุปผลอย่างมีขอบเขต (Bounded Aggregation)
สามารถเอาชนะความหนาแน่นของข้อมูลแบบดุดันได้ (Beats brute-force density)

ZAYA1-8B คือพิมพ์เขียวของยุคต่อไป